

# 矩阵手册

[ <http://matrixcookbook.com> ]

Kaare Brandt Petersen  
Michael Syskind Pedersen

版本：2012年11月15日

---

## 介绍

这是什么？ 这些页面是关于矩阵及其相关事项的事实（身份、近似、不等式、关系等）的集合。它以这种形式收集起来，以方便任何想要快速查阅的人。

免责声明：这里介绍的身份、近似和关系显然不是发明的，而是从大量来源中收集、借用和复制的。这些来源包括在互联网上找到的类似但较短的笔记和书籍附录-请参阅参考文献以获取完整列表。

错误：很可能存在错误、拼写错误和错误，我们对此表示歉意，并将非常感谢在[cookbook@2302.dk](mailto:cookbook@2302.dk)接收更正。

持续进行中：保持一个涉及矩阵的大型关系存储库的项目自然是持续进行的，版本将在标题中的日期中显示。

建议：欢迎您提供有关额外内容或某些主题的详细说明 [acookbook@2302.dk](mailto:acookbook@2302.dk)。

关键词：矩阵代数，矩阵关系，矩阵恒等式，行列式的导数，逆矩阵的导数，矩阵的微分。

致谢：我们要感谢以下人员对我们的贡献和建议：Bill Baxter, Brian Templeton, Christian Rishøj, Christian Schröppel, Dan Boley, Douglas L. Theobald, Esben Hoegh-Rasmussen, Evaristos Karsenas, Georg Martius, Glynne Casteel, Jan Larsen, Jun Bin Gao, Jürgen Struckmeier, Kamil Dedećius, Karim T. Abou-Moustafa, Korbinian Strimmer, Lars Christiansen, Lars Kai Hansen, Leland Wilkinson, Liguó He, Loïc Thibaut, Markus Froeb, Michael Hubatka, Miguel Barˆao, Ole Winther, Pavel Sakov, Stephan Hattinger, Troels Pedersen, Vasile Sima, Vincent Rabaud, Zhao Shui He。我们还要感谢奥蒂康基金会资助我们的博士研究。

## 目录

<b>1</b>	<b>基础知识</b>	<b>6</b>
1.1	迹	6
1.2	行列式	6
1.3	特殊情况 $2 \times 2$	7
<b>2</b>	<b>导数</b>	<b>8</b>
2.1	行列式的导数	8
2.2	逆矩阵的导数	9
2.3	特征值的导数	10
2.4	矩阵、向量和标量形式的导数	10
2.5	迹的导数	12
2.6	向量范数的导数	14
2.7	矩阵范数的导数	14
2.8	结构化矩阵的导数	14
<b>3</b>	<b>逆矩阵</b>	<b>17</b>
3.1	基本	17
3.2	精确关系	18
3.3	对逆矩阵的影响	20
3.4	近似	20
3.5	广义逆矩阵	21
3.6	伪逆矩阵	21
<b>4</b>	<b>复数矩阵</b>	<b>24</b>
4.1	复数导数	24
4.2	高阶和非线性导数	26
4.3	复数和的逆	27
<b>5</b>	<b>解和分解</b>	<b>28</b>
5.1	线性方程的解	28
5.2	特征值和特征向量	30
5.3	奇异值分解	31
5.4	三角分解	32
5.5	LU分解	32
5.6	LDM分解	33
5.7	LDL分解	33
<b>6</b>	<b>统计与概率</b>	<b>34</b>
6.1	矩的定义	34
6.2	线性组合的期望	35
6.3	加权标量变量	36
<b>7</b>	<b>多元分布</b>	<b>37</b>
7.1	柯西分布	37
7.2	狄利克雷分布	37
7.3	正态分布	37
7.4	正态逆伽马分布	37
7.5	高斯分布	37
7.6	多项分布	37

7.7 学生t分布 .....	37
7.8 Wishart .....	38
7.9 逆Wishart分布 .....	39
<b>8 高斯分布</b> .....	<b>40</b>
8.1 基础知识 .....	40
8.2 矩的定义 .....	42
8.3 其他 .....	44
8.4 高斯混合模型 .....	44
<b>9个特殊矩阵</b> .....	<b>46</b>
9.1 块矩阵 .....	46
9.2 离散傅里叶变换矩阵 .....	47
9.3 Hermite矩阵和skew-Hermite矩阵 .....	48
9.4 幂等矩阵 .....	49
9.5 正交矩阵 .....	49
9.6 正定和半正定矩阵 .....	50
9.7 单入口矩阵 .....	52
9.8 对称矩阵, 反对称矩阵 .....	54
9.9 Toeplitz矩阵 .....	54
9.10 过渡矩阵 .....	55
9.11 单位矩阵, 排列和移位 .....	56
9.12 Vandermonde矩阵 .....	57
<b>10 函数和运算符</b> .....	<b>58</b>
10.1 函数和级数 .....	58
10.2 Kronecker和Vec运算符 .....	59
10.3 向量范数 .....	61
10.4 矩阵范数 .....	61
10.5 秩 .....	62
10.6 包含Dirac Delta函数的积分 .....	62
10.7 其他 .....	63
<b>一维结果</b> .....	<b>64</b>
A.1 高斯分布 .....	64
A.2 一维高斯混合 .....	65
<b>B 证明和细节</b> .....	<b>66</b>
B.1 其他证明 .....	66

## 符号和术语

$\mathbf{A}$	矩阵
$\mathbf{A}_{ij}$	为某种目的而索引的矩阵
$\mathbf{A}_i$	为某种目的而索引的矩阵
$\mathbf{A}^{ij}$	为某种目的而索引的矩阵
$\mathbf{A}^n$	为某种目的而索引的矩阵或 一个方阵的 $n$ 次幂
$\mathbf{A}^{-1}$	矩阵 $\mathbf{A}$ 的逆矩阵
$\mathbf{A}^+$	矩阵 $\mathbf{A}$ 的伪逆矩阵(见第3.6节)
$\mathbf{A}^{1/2}$	矩阵的平方根（如果存在），不是逐元素的
$(\mathbf{A})_{ij}$	矩阵 $\mathbf{A}$ 的 $(i, j)$ 元素
$A_{ij}$	矩阵 $\mathbf{A}$ 的 $(i, j)$ 元素
$[\mathbf{A}]_{ij}$	矩阵 $\mathbf{A}$ 的 $ij$ 子矩阵，即删除第 $i$ 行和第 $j$ 列
$\mathbf{a}$	向量（列向量）
$\mathbf{a}_i$	为某种目的而索引的向量
$a_i$	向量 $\mathbf{a}$ 的第 $i$ 个元素
$a$	标量
$\Re z$	标量的实部
$\Re \mathbf{z}$	向量的实部
$\Re \mathbf{Z}$	矩阵的实部
$\Im z$	标量的虚部
$\Im \mathbf{z}$	向量的虚部
$\Im \mathbf{Z}$	矩阵的虚部
$\det(\mathbf{A})$	矩阵 $\mathbf{A}$ 的行列式
$\text{Tr}(\mathbf{A})$	矩阵 $\mathbf{A}$ 的迹
$\text{diag}(\mathbf{A})$	矩阵 $\mathbf{A}$ 的对角矩阵，即 $(\text{diag}(\mathbf{A}))_{ij} = \delta_{ij} A_{ij}$
$\text{eig}(\mathbf{A})$	矩阵 $\mathbf{A}$ 的特征值
$\text{vec}(\mathbf{A})$	矩阵 $\mathbf{A}$ 的向量形式（见第10.2.2节）
$\sup$	集合的上确界
$\ \mathbf{A}\ $	矩阵范数（下标表示范数类型）
$\mathbf{A}^T$	转置矩阵
$\mathbf{A}^{-T}$	转置的逆矩阵和逆的转置矩阵， $\mathbf{A}^{-T} = (\mathbf{A}^{-1})^T = (\mathbf{A}^T)^{-1}$ .
$\mathbf{A}^*$	共轭矩阵
$\mathbf{A}^H$	转置共轭矩阵（厄米矩阵）
$\mathbf{A} \circ \mathbf{B}$	哈达玛积（逐元素乘积）
$\mathbf{A} \otimes \mathbf{B}$	克罗内克积
$\mathbf{0}$	零矩阵。所有元素都为零。
$\mathbf{I}$	单位矩阵
$\mathbf{J}^{ij}$	单元素矩阵，在 $(i, j)$ 处为1，其他地方为零
$\Sigma$	正定矩阵
$\Lambda$	对角矩阵

## 1 基础知识

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1} \quad (1)$$

$$(\mathbf{ABC}\dots)^{-1} = \dots\mathbf{C}^{-1}\mathbf{B}^{-1}\mathbf{A}^{-1} \quad (2)$$

$$(\mathbf{A}^T)^{-1} = (\mathbf{A}^{-1})^T \quad (3)$$

$$(\mathbf{A} + \mathbf{B})^T = \mathbf{A}^T + \mathbf{B}^T \quad (4)$$

$$(\mathbf{AB})^T = \mathbf{B}^T\mathbf{A}^T \quad (5)$$

$$(\mathbf{ABC}\dots)^T = \dots\mathbf{C}^T\mathbf{B}^T\mathbf{A}^T \quad (6)$$

$$(\mathbf{A}^H)^{-1} = (\mathbf{A}^{-1})^H \quad (7)$$

$$(\mathbf{A} + \mathbf{B})^H = \mathbf{A}^H + \mathbf{B}^H \quad (8)$$

$$(\mathbf{AB})^H = \mathbf{B}^H\mathbf{A}^H \quad (9)$$

$$(\mathbf{ABC}\dots)^H = \dots\mathbf{C}^H\mathbf{B}^H\mathbf{A}^H \quad (10)$$

### 1.1 迹

$$\text{Tr}(\mathbf{A}) = \sum_i A_{ii} \quad (11)$$

$$\text{Tr}(\mathbf{A}) = \sum_i \lambda_i, \quad \lambda_i = \text{eig}(\mathbf{A}) \quad (12)$$

$$\text{Tr}(\mathbf{A}) = \text{Tr}(\mathbf{A}^T) \quad (13)$$

$$\text{Tr}(\mathbf{AB}) = \text{Tr}(\mathbf{BA}) \quad (14)$$

$$\text{Tr}(\mathbf{A} + \mathbf{B}) = \text{Tr}(\mathbf{A}) + \text{Tr}(\mathbf{B}) \quad (15)$$

$$\text{Tr}(\mathbf{ABC}) = \text{Tr}(\mathbf{BCA}) = \text{Tr}(\mathbf{CAB}) \quad (16)$$

$$\mathbf{a}^T \mathbf{a} = \text{Tr}(\mathbf{a}\mathbf{a}^T) \quad (17)$$

### 1.2 行列式

设  $\mathbf{A}$  为一个  $n \times n$  矩阵。

$$\det(\mathbf{A}) = \prod_i \lambda_i \quad \lambda_i = \text{eig}(\mathbf{A}) \quad (18)$$

$$\det(c\mathbf{A}) = c^n \det(\mathbf{A}), \quad \text{如果 } \mathbf{A} \in \mathbb{R}^{n \times n} \quad (19)$$

$$\det(\mathbf{A}^T) = \det(\mathbf{A}) \quad (20)$$

$$\det(\mathbf{AB}) = \det(\mathbf{A}) \det(\mathbf{B}) \quad (21)$$

$$\det(\mathbf{A}^{-1}) = 1 / \det(\mathbf{A}) \quad (22)$$

$$\det(\mathbf{A}^n) = \det(\mathbf{A})^n \quad (23)$$

$$\det(\mathbf{I} + \mathbf{u}\mathbf{v}^T) = 1 + \mathbf{u}^T \mathbf{v} \quad (24)$$

对于  $n=2$ :

$$\det(\mathbf{I} + \mathbf{A}) = 1 + \det(\mathbf{A}) + \text{Tr}(\mathbf{A}) \quad (25)$$

对于  $n=3$ :

$$\det(\mathbf{I} + \mathbf{A}) = 1 + \det(\mathbf{A}) + \text{Tr}(\mathbf{A}) + \frac{1}{2}\text{Tr}(\mathbf{A})^2 - \frac{1}{2}\text{Tr}(\mathbf{A}^2) \quad (26)$$

对于  $n = 4$ :

$$\begin{aligned}\det(\mathbf{I} + \mathbf{A}) &= 1 + \det(\mathbf{A}) + \text{Tr}(\mathbf{A}) + \frac{1}{2} \\ &\quad + \text{Tr}(\mathbf{A})^2 - \frac{1}{2}\text{Tr}(\mathbf{A}^2) \\ &\quad + \frac{1}{6}\text{Tr}(\mathbf{A})^3 - \frac{1}{2}\text{Tr}(\mathbf{A})\text{Tr}(\mathbf{A}^2) + \frac{1}{3}\text{Tr}(\mathbf{A}^3)\end{aligned}\quad (27)$$

对于小  $\varepsilon$ , 以下近似成立

$$\det(\mathbf{I} + \varepsilon\mathbf{A}) \cong 1 + \det(\mathbf{A}) + \varepsilon\text{Tr}(\mathbf{A}) + \frac{1}{2}\varepsilon^2\text{Tr}(\mathbf{A})^2 - \frac{1}{2}\varepsilon^2\text{Tr}(\mathbf{A}^2) \quad (28)$$

### 1.3 特殊情况 2x2

考虑矩阵  $\mathbf{A}$

$$\mathbf{A} = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}$$

行列式和迹

$$\det(\mathbf{A}) = A_{11}A_{22} - A_{12}A_{21} \quad (29)$$

$$\text{Tr}(\mathbf{A}) = A_{11} + A_{22} \quad (30)$$

特征值

$$\lambda^2 - \lambda \cdot \text{Tr}(\mathbf{A}) + \det(\mathbf{A}) = 0$$

$$\begin{aligned}\lambda_1 &= \frac{\text{Tr}(\mathbf{A}) + \sqrt{\frac{\text{Tr}(\mathbf{A})^2 - 4\det(\mathbf{A})}{2}}}{2} & \lambda_2 &= \frac{\text{Tr}(\mathbf{A}) - \sqrt{\frac{\text{Tr}(\mathbf{A})^2 - 4\det(\mathbf{A})}{2}}}{2} \\ \lambda_1 + \lambda_2 &= \text{Tr}(\mathbf{A}) & \lambda_1\lambda_2 &= \det(\mathbf{A})\end{aligned}$$

特征向量

$$\mathbf{v}_1 \propto \begin{bmatrix} A_{12} \\ \lambda_1 - A_{11} \end{bmatrix} \quad \mathbf{v}_2 \propto \begin{bmatrix} A_{12} \\ \lambda_2 - A_{11} \end{bmatrix}$$

逆

$$\mathbf{A}^{-1} = \frac{1}{\det(\mathbf{A})} \begin{bmatrix} A_{22} & -A_{12} \\ -A_{21} & A_{11} \end{bmatrix} \quad (31)$$

## 2 导数

本节涵盖了关于矩阵  $\mathbf{X}$  的多个表达式的微分。请注意，我们始终假设  $\mathbf{X}$  没有特殊结构，即  $\mathbf{X}$  的元素是独立的（例如不对称、Toeplitz、正定）。有关结构化矩阵的微分，请参见第2.8节。基本假设可以用以下公式表示

$$\frac{\partial X_{kl}}{\partial X_{ij}} = \delta_{ik} \delta_{lj} \quad (32)$$

例如，向量形式如下，

$$\left[ \frac{\partial \mathbf{x}}{\partial y} \right]_i = \frac{\partial x_i}{\partial y} \quad \left[ \frac{\partial x}{\partial \mathbf{y}} \right]_i = \frac{\partial x}{\partial y_i} \quad \left[ \frac{\partial \mathbf{x}}{\partial \mathbf{y}} \right]_{ij} = \frac{\partial x_i}{\partial y_j}$$

以下规则是普遍适用的，在推导表达式的微分时非常有用 ([19])：

$$\partial \mathbf{A} = 0 \quad (\mathbf{A} \text{ 是常数}) \quad (33)$$

$$\partial(\alpha \mathbf{X}) = \alpha \partial \mathbf{X} \quad (34)$$

$$\partial(\mathbf{X} + \mathbf{Y}) = \partial \mathbf{X} + \partial \mathbf{Y} \quad (35)$$

$$\partial(\text{Tr}(\mathbf{X})) = \text{Tr}(\partial \mathbf{X}) \quad (36)$$

$$\partial(\mathbf{X}\mathbf{Y}) = (\partial \mathbf{X})\mathbf{Y} + \mathbf{X}(\partial \mathbf{Y}) \quad (37)$$

$$\partial(\mathbf{X} \circ \mathbf{Y}) = (\partial \mathbf{X}) \circ \mathbf{Y} + \mathbf{X} \circ (\partial \mathbf{Y}) \quad (38)$$

$$\partial(\mathbf{X} \otimes \mathbf{Y}) = (\partial \mathbf{X}) \otimes \mathbf{Y} + \mathbf{X} \otimes (\partial \mathbf{Y}) \quad (39)$$

$$\partial(\mathbf{X}^{-1}) = -\mathbf{X}^{-1}(\partial \mathbf{X})\mathbf{X}^{-1} \quad (40)$$

$$\partial(\det(\mathbf{X})) = \text{Tr}(\text{adj}(\mathbf{X})\partial \mathbf{X}) \quad (41)$$

$$\partial(\det(\mathbf{X})) = \det(\mathbf{X})\text{Tr}(\mathbf{X}^{-1}\partial \mathbf{X}) \quad (42)$$

$$\partial(\ln(\det(\mathbf{X}))) = \text{Tr}(\mathbf{X}^{-1}\partial \mathbf{X}) \quad (43)$$

$$\partial \mathbf{X}^T = (\partial \mathbf{X})^T \quad (44)$$

$$\partial \mathbf{X}^H = (\partial \mathbf{X})^H \quad (45)$$

### 2.1 行列式的导数

#### 2.1.1 一般形式

$$\frac{\partial \det(\mathbf{Y})}{\partial x} = \det(\mathbf{Y}) \text{Tr} \left[ \mathbf{Y}^{-1} \frac{\partial \mathbf{Y}}{\partial x} \right] \quad (46)$$

$$\sum_k \frac{\partial \det(\mathbf{X})}{\partial X_{ik}} X_{jk} = \delta_{ij} \det(\mathbf{X}) \quad (47)$$

$$\begin{aligned} \frac{\partial^2 \det(\mathbf{Y})}{\partial x^2} &= \det(\mathbf{Y}) \left[ \text{迹} \left[ \mathbf{Y}^{-1} \frac{\partial^2 \mathbf{Y}}{\partial x^2} \right] \right. \\ &\quad + \text{迹} \left[ \mathbf{Y}^{-1} \frac{\partial \mathbf{Y}}{\partial x} \right] \text{迹} \left[ \mathbf{Y}^{-1} \frac{\partial \mathbf{Y}}{\partial x} \right] \\ &\quad \left. - \text{迹} \left[ \left( \mathbf{Y}^{-1} \frac{\partial \mathbf{Y}}{\partial x} \right) \left( \mathbf{Y}^{-1} \frac{\partial \mathbf{Y}}{\partial x} \right) \right] \right] \quad (48) \end{aligned}$$



## 2.1.2 线性形式

$$\frac{\partial \det(\mathbf{X})}{\partial \mathbf{X}} = \det(\mathbf{X})(\mathbf{X}^{-1})^T \quad (49)$$

$$\sum_k \frac{\partial \det(\mathbf{X})}{\partial X_{ik}} X_{jk} = \delta_{ij} \det(\mathbf{X}) \quad (50)$$

$$\frac{\partial \det(\mathbf{AXB})}{\partial \mathbf{X}} = \det(\mathbf{AXB})(\mathbf{X}^{-1})^T = \det(\mathbf{AXB})(\mathbf{X}^T)^{-1} \quad (51)$$

## 2.1.3 方阵形式

如果  $\mathbf{X}$  是方阵且可逆, 则

$$\frac{\partial \det(\mathbf{X}^T \mathbf{A} \mathbf{X})}{\partial \mathbf{X}} = 2 \det(\mathbf{X}^T \mathbf{A} \mathbf{X}) \mathbf{X}^{-T} \quad (52)$$

如果  $\mathbf{X}$  不是方阵但  $\mathbf{A}$  是对称的, 则

$$\frac{\partial \det(\mathbf{X}^T \mathbf{A} \mathbf{X})}{\partial \mathbf{X}} = 2 \det(\mathbf{X}^T \mathbf{A} \mathbf{X}) \mathbf{A} \mathbf{X} (\mathbf{X}^T \mathbf{A} \mathbf{X})^{-1} \quad (53)$$

如果  $\mathbf{X}$  不是方阵且  $\mathbf{A}$  不对称, 则

$$\frac{\partial \det(\mathbf{X}^T \mathbf{A} \mathbf{X})}{\partial \mathbf{X}} = \det(\mathbf{X}^T \mathbf{A} \mathbf{X}) (\mathbf{A} \mathbf{X} (\mathbf{X}^T \mathbf{A} \mathbf{X})^{-1} + \mathbf{A}^T \mathbf{X} (\mathbf{X}^T \mathbf{A}^T \mathbf{X})^{-1}) \quad (54)$$

## 2.1.4 其他非线性形式

一些特殊情况是 (见[9, 7])

$$\frac{\partial \ln \det(\mathbf{X}^T \mathbf{X})}{\partial \mathbf{X}} = 2(\mathbf{X}^+)^T \quad (55)$$

$$\frac{\partial \ln \det(\mathbf{X}^T \mathbf{X})}{\partial \mathbf{X}^+} = -2\mathbf{X}^T \quad (56)$$

$$\frac{\partial \ln |\det(\mathbf{X})|}{\partial \mathbf{X}} = (\mathbf{X}^{-1})^T = (\mathbf{X}^T)^{-1} \quad (57)$$

$$\frac{\partial \det(\mathbf{X}^k)}{\partial \mathbf{X}} = k \det(\mathbf{X}^k) \mathbf{X}^{-T} \quad (58)$$

## 2.2 逆矩阵的导数

从[27]我们有基本等式

$$\frac{\partial \mathbf{Y}^{-1}}{\partial x} = -\mathbf{Y}^{-1} \frac{\partial \mathbf{Y}}{\partial x} \mathbf{Y}^{-1} \quad (59)$$

由此可见

$$\frac{\partial(\mathbf{X}^{-1})_{kl}}{\partial X_{ij}} = -(\mathbf{X}^{-1})_{ki}(\mathbf{X}^{-1})_{jl} \quad (60)$$

$$\frac{\partial \mathbf{a}^T \mathbf{X}^{-1} \mathbf{b}}{\partial \mathbf{X}} = -\mathbf{X}^{-T} \mathbf{a} \mathbf{b}^T \mathbf{X}^{-T} \quad (61)$$

$$\frac{\partial \det(\mathbf{X}^{-1})}{\partial \mathbf{X}} = -\det(\mathbf{X}^{-1})(\mathbf{X}^{-1})^T \quad (62)$$

$$\frac{\partial \text{Tr}(\mathbf{A} \mathbf{X}^{-1} \mathbf{B})}{\partial \mathbf{X}} = -(\mathbf{X}^{-1} \mathbf{B} \mathbf{A} \mathbf{X}^{-1})^T \quad (63)$$

$$\frac{\partial \text{Tr}((\mathbf{X} + \mathbf{A})^{-1})}{\partial \mathbf{X}} = -((\mathbf{X} + \mathbf{A})^{-1}(\mathbf{X} + \mathbf{A})^{-1})^T \quad (64)$$

从[32]我们有以下结果：设  $\mathbf{A}$  是一个  $n \times n$  可逆方阵， $\mathbf{W}$  是  $\mathbf{A}$  的逆矩阵， $J(\mathbf{A})$  是一个关于  $\mathbf{A}$  的  $n$  元可微函数，那么  $J$  关于  $\mathbf{A}$  和  $\mathbf{W}$  的偏导数满足

$$\frac{\partial J}{\partial \mathbf{A}} = -\mathbf{A}^{-T} \frac{\partial J}{\partial \mathbf{W}} \mathbf{A}^{-T}$$

### 2.3 特征值的导数

$$\frac{\partial}{\partial \mathbf{X}} \sum \text{eig}(\mathbf{X}) = \frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X}) = \mathbf{I} \quad (65)$$

$$\frac{\partial}{\partial \mathbf{X}} \prod \text{eig}(\mathbf{X}) = \frac{\partial}{\partial \mathbf{X}} \det(\mathbf{X}) = \det(\mathbf{X}) \mathbf{X}^{-T} \quad (66)$$

如果  $\mathbf{A}$  是实对称矩阵， $\lambda_i$  和  $\mathbf{v}_i$  是  $\mathbf{A}$  的不同特征值和特征向量（见(276)），则[33]

$$\partial \lambda_i = \mathbf{v}_i^T \partial(\mathbf{A}) \mathbf{v}_i \quad (67)$$

$$\partial \mathbf{v}_i = (\lambda_i \mathbf{I} - \mathbf{A})^+ \partial(\mathbf{A}) \mathbf{v}_i \quad (68)$$

### 2.4 矩阵、向量和标量形式的导数

#### 2.4.1 一阶

$$\frac{\partial \mathbf{x}^T \mathbf{a}}{\partial \mathbf{x}} = \frac{\partial \mathbf{a}^T \mathbf{x}}{\partial \mathbf{x}} = \mathbf{a} \quad (69)$$

$$\frac{\partial \mathbf{a}^T \mathbf{X} \mathbf{b}}{\partial \mathbf{X}} = \mathbf{a} \mathbf{b}^T \quad (70)$$

$$\frac{\partial \mathbf{a}^T \mathbf{X}^T \mathbf{b}}{\partial \mathbf{X}} = \mathbf{b} \mathbf{a}^T \quad (71)$$

$$\frac{\partial \mathbf{a}^T \mathbf{X} \mathbf{a}}{\partial \mathbf{X}} = \frac{\partial \mathbf{a}^T \mathbf{X}^T \mathbf{a}}{\partial \mathbf{X}} = \mathbf{a} \mathbf{a}^T \quad (72)$$

$$\frac{\partial \mathbf{X}}{\partial X_{ij}} = \mathbf{J}^{ij} \quad (73)$$

$$\frac{\partial (\mathbf{X} \mathbf{A})_{ij}}{\partial X_{mn}} = \delta_{im} (\mathbf{A})_{nj} = (\mathbf{J}^{mn} \mathbf{A})_{ij} \quad (74)$$

$$\frac{\partial (\mathbf{X}^T \mathbf{A})_{ij}}{\partial X_{mn}} = \delta_{in} (\mathbf{A})_{mj} = (\mathbf{J}^{nm} \mathbf{A})_{ij} \quad (75)$$

## 2.4.2 二阶

$$\frac{\partial}{\partial X_{ij}} \sum_{klmn} X_{kl} X_{mn} = 2 \sum_{kl} X_{kl} \quad (76)$$

$$\frac{\partial \mathbf{b}^T \mathbf{X}^T \mathbf{X} \mathbf{c}}{\partial \mathbf{X}} = \mathbf{X}(\mathbf{b} \mathbf{c}^T + \mathbf{c} \mathbf{b}^T) \quad (77)$$

$$\frac{\partial (\mathbf{B} \mathbf{x} + \mathbf{b})^T \mathbf{C} (\mathbf{D} \mathbf{x} + \mathbf{d})}{\partial \mathbf{x}} = \mathbf{B}^T \mathbf{C} (\mathbf{D} \mathbf{x} + \mathbf{d}) + \mathbf{D}^T \mathbf{C}^T (\mathbf{B} \mathbf{x} + \mathbf{b}) \quad (78)$$

$$\frac{\partial (\mathbf{X}^T \mathbf{B} \mathbf{X})_{kl}}{\partial X_{ij}} = \delta_{lj} (\mathbf{X}^T \mathbf{B})_{ki} + \delta_{kj} (\mathbf{B} \mathbf{X})_{il} \quad (79)$$

$$\frac{\partial (\mathbf{X}^T \mathbf{B} \mathbf{X})}{\partial X_{ij}} = \mathbf{X}^T \mathbf{B} \mathbf{J}^{ij} + \mathbf{J}^{ji} \mathbf{B} \mathbf{X} \quad (\mathbf{J}^{ij})_{kl} = \delta_{ik} \delta_{jl} \quad (80)$$

有关单入矩阵  $\mathbf{J}^{ij}$  的有用性质，请参见第9.7节

$$\frac{\partial \mathbf{x}^T \mathbf{B} \mathbf{x}}{\partial \mathbf{x}} = (\mathbf{B} + \mathbf{B}^T) \mathbf{x} \quad (81)$$

$$\frac{\partial \mathbf{b}^T \mathbf{X}^T \mathbf{D} \mathbf{X} \mathbf{c}}{\partial \mathbf{X}} = \mathbf{D}^T \mathbf{X} \mathbf{b} \mathbf{c}^T + \mathbf{D} \mathbf{X} \mathbf{c} \mathbf{b}^T \quad (82)$$

$$\frac{\partial}{\partial \mathbf{X}} (\mathbf{X} \mathbf{b} + \mathbf{c})^T \mathbf{D} (\mathbf{X} \mathbf{b} + \mathbf{c}) = (\mathbf{D} + \mathbf{D}^T) (\mathbf{X} \mathbf{b} + \mathbf{c}) \mathbf{b}^T \quad (83)$$

假设  $\mathbf{W}$  是对称的，那么

$$\frac{\partial}{\partial \mathbf{s}} (\mathbf{x} - \mathbf{A} \mathbf{s})^T \mathbf{W} (\mathbf{x} - \mathbf{A} \mathbf{s}) = -2 \mathbf{A}^T \mathbf{W} (\mathbf{x} - \mathbf{A} \mathbf{s}) \quad (84)$$

$$\frac{\partial}{\partial \mathbf{x}} (\mathbf{x} - \mathbf{s})^T \mathbf{W} (\mathbf{x} - \mathbf{s}) = 2 \mathbf{W} (\mathbf{x} - \mathbf{s}) \quad (85)$$

$$\frac{\partial}{\partial \mathbf{s}} (\mathbf{x} - \mathbf{s})^T \mathbf{W} (\mathbf{x} - \mathbf{s}) = -2 \mathbf{W} (\mathbf{x} - \mathbf{s}) \quad (86)$$

$$\frac{\partial}{\partial \mathbf{x}} (\mathbf{x} - \mathbf{A} \mathbf{s})^T \mathbf{W} (\mathbf{x} - \mathbf{A} \mathbf{s}) = 2 \mathbf{W} (\mathbf{x} - \mathbf{A} \mathbf{s}) \quad (87)$$

$$\frac{\partial}{\partial \mathbf{A}} (\mathbf{x} - \mathbf{A} \mathbf{s})^T \mathbf{W} (\mathbf{x} - \mathbf{A} \mathbf{s}) = -2 \mathbf{W} (\mathbf{x} - \mathbf{A} \mathbf{s}) \mathbf{s}^T \quad (88)$$

作为具有复数值的情况，以下成立

$$\frac{\partial (a - \mathbf{x}^H \mathbf{b})^2}{\partial \mathbf{x}} = -2 \mathbf{b} (a - \mathbf{x}^H \mathbf{b})^* \quad (89)$$

这个公式也被称为LMS算法[14]

## 2.4.3 高阶和非线性

$$\frac{\partial (\mathbf{X}^n)_{kl}}{\partial X_{ij}} = \sum_{r=0}^{n-1} (\mathbf{X}^r \mathbf{J}^{ij} \mathbf{X}^{n-1-r})_{kl} \quad (90)$$

有关以上内容的证明，请参见B.1.3。

$$\frac{\partial}{\partial \mathbf{X}} \mathbf{a}^T \mathbf{X}^n \mathbf{b} = \sum_{r=0}^{n-1} (\mathbf{X}^r)^T \mathbf{a} \mathbf{b}^T (\mathbf{X}^{n-1-r})^T \quad (91)$$

$$\begin{aligned} \frac{\partial}{\partial \mathbf{X}} \mathbf{a}^T (\mathbf{X}^n)^T \mathbf{X}^n \mathbf{b} &= \sum_{r=0}^{n-1} \left[ \mathbf{X}^{n-1-r} \mathbf{a} \mathbf{b}^T (\mathbf{X}^n)^T \mathbf{X}^r \right. \\ &\quad \left. + (\mathbf{X}^r)^T \mathbf{X}^n \mathbf{a} \mathbf{b}^T (\mathbf{X}^{n-1-r})^T \right] \end{aligned} \quad (92)$$

有关证明, 请参见B.1.3。

假设  $\mathbf{s}$  和  $\mathbf{r}$  是  $\mathbf{x}$  的函数, 即  $\mathbf{s} = \mathbf{s}(\mathbf{x}), \mathbf{r} = \mathbf{r}(\mathbf{x})$ , 且  $\mathbf{A}$  是一个常数, 那么

$$\frac{\partial}{\partial \mathbf{x}} \mathbf{s}^T \mathbf{A} \mathbf{r} = \left[ \frac{\partial \mathbf{s}}{\partial \mathbf{x}} \right]^T \mathbf{A} \mathbf{r} + \left[ \frac{\partial \mathbf{r}}{\partial \mathbf{x}} \right]^T \mathbf{A}^T \mathbf{s} \quad (93)$$

$$\frac{\partial}{\partial \mathbf{x}} \frac{(\mathbf{A} \mathbf{x})^T (\mathbf{A} \mathbf{x})}{(\mathbf{B} \mathbf{x})^T (\mathbf{B} \mathbf{x})} = \frac{\partial}{\partial \mathbf{x}} \frac{\mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x}}{\mathbf{x}^T \mathbf{B}^T \mathbf{B} \mathbf{x}} \quad (94)$$

$$= 2 \frac{\mathbf{A}^T \mathbf{A} \mathbf{x}}{\mathbf{x}^T \mathbf{B} \mathbf{B} \mathbf{x}} - 2 \frac{\mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} \mathbf{B}^T \mathbf{B} \mathbf{x}}{(\mathbf{x}^T \mathbf{B}^T \mathbf{B} \mathbf{x})^2} \quad (95)$$

#### 2.4.4 梯度和海森矩阵

利用上述结果, 我们有梯度和海森矩阵

$$f = \mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{b}^T \mathbf{x} \quad (96)$$

$$\nabla_{\mathbf{x}} f = \frac{\partial f}{\partial \mathbf{x}} = (\mathbf{A} + \mathbf{A}^T) \mathbf{x} + \mathbf{b} \quad (97)$$

$$\frac{\partial^2 f}{\partial \mathbf{x} \partial \mathbf{x}^T} = \mathbf{A} + \mathbf{A}^T \quad (98)$$

### 2.5 迹的导数

假设  $F(\mathbf{X})$  是  $\mathbf{X}$  的每个元素的可微函数。那么有

$$\frac{\partial \text{Tr}(F(\mathbf{X}))}{\partial \mathbf{X}} = f(\mathbf{X})^T$$

其中  $f(\cdot)$  是  $F(\cdot)$  的标量导数。

#### 2.5.1 一阶

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X}) = \mathbf{I} \quad (99)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X} \mathbf{A}) = \mathbf{A}^T \quad (100)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{A} \mathbf{X} \mathbf{B}) = \mathbf{A}^T \mathbf{B}^T \quad (101)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{A} \mathbf{X}^T \mathbf{B}) = \mathbf{B} \mathbf{A} \quad (102)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X}^T \mathbf{A}) = \mathbf{A} \quad (103)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{A} \mathbf{X}^T) = \mathbf{A} \quad (104)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{A} \otimes \mathbf{X}) = \text{Tr}(\mathbf{A}) \mathbf{I} \quad (105)$$

## 2.5.2 二阶

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X}^2) = 2\mathbf{X}^T \quad (106)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X}^2 \mathbf{B}) = (\mathbf{X}\mathbf{B} + \mathbf{B}\mathbf{X})^T \quad (107)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X}^T \mathbf{B}\mathbf{X}) = \mathbf{B}\mathbf{X} + \mathbf{B}^T \mathbf{X} \quad (108)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{B}\mathbf{X}\mathbf{X}^T) = \mathbf{B}\mathbf{X} + \mathbf{B}^T \mathbf{X} \quad (109)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X}\mathbf{X}^T \mathbf{B}) = \mathbf{B}\mathbf{X} + \mathbf{B}^T \mathbf{X} \quad (110)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X}\mathbf{B}\mathbf{X}^T) = \mathbf{X}\mathbf{B}^T + \mathbf{X}\mathbf{B} \quad (111)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{B}\mathbf{X}^T \mathbf{X}) = \mathbf{X}\mathbf{B}^T + \mathbf{X}\mathbf{B} \quad (112)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X}^T \mathbf{X}\mathbf{B}) = \mathbf{X}\mathbf{B}^T + \mathbf{X}\mathbf{B} \quad (113)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{A}\mathbf{X}\mathbf{B}\mathbf{X}) = \mathbf{A}^T \mathbf{X}^T \mathbf{B}^T + \mathbf{B}^T \mathbf{X}^T \mathbf{A}^T \quad (114)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X}^T \mathbf{X}) = \frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X}\mathbf{X}^T) = 2\mathbf{X} \quad (115)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{B}^T \mathbf{X}^T \mathbf{C}\mathbf{X}\mathbf{B}) = \mathbf{C}^T \mathbf{X}\mathbf{B}\mathbf{B}^T + \mathbf{C}\mathbf{X}\mathbf{B}\mathbf{B}^T \quad (116)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}[\mathbf{X}^T \mathbf{B}\mathbf{X}\mathbf{C}] = \mathbf{B}\mathbf{X}\mathbf{C} + \mathbf{B}^T \mathbf{X}\mathbf{C}^T \quad (117)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{A}\mathbf{X}\mathbf{B}\mathbf{X}^T \mathbf{C}) = \mathbf{A}^T \mathbf{C}^T \mathbf{X}\mathbf{B}^T + \mathbf{C}\mathbf{A}\mathbf{X}\mathbf{B} \quad (118)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}[(\mathbf{A}\mathbf{X}\mathbf{B} + \mathbf{C})(\mathbf{A}\mathbf{X}\mathbf{B} + \mathbf{C})^T] = 2\mathbf{A}^T (\mathbf{A}\mathbf{X}\mathbf{B} + \mathbf{C})\mathbf{B}^T \quad (119)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X} \otimes \mathbf{X}) = \frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X})\text{Tr}(\mathbf{X}) = 2\text{Tr}(\mathbf{X})\mathbf{I} \quad (120)$$

见[7]。

## 2.5.3 高阶

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X}^k) = k(\mathbf{X}^{k-1})^T \quad (121)$$

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{A}\mathbf{X}^k) = \sum_{r=0}^{k-1} (\mathbf{X}^r \mathbf{A} \mathbf{X}^{k-r-1})^T \quad (122)$$

$$\begin{aligned} \frac{\partial}{\partial \mathbf{X}} \text{Tr}[\mathbf{B}^T \mathbf{X}^T \mathbf{C}\mathbf{X}\mathbf{X}^T \mathbf{C}\mathbf{X}\mathbf{B}] &= \mathbf{C}\mathbf{X}\mathbf{X}^T \mathbf{C}\mathbf{X}\mathbf{B}\mathbf{B}^T \\ &\quad + \mathbf{C}^T \mathbf{X}\mathbf{B}\mathbf{B}^T \mathbf{X}^T \mathbf{C}^T \mathbf{X} \\ &\quad + \mathbf{C}\mathbf{X}\mathbf{B}\mathbf{B}^T \mathbf{X}^T \mathbf{C}\mathbf{X} \\ &\quad + \mathbf{C}^T \mathbf{X}\mathbf{X}^T \mathbf{C}^T \mathbf{X}\mathbf{B}\mathbf{B}^T \end{aligned} \quad (123)$$

## 2.5.4 其他

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{A}\mathbf{X}^{-1}\mathbf{B}) = -(\mathbf{X}^{-1}\mathbf{B}\mathbf{A}\mathbf{X}^{-1})^T = -\mathbf{X}^{-T}\mathbf{A}^T\mathbf{B}^T\mathbf{X}^{-T} \quad (124)$$

假设  $\mathbf{B}$  和  $\mathbf{C}$  是对称的, 那么

$$\frac{\partial}{\partial \mathbf{X}} \text{Tr}[(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}\mathbf{A}] = -(\mathbf{C}\mathbf{X}(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1})(\mathbf{A} + \mathbf{A}^T)(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1} \quad (125)$$

$$\begin{aligned} \frac{\partial}{\partial \mathbf{X}} \text{Tr}[(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}(\mathbf{X}^T\mathbf{B}\mathbf{X})] &= -2\mathbf{C}\mathbf{X}(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}\mathbf{X}^T\mathbf{B}\mathbf{X}(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1} \\ &\quad + 2\mathbf{B}\mathbf{X}(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1} \end{aligned} \quad (126)$$

$$\begin{aligned} \frac{\partial}{\partial \mathbf{X}} \text{Tr}[(\mathbf{A} + \mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}(\mathbf{X}^T\mathbf{B}\mathbf{X})] &= -2\mathbf{C}\mathbf{X}(\mathbf{A} + \mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}\mathbf{X}^T\mathbf{B}\mathbf{X}(\mathbf{A} + \mathbf{X}^T\mathbf{C}\mathbf{X})^{-1} \\ &\quad + 2\mathbf{B}\mathbf{X}(\mathbf{A} + \mathbf{X}^T\mathbf{C}\mathbf{X})^{-1} \end{aligned} \quad (127)$$

见[7]。

$$\frac{\partial \text{Tr}(\sin(\mathbf{X}))}{\partial \mathbf{X}} = \cos(\mathbf{X})^T \quad (128)$$

## 2.6 向量范数的导数

## 2.6.1 二范数

$$\frac{\partial}{\partial \mathbf{x}} \|\mathbf{x} - \mathbf{a}\|_2 = \frac{\mathbf{x} - \mathbf{a}}{\|\mathbf{x} - \mathbf{a}\|_2} \quad (129)$$

$$\frac{\partial}{\partial \mathbf{x}} \frac{\mathbf{x} - \mathbf{a}}{\|\mathbf{x} - \mathbf{a}\|_2} = \frac{\mathbf{I}}{\|\mathbf{x} - \mathbf{a}\|_2} - \frac{(\mathbf{x} - \mathbf{a})(\mathbf{x} - \mathbf{a})^T}{\|\mathbf{x} - \mathbf{a}\|_2^3} \quad (130)$$

$$\frac{\partial \|\mathbf{x}\|_2^2}{\partial \mathbf{x}} = \frac{\partial \|\mathbf{x}^T \mathbf{x}\|_2}{\partial \mathbf{x}} = 2\mathbf{x} \quad (131)$$

## 2.7 矩阵范数的导数

有关矩阵范数的更多信息, 请参阅第10.4节。

## 2.7.1 弗罗贝尼乌斯范数

$$\frac{\partial}{\partial \mathbf{X}} \|\mathbf{X}\|_F^2 = \frac{\partial}{\partial \mathbf{X}} \text{Tr}(\mathbf{X}\mathbf{X}^H) = 2\mathbf{X} \quad (132)$$

参见 (248)。请注意, 这也是方程119中结果的特殊情况。

## 2.8 结构化矩阵的导数

假设矩阵  $\mathbf{A}$  具有某种结构, 即对称的, Toeplitz 的等等。

在这种情况下, 前一节的导数通常不适用。

相反, 考虑以下关于标量函数

$f(\mathbf{A})$

$$\frac{df}{dA_{ij}} = \sum_{kl} \frac{\partial f}{\partial A_{kl}} \frac{\partial A_{kl}}{\partial A_{ij}} = \text{Tr} \left[ \left[ \frac{\partial f}{\partial \mathbf{A}} \right]^T \frac{\partial \mathbf{A}}{\partial A_{ij}} \right] \quad (133)$$

本文档中，关于自身的矩阵的矩阵差异被称为  $\mathbf{A}$  的结构矩阵，并且简单地定义为

$$\frac{\partial \mathbf{A}}{\partial A_{ij}} = \mathbf{S}^{ij} \quad (134)$$

如果  $\mathbf{A}$  没有特殊结构，我们只需简单地将  $\mathbf{S}^{ij} = \mathbf{J}^{ij}$ ，也就是说，结构矩阵就是单个元素的矩阵。许多结构都可以用单个元素矩阵表示，更多结构矩阵的示例请参见第9.7.6节。

### 2.8.1 链式法则

有时候目标是找到另一个矩阵的函数的导数。设  $\mathbf{U} = f(\mathbf{X})$ ，目标是找到函数  $g(\mathbf{U})$  相对于  $\mathbf{X}$  的导数： $\frac{\partial g(\mathbf{U})}{\partial \mathbf{X}}$

$$\frac{\partial g(\mathbf{U})}{\partial \mathbf{X}} = \frac{\partial g(f(\mathbf{X}))}{\partial \mathbf{X}} \quad (135)$$

然后链式法则可以写成以下形式：

$$\frac{\partial g(\mathbf{U})}{\partial \mathbf{X}} = \frac{\partial g(\mathbf{U})}{\partial x_{ij}} = \sum_{k=1}^M \sum_{l=1}^N \frac{\partial g(\mathbf{U})}{\partial u_{kl}} \frac{\partial u_{kl}}{\partial x_{ij}} \quad (136)$$

使用矩阵符号，可以写成：

$$\frac{\partial g(\mathbf{U})}{\partial \mathbf{X}} = \text{Tr} \left[ \left( \frac{\partial g(\mathbf{U})}{\partial \mathbf{U}} \right)^T \frac{\partial \mathbf{U}}{\partial \mathbf{X}} \right]. \quad (137)$$

### 2.8.2 对称

如果  $\mathbf{A}$  是对称的，那么  $\mathbf{S}^{ij} = \mathbf{J}^{ij} + \mathbf{J}^{ji} - \mathbf{J}^{ij} \mathbf{J}^{ij}$ ，因此

$$\frac{df}{d\mathbf{A}} = \left[ \frac{\partial f}{\partial \mathbf{A}} \right] + \left[ \frac{\partial f}{\partial \mathbf{A}} \right]^T - \text{diag} \left[ \frac{\partial f}{\partial \mathbf{A}} \right] \quad (138)$$

也就是说，例如 ([5])：

$$\frac{\partial \text{Tr}(\mathbf{A}\mathbf{X})}{\partial \mathbf{X}} = \mathbf{A} + \mathbf{A}^T - (\mathbf{A} \circ \mathbf{I}), \text{ 参见 (14)} \quad (139)$$

$$\frac{\partial \det(\mathbf{X})}{\partial \mathbf{X}} = \det(\mathbf{X})(2\mathbf{X}^{-1} - (\mathbf{X}^{-1} \circ \mathbf{I})) \quad (140)$$

$$\frac{\partial \ln \det(\mathbf{X})}{\partial \mathbf{X}} = 2\mathbf{X}^{-1} - (\mathbf{X}^{-1} \circ \mathbf{I}) \quad (141)$$

### 2.8.3 对角

如果  $\mathbf{X}$  是对角的，那么 ([19])：

$$\frac{\partial \text{Tr}(\mathbf{A}\mathbf{X})}{\partial \mathbf{X}} = \mathbf{A} \circ \mathbf{I} \quad (142)$$

### 2.8.4 Toeplitz

就像对称矩阵和对角矩阵一样，Toeplitz矩阵也具有特殊的结构，在对具有Toeplitz结构的矩阵进行导数时需要考虑这一点。

$$\begin{aligned}
 & \frac{\partial \text{Tr}(\mathbf{A}\mathbf{T})}{\partial \mathbf{T}} \\
 &= \frac{\partial \text{Tr}(\mathbf{T}\mathbf{A})}{\partial \mathbf{T}} \\
 &= \begin{bmatrix} \text{Tr}(\mathbf{A}) & \text{Tr}([\mathbf{A}^T]_{n1}) & \text{Tr}([\mathbf{A}^T]_{1n}n-1,2) & \cdots & A_{n1} \\ \text{Tr}([\mathbf{A}^T]_{1n}) & \text{Tr}(\mathbf{A}) & \ddots & \ddots & \vdots \\ \text{Tr}([\mathbf{A}^T]_{1n}2,n-1) & \ddots & \ddots & \ddots & \text{Tr}([\mathbf{A}^T]_{1n}n-1,2) \\ \vdots & \ddots & \ddots & \ddots & \text{Tr}([\mathbf{A}^T]_{n1}) \\ A_{1n} & \cdots & \text{Tr}([\mathbf{A}^T]_{1n}2,n-1) & \text{Tr}([\mathbf{A}^T]_{1n}) & \text{Tr}(\mathbf{A}) \end{bmatrix} \\
 &\equiv \boldsymbol{\alpha}(\mathbf{A})
 \end{aligned} \tag{143}$$

正如可以看到的，导数  $\boldsymbol{\alpha}(\mathbf{A})$  也具有Toeplitz结构。对角线上的每个值是  $\mathbf{A}$  中对角线上的所有值的和，主对角线旁边的对角线上的值等于  $\mathbf{A}^T$  中主对角线旁边的对角线上的值的和。这个结果仅对无约束的Toeplitz矩阵有效。如果Toeplitz矩阵也是对称的，同样的导数得到

$$\frac{\partial \text{Tr}(\mathbf{A}\mathbf{T})}{\partial \mathbf{T}} = \frac{\partial \text{Tr}(\mathbf{T}\mathbf{A})}{\partial \mathbf{T}} = \boldsymbol{\alpha}(\mathbf{A}) + \boldsymbol{\alpha}(\mathbf{A})^T - \boldsymbol{\alpha}(\mathbf{A}) \circ \mathbf{I} \tag{144}$$



## 3 逆矩阵

### 3.1 基本

#### 3.1.1 定义

矩阵  $\mathbf{A}$  的逆矩阵  $\mathbf{A}^{-1}$  是指满足以下条件的矩阵  $\mathbf{A} \in \mathbb{C}^{n \times n}$ :

$$\mathbf{A}\mathbf{A}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}, \quad (145)$$

其中  $\mathbf{I}$  是  $n \times n$  单位矩阵。如果  $\mathbf{A}^{-1}$  存在, 则称  $\mathbf{A}$  为非奇异矩阵。否则,  $\mathbf{A}$  被称为奇异矩阵 (参见例如[12])。

#### 3.1.2 余子式和伴随矩阵

矩阵  $\mathbf{A}$  的子矩阵, 记为  $[\mathbf{A}]_{ij}$ , 是通过删除  $\mathbf{A}$  的第  $i$  行和第  $j$  列得到的一个  $(n-1) \times (n-1)$  矩阵。矩阵的  $(i, j)$  余子式定义为

$$\text{cof}(\mathbf{A}, i, j) = (-1)^{i+j} \det([\mathbf{A}]_{ij}), \quad (146)$$

余子式矩阵可以由余子式创建

$$\text{cof}(\mathbf{A}) = \begin{bmatrix} \text{cof}(\mathbf{A}, 1, 1) & \cdots & \text{cof}(\mathbf{A}, 1, n) \\ \vdots & \text{cof}(\mathbf{A}, i, j) & \vdots \\ \text{cof}(\mathbf{A}, n, 1) & \cdots & \text{cof}(\mathbf{A}, n, n) \end{bmatrix} \quad (147)$$

伴随矩阵是余子式矩阵的转置

$$\text{adj}(\mathbf{A}) = (\text{cof}(\mathbf{A}))^T, \quad (148)$$

#### 3.1.3 行列式

矩阵  $\mathbf{A} \in \mathbb{C}^{n \times n}$  的行列式定义如下 (见[12])

$$\det(\mathbf{A}) = \sum_{j=1}^n (-1)^{j+1} A_{1j} \det([\mathbf{A}]_{1j}) \quad (149)$$

$$= \sum_{j=1}^n A_{1j} \text{余子式}(\mathbf{A}, 1, j). \quad (150)$$

#### 3.1.4 构造

逆矩阵可以通过伴随矩阵构造

$$\mathbf{A}^{-1} = \frac{1}{\det(\mathbf{A})} \cdot \text{adj}(\mathbf{A}) \quad (151)$$

对于  $2 \times 2$  矩阵的情况, 请参见第1.3节。

### 3.1.5 条件数

矩阵  $c(\mathbf{A})$  的条件数是矩阵的最大奇异值与最小奇异值之比（参见第5.3节的奇异值）

$$c(\mathbf{A}) = \frac{d_+}{d_-} \quad (152)$$

条件数可以用来衡量矩阵的奇异性。如果条件数很大，表示矩阵接近奇异。条件数也可以从矩阵范数估计。在这里

$$c(\mathbf{A}) = \|\mathbf{A}\| \cdot \|\mathbf{A}^{-1}\|, \quad (153)$$

其中  $\|\cdot\|$  是一种范数，例如1-范数，2-范数， $\infty$ -范数或者 Frobenius 范数（详见第10.4节关于矩阵范数的更多内容）。

矩阵  $\mathbf{A}$  的2-范数等于  $\sqrt{\lambda_{\max}(\mathbf{A}^H \mathbf{A})}$  [12, p.57]。对于对称矩阵，这可以简化为  $\|\mathbf{A}\|_2 = \max(|\text{eig}(\mathbf{A})|)$  [12, p.394]。如果矩阵是对称且正定的， $\|\mathbf{A}\|_2 = \max(\text{eig}(\mathbf{A}))$ 。基于2-范数的条件数因此简化为

$$\|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2 = \max(\text{eig}(\mathbf{A})) \max(\text{eig}(\mathbf{A}^{-1})) = \frac{\max(\text{eig}(\mathbf{A}))}{\min(\text{eig}(\mathbf{A}))}. \quad (154)$$

## 3.2 精确关系

### 3.2.1 基础

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1} \quad (155)$$

### 3.2.2 伍德伯里恒等式

伍德伯里恒等式有很多变种。其中的一种可以在[12]中找到

$$(\mathbf{A} + \mathbf{CBC}^T)^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1} \mathbf{C} (\mathbf{B}^{-1} + \mathbf{C}^T \mathbf{A}^{-1} \mathbf{C})^{-1} \mathbf{C}^T \mathbf{A}^{-1} \quad (156)$$

$$(\mathbf{A} + \mathbf{UBV})^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1} \mathbf{U} (\mathbf{B}^{-1} + \mathbf{V} \mathbf{A}^{-1} \mathbf{U})^{-1} \mathbf{V} \mathbf{A}^{-1} \quad (157)$$

如果  $\mathbf{P}, \mathbf{R}$  是正定的，那么（见[30]）

$$(\mathbf{P}^{-1} + \mathbf{B}^T \mathbf{R}^{-1} \mathbf{B})^{-1} \mathbf{B}^T \mathbf{R}^{-1} = \mathbf{P} \mathbf{B}^T (\mathbf{B} \mathbf{P} \mathbf{B}^T + \mathbf{R})^{-1} \quad (158)$$

### 3.2.3 凯拉斯变体

$$(\mathbf{A} + \mathbf{BC})^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1} \mathbf{B} (\mathbf{I} + \mathbf{CA}^{-1} \mathbf{B})^{-1} \mathbf{CA}^{-1} \quad (159)$$

参见[4, 第153页]。

### 3.2.4 谢尔曼-莫里森

$$(\mathbf{A} + \mathbf{bc}^T)^{-1} = \mathbf{A}^{-1} - \frac{\mathbf{A}^{-1} \mathbf{bc}^T \mathbf{A}^{-1}}{1 + \mathbf{c}^T \mathbf{A}^{-1} \mathbf{b}} \quad (160)$$

## 3.2.5 西尔尔恩恒等式集合

以下一组恒等式可在[25, 第151页]中找到,

$$(\mathbf{I} + \mathbf{A}^{-1})^{-1} = \mathbf{A}(\mathbf{A} + \mathbf{I})^{-1} \quad (161)$$

$$(\mathbf{A} + \mathbf{B}\mathbf{B}^T)^{-1}\mathbf{B} = \mathbf{A}^{-1}\mathbf{B}(\mathbf{I} + \mathbf{B}^T\mathbf{A}^{-1}\mathbf{B})^{-1} \quad (162)$$

$$(\mathbf{A}^{-1} + \mathbf{B}^{-1})^{-1} = \mathbf{A}(\mathbf{A} + \mathbf{B})^{-1}\mathbf{B} = \mathbf{B}(\mathbf{A} + \mathbf{B})^{-1}\mathbf{A} \quad (163)$$

$$\mathbf{A} - \mathbf{A}(\mathbf{A} + \mathbf{B})^{-1}\mathbf{A} = \mathbf{B} - \mathbf{B}(\mathbf{A} + \mathbf{B})^{-1}\mathbf{B} \quad (164)$$

$$\mathbf{A}^{-1} + \mathbf{B}^{-1} = \mathbf{A}^{-1}(\mathbf{A} + \mathbf{B})\mathbf{B}^{-1} \quad (165)$$

$$(\mathbf{I} + \mathbf{A}\mathbf{B})^{-1} = \mathbf{I} - \mathbf{A}(\mathbf{I} + \mathbf{B}\mathbf{A})^{-1}\mathbf{B} \quad (166)$$

$$(\mathbf{I} + \mathbf{A}\mathbf{B})^{-1}\mathbf{A} = \mathbf{A}(\mathbf{I} + \mathbf{B}\mathbf{A})^{-1} \quad (167)$$

## 3.2.6 内积逆的秩-1更新

记  $\mathbf{A} = (\mathbf{X}^T\mathbf{X})^{-1}$  并且  $\mathbf{X}$  被扩展以包括一个新的列向量  
在末尾  $\tilde{\mathbf{X}} = [\mathbf{X} \ \mathbf{v}]$ . 然后 [34]

$$(\tilde{\mathbf{X}}^T\tilde{\mathbf{X}})^{-1} = \begin{bmatrix} \mathbf{A} + \frac{\mathbf{A}\mathbf{X}^T\mathbf{v}\mathbf{v}^T\mathbf{X}\mathbf{A}^T}{\mathbf{v}^T\mathbf{v} - \mathbf{v}^T\mathbf{X}\mathbf{A}\mathbf{X}^T\mathbf{v}} & \frac{-\mathbf{A}\mathbf{X}^T\mathbf{v}}{\mathbf{v}^T\mathbf{v} - \mathbf{v}^T\mathbf{X}\mathbf{A}\mathbf{X}^T\mathbf{v}} \\ \frac{-\mathbf{v}^T\mathbf{X}\mathbf{A}^T}{\mathbf{v}^T\mathbf{v} - \mathbf{v}^T\mathbf{X}\mathbf{A}\mathbf{X}^T\mathbf{v}} & \frac{1}{\mathbf{v}^T\mathbf{v} - \mathbf{v}^T\mathbf{X}\mathbf{A}\mathbf{X}^T\mathbf{v}} \end{bmatrix}$$

## 3.2.7 Moore-Penrose逆的秩-1更新

下面是实值矩阵的Moore-Penrose伪逆的秩-1更新, 证明可以在[18]中找到. 矩阵  $\mathbf{G}$  定义如下:

$$(\mathbf{A} + \mathbf{c}\mathbf{d}^T)^+ = \mathbf{A}^+ + \mathbf{G} \quad (168)$$

使用以下符号

$$\beta = 1 + \mathbf{d}^T\mathbf{A}^+\mathbf{c} \quad (169)$$

$$\mathbf{v} = \mathbf{A}^+\mathbf{c} \quad (170)$$

$$\mathbf{n} = (\mathbf{A}^+)^T\mathbf{d} \quad (171)$$

$$\mathbf{w} = (\mathbf{I} - \mathbf{A}\mathbf{A}^+)\mathbf{c} \quad (172)$$

$$\mathbf{m} = (\mathbf{I} - \mathbf{A}^+\mathbf{A})^T\mathbf{d} \quad (173)$$

解决方案分为六种不同情况, 取决于实体  $\|\mathbf{w}\|$ ,  $\|\mathbf{m}\|$ , 和  $\beta$ . 请注意, 对于任何 (列) 向量  $\mathbf{v}$ , 有  $\mathbf{v}^+ = \mathbf{v}^T(\mathbf{v}^T\mathbf{v})^{-1} = \frac{\mathbf{v}^T}{\|\mathbf{v}\|^2}$ . 解决方案是:

第1种情况: 如果  $\|\mathbf{w}\| \neq 0$  和  $\|\mathbf{m}\| \neq 0$ . 那么

$$\mathbf{G} = -\mathbf{v}\mathbf{w}^+ - (\mathbf{m}^+)^T\mathbf{n}^T + \beta(\mathbf{m}^+)^T\mathbf{w}^+ \quad (174)$$

$$= -\frac{1}{\|\mathbf{w}\|^2}\mathbf{v}\mathbf{w}^T - \frac{1}{\|\mathbf{m}\|^2}\mathbf{m}\mathbf{n}^T + \frac{\beta}{\|\mathbf{m}\|^2\|\mathbf{w}\|^2}\mathbf{m}\mathbf{w}^T \quad (175)$$

第2个案例中的第6个情况: 如果  $\|\mathbf{w}\| = 0$  且  $\|\mathbf{m}\| \neq 0$  且  $\beta = 0$ . 那么

$$\mathbf{G} = -\mathbf{v}\mathbf{v}^+\mathbf{A}^+ - (\mathbf{m}^+)^T\mathbf{n}^T \quad (176)$$

$$= -\frac{1}{\|\mathbf{v}\|^2}\mathbf{v}\mathbf{v}^T\mathbf{A}^+ - \frac{1}{\|\mathbf{m}\|^2}\mathbf{m}\mathbf{n}^T \quad (177)$$

第3个案例中的第6个情况：如果  $\|\mathbf{w}\|=0$  且  $\beta=0$ 。那么

$$\mathbf{G} = \frac{1}{\beta} \mathbf{m} \mathbf{v}^T \mathbf{A}^+ - \frac{\beta}{\|\mathbf{v}\|^2 \|\mathbf{m}\|^2 + |\beta|^2} \left( \frac{\|\mathbf{v}\|^2}{\beta} \mathbf{m} + \mathbf{v} \right) \left( \frac{\|\mathbf{m}\|^2}{\beta} (\mathbf{A}^+)^T \mathbf{v} + \mathbf{n} \right)^T \quad (178)$$

第4个案例中的第6个情况：如果  $\|\mathbf{w}\| \neq 0$  且  $\|\mathbf{m}\|=0$  且  $\beta=0$ 。那么

$$\mathbf{G} = -\mathbf{A}^+ \mathbf{n} \mathbf{n}^+ - \mathbf{v} \mathbf{w}^+ \quad (179)$$

$$= -\frac{1}{\|\mathbf{n}\|^2} \mathbf{A}^+ \mathbf{n} \mathbf{n}^T - \frac{1}{\|\mathbf{w}\|^2} \mathbf{v} \mathbf{w}^T \quad (180)$$

第5个案例：如果  $\|\mathbf{m}\|=0$  且  $\beta=0$ 。那么

$$\mathbf{G} = \frac{1}{\beta} \mathbf{A}^+ \mathbf{n} \mathbf{w}^T - \frac{\beta}{\|\mathbf{n}\|^2 \|\mathbf{w}\|^2 + |\beta|^2} \left( \frac{\|\mathbf{w}\|^2}{\beta} \mathbf{A}^+ \mathbf{n} + \mathbf{v} \right) \left( \frac{\|\mathbf{n}\|^2}{\beta} \mathbf{w} + \mathbf{n} \right)^T \quad (181)$$

第6个案例：如果  $\|\mathbf{w}\|=0$  且  $\|\mathbf{m}\|=0$  且  $\beta=0$ 。那么

$$\mathbf{G} = -\mathbf{v} \mathbf{v}^+ \mathbf{A}^+ - \mathbf{A}^+ \mathbf{n} \mathbf{n}^+ + \mathbf{v}^+ \mathbf{A}^+ \mathbf{n} \mathbf{v} \mathbf{n}^+ \quad (182)$$

$$= -\frac{1}{\|\mathbf{v}\|^2} \mathbf{v} \mathbf{v}^T \mathbf{A}^+ - \frac{1}{\|\mathbf{n}\|^2} \mathbf{A}^+ \mathbf{n} \mathbf{n}^T + \frac{\mathbf{v}^T \mathbf{A}^+ \mathbf{n}}{\|\mathbf{v}\|^2 \|\mathbf{n}\|^2} \mathbf{v} \mathbf{n}^T \quad (183)$$

### 3.3 对逆矩阵的影响

$$\text{If } (\mathbf{A} + \mathbf{B})^{-1} = \mathbf{A}^{-1} + \mathbf{B}^{-1} \quad \text{然后} \quad \mathbf{A} \mathbf{B}^{-1} \mathbf{A} = \mathbf{B} \mathbf{A}^{-1} \mathbf{B} \quad (184)$$

参见[25]。

#### 3.3.1 正定恒等式

假设  $\mathbf{P}$ ,  $\mathbf{R}$  为正定且可逆的, 那么

$$(\mathbf{P}^{-1} + \mathbf{B}^T \mathbf{R}^{-1} \mathbf{B})^{-1} \mathbf{B}^T \mathbf{R}^{-1} = \mathbf{P} \mathbf{B}^T (\mathbf{B} \mathbf{P} \mathbf{B}^T + \mathbf{R})^{-1} \quad (185)$$

参见[30]。

### 3.4 近似

下面的恒等式被称为矩阵的 *Neuman* 级数, 当  $|\lambda_i| < 1$  对于所有特征值  $\lambda_i$  时成立

$$(\mathbf{I} - \mathbf{A})^{-1} = \sum_{n=0}^{\infty} \mathbf{A}^n \quad (186)$$

等价于

$$(\mathbf{I} + \mathbf{A})^{-1} = \sum_{n=0}^{\infty} (-1)^n \mathbf{A}^n \quad (187)$$

当所有特征值  $\lambda_i$  的绝对值都小于1时, 对于  $n \rightarrow \infty$ , 有  $\mathbf{A}^n \rightarrow 0$ , 并且以下近似成立

$$(\mathbf{I} - \mathbf{A})^{-1} \cong \mathbf{I} + \mathbf{A} + \mathbf{A}^2 \quad (188)$$

$$(\mathbf{I} + \mathbf{A})^{-1} \cong \mathbf{I} - \mathbf{A} + \mathbf{A}^2 \quad (189)$$

以下近似来自于[22]，在  $A$  大且对称时成立

$$A - A(I + A)^{-1}A \cong I - A^{-1} \quad (190)$$

如果  $\sigma^2$  相对于  $Q$  和  $M$  很小

$$(Q + \sigma^2 M)^{-1} \cong Q^{-1} - \sigma^2 Q^{-1} M Q^{-1} \quad (191)$$

证明:

$$(Q + \sigma^2 M)^{-1} = \quad (192)$$

$$(Q Q^{-1} Q + \sigma^2 M Q^{-1} Q)^{-1} = \quad (193)$$

$$((I + \sigma^2 M Q^{-1}) Q)^{-1} = \quad (194)$$

$$Q^{-1} (I + \sigma^2 M Q^{-1})^{-1} \quad (195)$$

这可以用泰勒展开式重写:

$$Q^{-1} (I + \sigma^2 M Q^{-1})^{-1} = \quad (196)$$

$$Q^{-1} (I - \sigma^2 M Q^{-1} + (\sigma^2 M Q^{-1})^2 - \dots) \cong Q^{-1} - \sigma^2 Q^{-1} M Q^{-1} \quad (197)$$

### 3.5 广义逆矩阵

#### 3.5.1 定义

矩阵  $A$  的广义逆矩阵是任何满足 (见 [26]) 的矩阵  $A^-$

$$A A^- A = A \quad (198) \text{ 矩阵}$$

$A^-$  不唯一。

### 3.6 伪逆矩阵

#### 3.6.1 定义

矩阵  $A$  的伪逆矩阵 (或摩尔-彭罗斯逆矩阵) 是满足的矩阵  $A^+$

$$\text{I} \quad A A^+ A = A$$

$$\text{II} \quad A^+ A A^+ = A^+$$

$$\text{III} \quad A A^+ \text{ 对称}$$

$$\text{IV} \quad A^+ A \text{ 对称}$$

矩阵  $A^+$  是唯一的且总是存在的。请注意，在复数矩阵的情况下，对称条件被一个具有埃尔米特性质的条件所替代。

## 3.6.2 属性

假设  $\mathbf{A}^+$  是  $\mathbf{A}$  的伪逆矩阵, 则 (见 [3] 中的一些性质)

$$(\mathbf{A}^+)^+ = \mathbf{A} \quad (199)$$

$$(\mathbf{A}^T)^+ = (\mathbf{A}^+)^T \quad (200)$$

$$(\mathbf{A}^H)^+ = (\mathbf{A}^+)^H \quad (201)$$

$$(\mathbf{A}^*)^+ = (\mathbf{A}^+)^* \quad (202)$$

$$(\mathbf{A}^+ \mathbf{A}) \mathbf{A}^H = \mathbf{A}^H \quad (203)$$

$$(\mathbf{A}^+ \mathbf{A}) \mathbf{A}^T = \mathbf{A}^T \quad (204)$$

$$(c\mathbf{A})^+ = (1/c)\mathbf{A}^+ \quad (205)$$

$$\mathbf{A}^+ = (\mathbf{A}^T \mathbf{A})^+ \mathbf{A}^T \quad (206)$$

$$\mathbf{A}^+ = \mathbf{A}^T (\mathbf{A} \mathbf{A}^T)^+ \quad (207)$$

$$(\mathbf{A}^T \mathbf{A})^+ = \mathbf{A}^+ (\mathbf{A}^T)^+ \quad (208)$$

$$(\mathbf{A} \mathbf{A}^T)^+ = (\mathbf{A}^T)^+ \mathbf{A}^+ \quad (209)$$

$$\mathbf{A}^+ = (\mathbf{A}^H \mathbf{A})^+ \mathbf{A}^H \quad (210)$$

$$\mathbf{A}^+ = \mathbf{A}^H (\mathbf{A} \mathbf{A}^H)^+ \quad (211)$$

$$(\mathbf{A}^H \mathbf{A})^+ = \mathbf{A}^+ (\mathbf{A}^H)^+ \quad (212)$$

$$(\mathbf{A} \mathbf{A}^H)^+ = (\mathbf{A}^H)^+ \mathbf{A}^+ \quad (213)$$

$$(\mathbf{A} \mathbf{B})^+ = (\mathbf{A}^+ \mathbf{A} \mathbf{B})^+ (\mathbf{A} \mathbf{B} \mathbf{B}^+)^+ \quad (214)$$

$$f(\mathbf{A}^H \mathbf{A}) - f(0)\mathbf{I} = \mathbf{A}^+ [f(\mathbf{A} \mathbf{A}^H) - f(0)\mathbf{I}] \mathbf{A} \quad (215)$$

$$f(\mathbf{A} \mathbf{A}^H) - f(0)\mathbf{I} = \mathbf{A} [f(\mathbf{A}^H \mathbf{A}) - f(0)\mathbf{I}] \mathbf{A}^+ \quad (216)$$

其中  $\mathbf{A} \in \mathbb{C}^{n \times m}$ .

假设  $\mathbf{A}$  具有满秩, 则

$$(\mathbf{A} \mathbf{A}^+)(\mathbf{A} \mathbf{A}^+) = \mathbf{A} \mathbf{A}^+ \quad (217)$$

$$(\mathbf{A}^+ \mathbf{A})(\mathbf{A}^+ \mathbf{A}) = \mathbf{A}^+ \mathbf{A} \quad (218)$$

$$\text{Tr}(\mathbf{A} \mathbf{A}^+) = \text{rank}(\mathbf{A} \mathbf{A}^+) \quad (\text{见 [26]}) \quad (219)$$

$$\text{Tr}(\mathbf{A}^+ \mathbf{A}) = \text{rank}(\mathbf{A}^+ \mathbf{A}) \quad (\text{见 [26]}) \quad (220)$$

对于两个矩阵, 有

$$(\mathbf{A} \mathbf{B})^+ = (\mathbf{A}^+ \mathbf{A} \mathbf{B})^+ (\mathbf{A} \mathbf{B} \mathbf{B}^+)^+ \quad (221)$$

$$(\mathbf{A} \otimes \mathbf{B})^+ = \mathbf{A}^+ \otimes \mathbf{B}^+ \quad (222)$$

## 3.6.3 构造

假设  $\mathbf{A}$  具有满秩, 则

$$\begin{array}{lll} \mathbf{A} \ n \times n & \text{方阵} & \text{rank}(\mathbf{A}) = n \Rightarrow \mathbf{A}^+ = \mathbf{A}^{-1} \\ \mathbf{A} \ n \times m & \text{宽} & \text{rank}(\mathbf{A}) = n \Rightarrow \mathbf{A}^+ = \mathbf{A}^T (\mathbf{A} \mathbf{A}^T)^{-1} \\ \mathbf{A} \ n \times m & \text{高} & \text{rank}(\mathbf{A}) = m \Rightarrow \mathbf{A}^+ = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \end{array}$$

谓的“宽版本”也被称为右逆, 而“高版本”被称为左逆。

假设  $\mathbf{A}$  没有满秩, 即  $\mathbf{A}$  是  $n \times m$  的矩阵, 且  $\text{rank}(\mathbf{A}) = r < \min(n, m)$ 。伪逆矩阵  $\mathbf{A}^+$  可以通过奇异值分解  $\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^T$  构造, 即

$$\mathbf{A}^+ = \mathbf{V}_r \mathbf{D}_r^{-1} \mathbf{U}_r^T \quad (223)$$

其中  $\mathbf{U}_r$ 、 $\mathbf{D}_r$  和  $\mathbf{V}_r$  是删除了退化行和列的矩阵。另一种方式是: 总是存在两个满秩矩阵  $\mathbf{C} \ n \times r$  和  $\mathbf{D} \ r \times m$ , 使得  $\mathbf{A} = \mathbf{C}\mathbf{D}$ 。利用这些矩阵, 有以下关系成立

$$\mathbf{A}^+ = \mathbf{D}^T (\mathbf{D}\mathbf{D}^T)^{-1} (\mathbf{C}^T \mathbf{C})^{-1} \mathbf{C}^T \quad (224)$$

参见[3]。

## 4复数矩阵

复数标量积  $r = pq$  可以写成

$$\begin{bmatrix} \Re r \\ \Im r \end{bmatrix} = \begin{bmatrix} \Re p & -\Im p \\ \Im p & \Re p \end{bmatrix} \begin{bmatrix} \Re q \\ \Im q \end{bmatrix} \quad (225)$$

### 4.1 复数导数

为了对复数  $z$  进行表达式  $f(z)$  的微分, 需要满足柯西-黎曼方程组 ([7]) :  $df(z)$

$$\frac{df(z)}{dz} = \frac{\partial \Re(f(z))}{\partial \Re z} + i \frac{\partial \Im(f(z))}{\partial \Re z} \quad (226)$$

和

$$\frac{df(z)}{dz} = -i \frac{\partial \Re(f(z))}{\partial \Im z} + \frac{\partial \Im(f(z))}{\partial \Im z} \quad (227)$$

或者更简洁地表示为:

$$\frac{\partial f(z)}{\partial \Im z} = i \frac{\partial f(z)}{\partial \Re z}. \quad (228)$$

满足区域  $R$  中点的柯西-黎曼方程的复函数被称为在该区域  $R$  中是解析的。一般来说, 涉及复共轭或共轭转置的表达式不满足柯西-黎曼方程。为了避免这个问题, 使用了更广义的复导数定义 ([24], [6]) :

- 广义复导数:

$$\frac{df(z)}{dz} = \frac{1}{2} \left( \frac{\partial f(z)}{\partial \Re z} - i \frac{\partial f(z)}{\partial \Im z} \right). \quad (229)$$

- 共轭复导数:

$$\frac{df(z)}{dz^*} = \frac{1}{2} \left( \frac{\partial f(z)}{\partial \Re z} + i \frac{\partial f(z)}{\partial \Im z} \right). \quad (230)$$

当  $f$  是解析函数时, 广义复导数等于普通导数。对于非解析函数, 如  $f(z) = z^*$ , 导数等于零。当  $f$  是解析函数时, 共轭复导数等于零。在推导复梯度时, 例如[21]使用了共轭复导数。

注意:

$$\frac{df(z)}{dz} = \frac{\partial f(z)}{\partial \Re z} + i \frac{\partial f(z)}{\partial \Im z}. \quad (231)$$

- 复梯度向量: 如果  $f$  是一个关于复向量  $\mathbf{z}$  的实函数, 那么复梯度向量由以下公式给出 ([14, p. 798])

$$\begin{aligned} \nabla f(\mathbf{z}) &= 2 \frac{df(\mathbf{z})}{d\mathbf{z}^*} \\ &= \frac{\partial f(\mathbf{z})}{\partial \Re \mathbf{z}} + i \frac{\partial f(\mathbf{z})}{\partial \Im \mathbf{z}}. \end{aligned} \quad (232)$$



- 复梯度矩阵：如果  $f$  是一个关于复矩阵  $\mathbf{Z}$  的实函数，那么复梯度矩阵由以下公式给出 ([2])

$$\begin{aligned}\nabla f(\mathbf{Z}) &= 2 \frac{df(\mathbf{Z})}{d\mathbf{Z}^*} \\ &= \frac{\partial f(\mathbf{Z})}{\partial \Re \mathbf{Z}} + i \frac{\partial f(\mathbf{Z})}{\partial \Im \mathbf{Z}}.\end{aligned}\quad (233)$$

这些表达式可用于梯度下降算法。

#### 4.1.1 复数的链式法则

当复数函数  $u = f(x)$  是非解析的时候，链式法则会更加复杂。对于非解析函数，可以应用以下链式法则 ([7])  $\partial g(u)$

$$\begin{aligned}\frac{\partial g}{\partial x} &= \frac{\partial g}{\partial u} \frac{\partial u}{\partial x} + \frac{\partial g}{\partial u^*} \frac{\partial u^*}{\partial x} \\ &= \frac{\partial g}{\partial u} \frac{\partial u}{\partial x} + \left( \frac{\partial g}{\partial u} \right)^* \frac{\partial u^*}{\partial x}\end{aligned}\quad (234)$$

注意，如果函数是解析的，第二项将减少为零，函数将简化为常规的众所周知的链式法则。对于标量函数  $g(\mathbf{U})$  的矩阵导数，链式法则可以写成以下形式：

$$\frac{\partial g(\mathbf{U})}{\partial \mathbf{X}} = \frac{\text{Tr}((\frac{\partial g(\mathbf{U})}{\partial \mathbf{U}})^T \partial \mathbf{U})}{\partial \mathbf{X}} + \frac{\text{Tr}((\frac{\partial g(\mathbf{U})}{\partial \mathbf{U}^*})^T \partial \mathbf{U}^*)}{\partial \mathbf{X}}. \quad (235)$$

#### 4.1.2 复数的迹导数

如果导数涉及复数，通常会涉及共轭转置。显示复数导数最有用的方法是分别显示对实部和虚部的导数。一个简单的例子是：

$$\frac{\partial \text{Tr}(\mathbf{X}^*)}{\partial \Re \mathbf{X}} = \frac{\partial \text{Tr}(\mathbf{X}^H)}{\partial \Re \mathbf{X}} = \mathbf{I} \quad (236)$$

$$i \frac{\partial \text{Tr}(\mathbf{X}^*)}{\partial \Im \mathbf{X}} = i \frac{\partial \text{Tr}(\mathbf{X}^H)}{\partial \Im \mathbf{X}} = \mathbf{I} \quad (237)$$

由于这两个结果具有相同的符号，应使用共轭复数导数 (230)。

$$\frac{\partial \text{Tr}(\mathbf{X})}{\partial \Re \mathbf{X}} = \frac{\partial \text{Tr}(\mathbf{X}^T)}{\partial \Re \mathbf{X}} = \mathbf{I} \quad (238)$$

$$i \frac{\partial \text{Tr}(\mathbf{X})}{\partial \Im \mathbf{X}} = i \frac{\partial \text{Tr}(\mathbf{X}^T)}{\partial \Im \mathbf{X}} = -\mathbf{I} \quad (239)$$

在这里，这两个结果具有不同的符号，应使用广义复数导数 (229)。因此，即使  $\mathbf{X}$  是一个复数，也可以看出 (100) 成立。

$$\frac{\partial \text{Tr}(\mathbf{A}\mathbf{X}^H)}{\partial \Re \mathbf{X}} = \mathbf{A} \quad (240)$$

$$i \frac{\partial \text{Tr}(\mathbf{A}\mathbf{X}^H)}{\partial \Im \mathbf{X}} = \mathbf{A} \quad (241)$$

$$\frac{\partial \text{Tr}(\mathbf{A}\mathbf{X}^*)}{\partial \Re \mathbf{X}} = \mathbf{A}^T \quad (242)$$

$$i \frac{\partial \text{Tr}(\mathbf{A}\mathbf{X}^*)}{\partial \Im \mathbf{X}} = \mathbf{A}^T \quad (243)$$

$$\frac{\partial \text{Tr}(\mathbf{X}\mathbf{X}^H)}{\partial \Re \mathbf{X}} = \frac{\partial \text{Tr}(\mathbf{X}^H \mathbf{X})}{\partial \Re \mathbf{X}} = 2\Re \mathbf{X} \quad (244)$$

$$i \frac{\partial \text{Tr}(\mathbf{X}\mathbf{X}^H)}{\partial \Im \mathbf{X}} = i \frac{\partial \text{Tr}(\mathbf{X}^H \mathbf{X})}{\partial \Im \mathbf{X}} = i2\Im \mathbf{X} \quad (245)$$

通过将(244)和(245)插入(229)和(230)中, 可以看到

$$\frac{\partial \text{Tr}(\mathbf{X}\mathbf{X}^H)}{\partial \mathbf{X}} = \mathbf{X}^* \quad (246)$$

$$\frac{\partial \text{Tr}(\mathbf{X}\mathbf{X}^H)}{\partial \mathbf{X}^*} = \mathbf{X} \quad (247)$$

由于函数 $\text{Tr}(\mathbf{X}\mathbf{X}^H)$ 是复矩阵  $\mathbf{X}$  的实函数, 复梯度矩阵(233)由以下给出

$$\nabla \text{Tr}(\mathbf{X}\mathbf{X}^H) = 2 \frac{\partial \text{Tr}(\mathbf{X}\mathbf{X}^H)}{\partial \mathbf{X}^*} = 2\mathbf{X} \quad (248)$$

#### 4.1.3 涉及行列式的复导数

这里提供一个计算示例。目标是找到关于 $\mathbf{X} \in \mathbb{C}^{m \times n}$  的 $\det(\mathbf{X}^H \mathbf{A} \mathbf{X})$  的导数。通过对  $\mathbf{X}$  的实部和虚部进行求导, 利用(42)和(37), 可以计算出 $\det(\mathbf{X}^H \mathbf{A} \mathbf{X})$  (详见附录B.1.4)

$$\begin{aligned} \frac{\partial \det(\mathbf{X}^H \mathbf{A} \mathbf{X})}{\partial \mathbf{X}} &= \frac{1}{2} \left( \frac{\partial \det(\mathbf{X}^H \mathbf{A} \mathbf{X})}{\partial \Re \mathbf{X}} - i \frac{\partial \det(\mathbf{X}^H \mathbf{A} \mathbf{X})}{\partial \Im \mathbf{X}} \right) \\ &= \det(\mathbf{X}^H \mathbf{A} \mathbf{X}) \left( (\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} \mathbf{X}^H \mathbf{A} \right)^T \end{aligned} \quad (249)$$

和复共轭导数产生

$$\begin{aligned} \frac{\partial \det(\mathbf{X}^H \mathbf{A} \mathbf{X})}{\partial \mathbf{X}^*} &= \frac{1}{2} \left( \frac{\partial \det(\mathbf{X}^H \mathbf{A} \mathbf{X})}{\partial \Re \mathbf{X}} + i \frac{\partial \det(\mathbf{X}^H \mathbf{A} \mathbf{X})}{\partial \Im \mathbf{X}} \right) \\ &= \det(\mathbf{X}^H \mathbf{A} \mathbf{X}) \mathbf{A} \mathbf{X} (\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} \end{aligned} \quad (250)$$

#### 4.2 高阶和非线性导数

$$\frac{\partial (\mathbf{A}\mathbf{x})^H (\mathbf{A}\mathbf{x})}{\partial \mathbf{x} (\mathbf{B}\mathbf{x})^H (\mathbf{B}\mathbf{x})} = \frac{\partial \mathbf{x}^H \mathbf{A}^H \mathbf{A} \mathbf{x}}{\partial \mathbf{x} \mathbf{x}^H \mathbf{B}^H \mathbf{B} \mathbf{x}} \quad (251)$$

$$= 2 \frac{\mathbf{A}^H \mathbf{A} \mathbf{x}}{\mathbf{x}^H \mathbf{B} \mathbf{B} \mathbf{x}} - 2 \frac{\mathbf{x}^H \mathbf{A}^H \mathbf{A} \mathbf{x} \mathbf{B}^H \mathbf{B} \mathbf{x}}{(\mathbf{x}^H \mathbf{B}^H \mathbf{B} \mathbf{x})^2} \quad (252)$$

### 4.3 复数和的逆

给定实矩阵  $\mathbf{A}, \mathbf{B}$  找到复数和  $\mathbf{A} + i\mathbf{B}$  的逆。形成辅助矩阵

$$\mathbf{E} = \mathbf{A} + t\mathbf{B} \quad (253)$$

$$\mathbf{F} = \mathbf{B} - t\mathbf{A}, \quad (254)$$

并找到一个值为  $t$  的  $\mathbf{E}^{-1}$  存在。然后

$$(\mathbf{A} + i\mathbf{B})^{-1} = (1 - it)(\mathbf{E} + i\mathbf{F})^{-1} \quad (255)$$

$$= (1 - it)((\mathbf{E} + \mathbf{F}\mathbf{E}^{-1}\mathbf{F})^{-1} - i(\mathbf{E} + \mathbf{F}\mathbf{E}^{-1}\mathbf{F})^{-1}\mathbf{F}\mathbf{E}^{-1}) \quad (256)$$

$$= (1 - it)(\mathbf{E} + \mathbf{F}\mathbf{E}^{-1}\mathbf{F})^{-1}(\mathbf{I} - i\mathbf{F}\mathbf{E}^{-1}) \quad (257)$$

$$= (\mathbf{E} + \mathbf{F}\mathbf{E}^{-1}\mathbf{F})^{-1}((\mathbf{I} - t\mathbf{F}\mathbf{E}^{-1}) - i(t\mathbf{I} + \mathbf{F}\mathbf{E}^{-1})) \quad (258)$$

$$= (\mathbf{E} + \mathbf{F}\mathbf{E}^{-1}\mathbf{F})^{-1}(\mathbf{I} - t\mathbf{F}\mathbf{E}^{-1}) - i(\mathbf{E} + \mathbf{F}\mathbf{E}^{-1}\mathbf{F})^{-1}(t\mathbf{I} + \mathbf{F}\mathbf{E}^{-1}) \quad (259)$$

## 5 解和分解

### 5.1 线性方程的解

#### 5.1.1 简单线性回归

假设我们有数据  $(x_n, y_n)$  for  $n = 1, \dots, N$  and are seeking the parameters  $a, b \in \mathbb{R}$  such that  $y_i \cong ax_i + b$ . 使用最小二乘误差函数，可以用以下符号表示最优的  $a, b$  值

$$\mathbf{x} = (x_1, \dots, x_N)^T \quad \mathbf{y} = (y_1, \dots, y_N)^T \quad \mathbf{1} = (1, \dots, 1)^T \in \mathbb{R}^{N \times 1}$$

和

$$\begin{aligned} R_{xx} &= \mathbf{x}^T \mathbf{x} & R_{x1} &= \mathbf{x}^T \mathbf{1} & R_{11} &= \mathbf{1}^T \mathbf{1} \\ R_{yx} &= \mathbf{y}^T \mathbf{x} & R_{y1} &= \mathbf{y}^T \mathbf{1} \end{aligned}$$

如

$$\begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} R_{xx} & R_{x1} \\ R_{x1} & R_{11} \end{bmatrix}^{-1} \begin{bmatrix} R_{x,y} \\ R_{y1} \end{bmatrix} \quad (260)$$

#### 5.1.2 线性系统中的存在性

假设  $\mathbf{A}$  是  $n \times m$  的，并考虑线性系统

$$\mathbf{Ax} = \mathbf{b} \quad (261)$$

构造增广矩阵  $\mathbf{B} = [\mathbf{A} \ \mathbf{b}]$  然后

条件	解	
$\text{rank}(\mathbf{A}) = \text{rank}(\mathbf{B}) = m$	唯一解	$\mathbf{x}$
$\text{rank}(\mathbf{A}) = \text{rank}(\mathbf{B}) < m$	多个解	$\mathbf{x}$
$\text{rank}(\mathbf{A}) < \text{rank}(\mathbf{B})$	无解	$\mathbf{x}$

#### 5.1.3 标准方阵

假设  $\mathbf{A}$  是方阵且可逆，则

$$\mathbf{Ax} = \mathbf{b} \quad \Rightarrow \quad \mathbf{x} = \mathbf{A}^{-1} \mathbf{b} \quad (262)$$

#### 5.1.4 退化的方阵

假设  $\mathbf{A}$  是一个  $n \times n$  的矩阵，但是它的秩为  $r < n$ 。在这种情况下，方程组  $\mathbf{Ax} = \mathbf{b}$  的解为

$$\mathbf{x} = \mathbf{A}^+ \mathbf{b}$$

其中  $\mathbf{A}^+$  是秩缺失矩阵的伪逆，根据第3.6.3节的描述构造。

## 5.1.5 克莱姆法则

方程

$$\mathbf{Ax} = \mathbf{b}, \quad (263)$$

其中  $\mathbf{A}$  是方阵, 如果  $\mathbf{x}$  的第  $i$  个元素可以表示为

$$x_i = \frac{\det \mathbf{B}_i}{\det \mathbf{A}}, \quad (264)$$

其中  $\mathbf{B}$  等于  $\mathbf{A}$ , 但是  $\mathbf{A}$  的第  $i$  列被  $\mathbf{b}$  替换。

## 5.1.6 过定的矩形方程组

假设  $\mathbf{A}$  是一个  $n \times m$  的矩阵,  $n > m$  (高矩阵), 且  $\text{rank}(\mathbf{A}) = m$ , 那

$$\text{么方程组 } \mathbf{Ax} = \mathbf{b} \text{ 的} \quad \Rightarrow \quad \mathbf{x} = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{b} = \mathbf{A}^+ \mathbf{b} \quad (265)$$

也就是说如果存在解  $\mathbf{x}$  的话! 如果没有解, 下面的内容可能会有用:  $\mathbf{Ax} = \mathbf{b}$

$$\Rightarrow \quad \mathbf{x}_{min} = \mathbf{A}^+ \mathbf{b} \quad (266)$$

现在,  $\mathbf{x}_{min}$  是向量  $\mathbf{x}$ , 它最小化了  $\|\mathbf{Ax} - \mathbf{b}\|^2$ , 也就是说, 它是最“接近正确”的向量。矩阵  $\mathbf{A}^+$  是  $\mathbf{A}$  的伪逆矩阵。参见[3]。

## 5.1.7 欠定矩形

假设  $\mathbf{A}$  是一个  $n \times m$  的矩阵, 且  $n < m$  (“宽”), 且  $\text{rank}(\mathbf{A}) = n$ 。

$$\mathbf{Ax} = \mathbf{b} \quad \Rightarrow \quad \mathbf{x}_{min} = \mathbf{A}^T (\mathbf{AA}^T)^{-1} \mathbf{b} \quad (267)$$

该方程有很多解  $\mathbf{x}$ 。但是,  $\mathbf{x}_{min}$  是最小化了  $\|\mathbf{Ax} - \mathbf{b}\|^2$  的解, 也是具有最小范数  $\|\mathbf{x}\|^2$  的解。对于矩阵版本也是一样的: 假设  $\mathbf{A}$  是一个  $n \times m$  的矩阵,  $\mathbf{X}$  是一个  $m \times n$  的矩阵,  $\mathbf{B}$  是一个  $n \times n$  的矩阵, 那么  $\mathbf{AX} = \mathbf{B}$

$$\Rightarrow \quad \mathbf{X}_{min} = \mathbf{A}^+ \mathbf{B} \quad (268)$$

方程有很多解  $\mathbf{X}$ 。但是  $\mathbf{X}_{min}$  是最小化  $\|\mathbf{AX} - \mathbf{B}\|^2$  的解, 也是具有最小范数  $\|\mathbf{X}\|^2$  的解。参见[3]。

类似但不同: 假设  $\mathbf{A}$  是方阵  $n \times n$ , 矩阵  $\mathbf{B}_0$ ,  $\mathbf{B}_1$  是  $n \times N$  的矩阵, 其中  $N > n$ , 那么如果  $\mathbf{B}_0$  具有最大秩

$$\mathbf{AB}_0 = \mathbf{B}_1 \quad \Rightarrow \quad \mathbf{A}_{min} = \mathbf{B}_1 \mathbf{B}_0^T (\mathbf{B}_0 \mathbf{B}_0^T)^{-1} \quad (269)$$

其中  $\mathbf{A}_{min}$  表示在最小二乘意义下最优的矩阵。一种解释是  $\mathbf{A}$  是将  $\mathbf{B}_0$  的列向量映射到  $\mathbf{B}_1$  的列向量的线性近似。

## 5.1.8 线性形式和零解

$$\mathbf{Ax} = \mathbf{0}, \text{ 对于所有的 } \mathbf{x} \quad \Rightarrow \quad \mathbf{A} = \mathbf{0} \quad (270)$$

## 5.1.9 方阵形式和零

如果  $\mathbf{A}$  是对称的, 则

$$\mathbf{x}^T \mathbf{Ax} = 0, \quad \forall \mathbf{x} \quad \Rightarrow \quad \mathbf{A} = \mathbf{0} \quad (271)$$

## 5.2 特征值和特征向量5 解和分解

---

### 5.1.10 李亚普诺夫方程

$$\mathbf{A}\mathbf{X} + \mathbf{X}\mathbf{B} = \mathbf{C} \quad (272)$$

$$\text{vec}(\mathbf{X}) = (\mathbf{I} \otimes \mathbf{A} + \mathbf{B}^T \otimes \mathbf{I})^{-1} \text{vec}(\mathbf{C}) \quad (273)$$

有关克罗内克积和 $\text{vec}$ 运算符的详细信息，请参见第10.2.1节和10.2.2节。

### 5.1.11 封装求和

$$\sum_n \mathbf{A}_n \mathbf{X} \mathbf{B}_n = \mathbf{C} \quad (274)$$

$$\text{vec}(\mathbf{X}) = \left( \sum_n \mathbf{B}_n^T \otimes \mathbf{A}_n \right)^{-1} \text{vec}(\mathbf{C}) \quad (275)$$

有关克罗内克积和 $\text{vec}$ 运算符的详细信息，请参见第10.2.1节和10.2.2节。

## 5.2 特征值和特征向量

### 5.2.1 定义

特征向量  $\mathbf{v}_i$  和特征值  $\lambda_i$  满足以下条件

$$\mathbf{A}\mathbf{v}_i = \lambda_i \mathbf{v}_i \quad (276)$$

### 5.2.2 分解

对于具有与维度相同数量的不同特征值的矩阵  $\mathbf{A}$ ，以下等式成立，其中  $\mathbf{V}$  的列是特征向量， $(\mathbf{D})_{ij} = \delta_{ij} \lambda_i$ ， $\mathbf{A}\mathbf{V} = \mathbf{V}\mathbf{D}$

(277)对

于有缺陷的矩阵  $\mathbf{A}$ ，即具有较少不同特征值的矩阵，以下分解称为 *Jordan* 规范形式，成立

$$\mathbf{A}\mathbf{V} = \mathbf{V}\mathbf{J} \quad (278)$$

其中  $\mathbf{J}$  是一个块对角矩阵，块  $\mathbf{J}_i = \lambda_i \mathbf{I} + \mathbf{N}$ 。矩阵  $\mathbf{J}_i$  的维度与相同特征值  $\lambda_i$  的数量相等， $\mathbf{N}$  是一个大小相同的方阵，其超对角线上为1，其他位置为0。

对于所有矩阵  $\mathbf{A}$ ，存在矩阵  $\mathbf{V}$  和  $\mathbf{R}$  使得

$$\mathbf{A}\mathbf{V} = \mathbf{V}\mathbf{R} \text{ 也成立} \quad (279)$$

其中  $\mathbf{R}$  是上三角矩阵，其对角线上是特征值  $\lambda_i$

### 5.2.3 一般性质假设 $\mathbf{A} \in \mathbb{R}^{n \times m}$ 和 $\mathbf{B} \in \mathbb{R}^{m \times n}$

，则  $\text{eig}(\mathbf{A}\mathbf{B}) = \text{eig}(\mathbf{B}\mathbf{A})$

(280)

$$\text{rank}(\mathbf{A}) = r \Rightarrow \text{最多有 } r \text{ 个非零特征值 } \lambda_i \quad (281)$$

## 5.2.4 对称性

假设  $\mathbf{A}$  是对称矩阵, 则

$$\mathbf{V}\mathbf{V}^T = \mathbf{I} \quad (\text{即 } \mathbf{V} \text{ 是正交矩阵}) \quad (282)$$

$$\lambda_i \in \mathbb{R} \quad (\text{即特征值 } \lambda_i \text{ 是实数}) \quad (283)$$

$$\text{Tr}(\mathbf{A}^p) = \sum_i \lambda_i^p \quad (284)$$

$$\text{eig}(\mathbf{I} + c\mathbf{A}) = 1 + c\lambda_i \quad (285)$$

$$\text{eig}(\mathbf{A} - c\mathbf{I}) = \lambda_i - c \quad (286)$$

$$\text{eig}(\mathbf{A}^{-1}) = \lambda_i^{-1} \quad (287)$$

对于一个对称的正矩阵  $\mathbf{A}$ ,

$$\text{eig}(\mathbf{A}^T \mathbf{A}) = \text{eig}(\mathbf{A}\mathbf{A}^T) = \text{eig}(\mathbf{A}) \circ \text{eig}(\mathbf{A}) \quad (288)$$

## 5.2.5 特征多项式

矩阵  $\mathbf{A}$  的特征多项式为

$$0 = \det(\mathbf{A} - \lambda\mathbf{I}) \quad (289)$$

$$= \lambda^n - g_1\lambda^{n-1} + g_2\lambda^{n-2} - \dots + (-1)^n g_n \quad (290) \text{注意,}$$

系数  $g_j$  对于  $j=1, \dots, n$  在旋转下是不变的矩阵  $\mathbf{A}$ . 因此,  $g_j$  是  $\mathbf{A}$  的所有子矩阵的行和列的行列式之和取  $j$  行和列的情况下。也就是说,  $g_1$  是  $\mathbf{A}$  的迹,  $g_2$  是从  $\mathbf{A}$  中删除所有但两行和两列后可以形成的所有  $(n(n-1)/2)$  个子矩阵的行列式之和, 以此类推 – 参见[17]。

## 5.3 奇异值分解

任意  $n \times m$  矩阵  $\mathbf{A}$  可以表示为

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}^T, \quad (291)$$

其中

$$\mathbf{U} = \text{矩阵 } \mathbf{A}\mathbf{A}^T \text{ 的特征向量, 维度为 } n \times n$$

$$\mathbf{D} = \sqrt{\text{diag}(\text{eig}(\mathbf{A}\mathbf{A}^T))} \quad n \times m \quad (292)$$

$$\mathbf{V} = \text{矩阵 } \mathbf{A}^T \mathbf{A} \text{ 的特征向量, 维度为 } m \times m$$

## 5.3.1 对称方阵分解为平方

假设  $\mathbf{A}$  为  $n \times n$  的对称方阵。则

$$\begin{bmatrix} \mathbf{A} \end{bmatrix} = \begin{bmatrix} \mathbf{V} \end{bmatrix} \begin{bmatrix} \mathbf{D} \end{bmatrix} \begin{bmatrix} \mathbf{V}^T \end{bmatrix}, \quad (293)$$

其中  $\mathbf{D}$  是  $\mathbf{A}$  的特征值构成的对角矩阵,  $\mathbf{V}$  是正交矩阵, 是  $\mathbf{A}$  的特征向量。

## 5.3.2 方阵分解为平方

假设  $\mathbf{A} \in \mathbb{R}^{n \times n}$ 。则

$$\begin{bmatrix} \mathbf{A} \end{bmatrix} = \begin{bmatrix} \mathbf{V} \end{bmatrix} \begin{bmatrix} \mathbf{D} \end{bmatrix} \begin{bmatrix} \mathbf{U}^T \end{bmatrix}, \quad (294)$$

其中  $\mathbf{D}$  是对角线, 其元素为  $\mathbf{A}\mathbf{A}^T$  的特征值的平方根,  $\mathbf{V}$  是  $\mathbf{A}\mathbf{A}^T$  的特征向量,  $\mathbf{U}^T$  是  $\mathbf{A}^T \mathbf{A}$  的特征向量。

### 5.3.3 方阵分解为矩形

假设  $\mathbf{V}_* \mathbf{D}_* \mathbf{U}_*^T = \mathbf{0}$ , 那么我们可以将  $\mathbf{A}$  的奇异值分解展开为

$$\begin{bmatrix} \mathbf{A} \end{bmatrix} = \begin{bmatrix} \mathbf{V} & \mathbf{V}_* \end{bmatrix} \begin{bmatrix} \mathbf{D} & \mathbf{0} \\ \mathbf{0} & \mathbf{D}_* \end{bmatrix} \begin{bmatrix} \mathbf{U}^T \\ \mathbf{U}_*^T \end{bmatrix}, \quad (295)$$

其中  $\mathbf{A}$  的奇异值分解为  $\mathbf{A} = \mathbf{V} \mathbf{D} \mathbf{U}^T$ 。

### 5.3.4 矩形分解 I

假设  $\mathbf{A}$  是  $n \times m$  的矩阵,  $\mathbf{V}$  是  $n \times n$  的矩阵,  $\mathbf{D}$  是  $n \times n$  的矩阵,  $\mathbf{U}^T$  是  $n \times m$

$$\begin{bmatrix} \mathbf{A} \end{bmatrix} = \begin{bmatrix} \mathbf{V} \end{bmatrix} \begin{bmatrix} \mathbf{D} \end{bmatrix} \begin{bmatrix} \mathbf{U}^T \end{bmatrix}, \quad (296)$$

其中  $\mathbf{D}$  是对角线上的特征值的平方根  $\mathbf{A} \mathbf{A}^T$ ,  $\mathbf{V}$  是  $\mathbf{A} \mathbf{A}^T$  的特征向量  $\mathbf{U}^T$  是  $\mathbf{A}^T \mathbf{A}$  的特征向量。

### 5.3.5 矩形分解 II

假设  $\mathbf{A}$  是  $n \times m$  的矩阵  $\mathbf{V}$  是  $n \times m$  的矩阵  $\mathbf{D}$  是  $m \times m$  的矩阵  $\mathbf{U}^T$  是  $m \times m$

$$\begin{bmatrix} \mathbf{A} \end{bmatrix} = \begin{bmatrix} \mathbf{V} \end{bmatrix} \begin{bmatrix} \mathbf{D} \end{bmatrix} \begin{bmatrix} \mathbf{U}^T \end{bmatrix} \quad (297)$$

### 5.3.6 矩形分解 III

假设  $\mathbf{A}$  是  $n \times m$  的矩阵  $\mathbf{V}$  是  $n \times n$  的矩阵  $\mathbf{D}$  是  $n \times m$  的矩阵  $\mathbf{U}^T$  是  $m \times m$

$$\begin{bmatrix} \mathbf{A} \end{bmatrix} = \begin{bmatrix} \mathbf{V} \end{bmatrix} \begin{bmatrix} \mathbf{D} \end{bmatrix} \begin{bmatrix} \mathbf{U}^T \end{bmatrix}, \quad (298)$$

其中  $\mathbf{D}$  是对角线上的特征值的平方根  $\mathbf{A} \mathbf{A}^T$ ,  $\mathbf{V}$  是  $\mathbf{A} \mathbf{A}^T$  的特征向量  $\mathbf{U}^T$  是  $\mathbf{A}^T \mathbf{A}$  的特征向量。

## 5.4 三角分解

### 5.5 LU分解

假设  $\mathbf{A}$  是一个具有非零主子式的方阵, 则

$$\mathbf{A} = \mathbf{L} \mathbf{U} \quad (299)$$

其中  $\mathbf{L}$  是一个唯一的单位下三角矩阵,  $\mathbf{U}$  是一个唯一的上三角矩阵。

#### 5.5.1 乔列斯基分解

假设  $\mathbf{A}$  是一个对称正定的方阵, 那么

$$\mathbf{A} = \mathbf{U}^T \mathbf{U} = \mathbf{L} \mathbf{L}^T, \quad (300)$$

其中  $\mathbf{U}$  是一个唯一的上三角矩阵,  $\mathbf{L}$  是一个下三角矩阵。



## 5.6 LDM分解

假设  $A$  是一个具有非零主子式<sup>1</sup>的方阵，那么

$$A = LDM^T \quad (301)$$

其中  $L$ ,  $M$  是唯一的单位下三角矩阵， $D$  是一个唯一的对角矩阵。

## 5.7 LDL分解

LDL分解是LDM分解的特殊情况。假设  $A$  是一个非奇异的对称正定方阵，那么

$$A = LDL^T = L^T DL \quad (302)$$

其中  $L$  是一个单位下三角矩阵， $D$  是一个对角矩阵。如果  $A$  也是正定的，那么  $D$  的对角线元素严格为正。

---

<sup>1</sup>如果与一个主子式相对应的矩阵是较大矩阵的二次上左部分（即由行和列从1到k的矩阵元素组成），则该主子式称为前导主子式。对于一个  $n$  乘  $n$  的方阵，有  $n$  个前导主子式。[31]

## 6 统计与概率

### 6.1 矩的定义

假设  $\mathbf{x} \in \mathbb{R}^{n \times 1}$  是一个随机变量

#### 6.1.1 均值

均值向量  $\mathbf{m}$  的定义如下

$$(\mathbf{m})_i = \langle x_i \rangle \quad (303)$$

#### 6.1.2 协方差

协方差矩阵  $\mathbf{M}$  的定义如下

$$(\mathbf{M})_{ij} = \langle (x_i - \langle x_i \rangle)(x_j - \langle x_j \rangle) \rangle \quad (304)$$

或者可以写成

$$\mathbf{M} = \langle (\mathbf{x} - \mathbf{m})(\mathbf{x} - \mathbf{m})^T \rangle \quad (305)$$

#### 6.1.3 第三阶矩

第三阶中心矩阵 - 在某些情况下称为共偏斜度 - 使用以下符号定义

$$m_{ijk}^{(3)} = \langle (x_i - \langle x_i \rangle)(x_j - \langle x_j \rangle)(x_k - \langle x_k \rangle) \rangle \quad (306)$$

如

$$\mathbf{M}_3 = [m_{::1}^{(3)} m_{::2}^{(3)} \dots m_{::n}^{(3)}] \quad (307)$$

其中 ':' 表示给定索引内的所有元素。  $\mathbf{M}_3$  也可以表示为

$$\mathbf{M}_3 = \langle (\mathbf{x} - \mathbf{m})(\mathbf{x} - \mathbf{m})^T \otimes (\mathbf{x} - \mathbf{m})^T \rangle \quad (308)$$

#### 6.1.4 四阶矩

第四阶中心矩阵 - 在某些情况下也称为峰度 - 使用以下符号定义

$$m_{ijkl}^{(4)} = \langle (x_i - \langle x_i \rangle)(x_j - \langle x_j \rangle)(x_k - \langle x_k \rangle)(x_l - \langle x_l \rangle) \rangle \quad (309)$$

在

$$\mathbf{M}_4 = [m_{::11}^{(4)} m_{::21}^{(4)} \dots m_{::n1}^{(4)} | m_{::12}^{(4)} m_{::22}^{(4)} \dots m_{::n2}^{(4)} | \dots | m_{::1n}^{(4)} m_{::2n}^{(4)} \dots m_{::nn}^{(4)}] \quad (310)$$

或者可以表示为

$$\mathbf{M}_4 = \langle (\mathbf{x} - \mathbf{m})(\mathbf{x} - \mathbf{m})^T \otimes (\mathbf{x} - \mathbf{m})^T \otimes (\mathbf{x} - \mathbf{m})^T \rangle \quad (311)$$

## 6.2 线性组合的期望

### 6.2.1 线性形式

假设  $\mathbf{X}$  和  $\mathbf{x}$  是一个矩阵和一个随机变量向量。那么（见参见[26]）

$$E[\mathbf{A}\mathbf{X}\mathbf{B} + \mathbf{C}] = \mathbf{A}E[\mathbf{X}]\mathbf{B} + \mathbf{C} \quad (312)$$

$$\text{Var}[\mathbf{A}\mathbf{x}] = \mathbf{A}\text{Var}[\mathbf{x}]\mathbf{A}^T \quad (313)$$

$$\text{Cov}[\mathbf{A}\mathbf{x}, \mathbf{B}\mathbf{y}] = \mathbf{A}\text{Cov}[\mathbf{x}, \mathbf{y}]\mathbf{B}^T \quad (314)$$

假设  $\mathbf{x}$  是一个具有均值  $\mathbf{m}$  的随机向量，那么（见[7]）

$$E[\mathbf{A}\mathbf{x} + \mathbf{b}] = \mathbf{A}\mathbf{m} + \mathbf{b} \quad (315)$$

$$E[\mathbf{A}\mathbf{x}] = \mathbf{A}\mathbf{m} \quad (316)$$

$$E[\mathbf{x} + \mathbf{b}] = \mathbf{m} + \mathbf{b} \quad (317)$$

### 6.2.2 二次型

假设  $\mathbf{A}$  是对称的， $\mathbf{c} = E[\mathbf{x}]$  和  $\mathbf{\Sigma} = \text{Var}[\mathbf{x}]$ . 还假设所有坐标  $x_i$  是独立的，具有相同的中心矩  $\mu_1, \mu_2, \mu_3, \mu_4$  并且记  $\mathbf{a} = \text{diag}(\mathbf{A})$ . 那么（参见[26]）

$$E[\mathbf{x}^T \mathbf{A} \mathbf{x}] = \text{Tr}(\mathbf{A}\mathbf{\Sigma}) + \mathbf{c}^T \mathbf{A} \mathbf{c} \quad (318)$$

$$\text{Var}[\mathbf{x}^T \mathbf{A} \mathbf{x}] = 2\mu_2^2 \text{Tr}(\mathbf{A}^2) + 4\mu_2 \mathbf{c}^T \mathbf{A}^2 \mathbf{c} + 4\mu_3 \mathbf{c}^T \mathbf{A} \mathbf{a} + (\mu_4 - 3\mu_2^2) \mathbf{a}^T \mathbf{a} \quad (319)$$

另外，假设  $\mathbf{x}$  是一个均值为  $\mathbf{m}$ ，协方差为  $\mathbf{M}$  的随机向量（见[7]）

$$E[(\mathbf{A}\mathbf{x} + \mathbf{a})(\mathbf{B}\mathbf{x} + \mathbf{b})^T] = \mathbf{A}\mathbf{M}\mathbf{B}^T + (\mathbf{A}\mathbf{m} + \mathbf{a})(\mathbf{B}\mathbf{m} + \mathbf{b})^T \quad (320)$$

$$E[\mathbf{x}\mathbf{x}^T] = \mathbf{M} + \mathbf{m}\mathbf{m}^T \quad (321)$$

$$E[\mathbf{x}\mathbf{a}^T \mathbf{x}] = (\mathbf{M} + \mathbf{m}\mathbf{m}^T)\mathbf{a} \quad (322)$$

$$E[\mathbf{x}^T \mathbf{a}\mathbf{x}^T] = \mathbf{a}^T(\mathbf{M} + \mathbf{m}\mathbf{m}^T) \quad (323)$$

$$E[(\mathbf{A}\mathbf{x})(\mathbf{A}\mathbf{x})^T] = \mathbf{A}(\mathbf{M} + \mathbf{m}\mathbf{m}^T)\mathbf{A}^T \quad (324)$$

$$E[(\mathbf{x} + \mathbf{a})(\mathbf{x} + \mathbf{a})^T] = \mathbf{M} + (\mathbf{m} + \mathbf{a})(\mathbf{m} + \mathbf{a})^T \quad (325)$$

$$E[(\mathbf{A}\mathbf{x} + \mathbf{a})^T(\mathbf{B}\mathbf{x} + \mathbf{b})] = \text{Tr}(\mathbf{A}\mathbf{M}\mathbf{B}^T) + (\mathbf{A}\mathbf{m} + \mathbf{a})^T(\mathbf{B}\mathbf{m} + \mathbf{b}) \quad (326)$$

$$E[\mathbf{x}^T \mathbf{x}] = \text{Tr}(\mathbf{M}) + \mathbf{m}^T \mathbf{m} \quad (327)$$

$$E[\mathbf{x}^T \mathbf{A} \mathbf{x}] = \text{Tr}(\mathbf{A}\mathbf{M}) + \mathbf{m}^T \mathbf{A} \mathbf{m} \quad (328)$$

$$E[(\mathbf{A}\mathbf{x})^T(\mathbf{A}\mathbf{x})] = \text{Tr}(\mathbf{A}\mathbf{M}\mathbf{A}^T) + (\mathbf{A}\mathbf{m})^T(\mathbf{A}\mathbf{m}) \quad (329)$$

$$E[(\mathbf{x} + \mathbf{a})^T(\mathbf{x} + \mathbf{a})] = \text{Tr}(\mathbf{M}) + (\mathbf{m} + \mathbf{a})^T(\mathbf{m} + \mathbf{a}) \quad (330)$$

见[7]。

## 6.2.3 立方形式

假设  $\mathbf{x}$  是一个具有独立坐标、均值  $\mathbf{m}$ 、协方差  $\mathbf{M}$  和中心矩  $\mathbf{v}_3 = E[(\mathbf{x} - \mathbf{m})^3]$  的随机向量。然后 (参见[7])

$$\begin{aligned}
 E[(\mathbf{Ax} + \mathbf{a})(\mathbf{Bx} + \mathbf{b})^T(\mathbf{Cx} + \mathbf{c})] &= \mathbf{A} \text{diag}(\mathbf{B}^T \mathbf{C}) \mathbf{v}_3 \\
 &\quad + \text{Tr}(\mathbf{BMC}^T)(\mathbf{Am} + \mathbf{a}) \\
 &\quad + \mathbf{AMC}^T(\mathbf{Bm} + \mathbf{b}) \\
 &\quad + (\mathbf{AMB}^T + (\mathbf{Am} + \mathbf{a})(\mathbf{Bm} + \mathbf{b})^T)(\mathbf{Cm} + \mathbf{c}) \\
 E[\mathbf{xx}^T \mathbf{x}] &= \mathbf{v}_3 + 2\mathbf{Mm} + (\text{Tr}(\mathbf{M}) + \mathbf{m}^T \mathbf{m}) \mathbf{m} \\
 E[(\mathbf{Ax} + \mathbf{a})(\mathbf{Ax} + \mathbf{a})^T(\mathbf{Ax} + \mathbf{a})] &= \mathbf{A} \text{diag}(\mathbf{A}^T \mathbf{A}) \mathbf{v}_3 \\
 &\quad + [2\mathbf{AMA}^T + (\mathbf{Ax} + \mathbf{a})(\mathbf{Ax} + \mathbf{a})^T](\mathbf{Am} + \mathbf{a}) \\
 &\quad + \text{Tr}(\mathbf{AMA}^T)(\mathbf{Am} + \mathbf{a}) \\
 E[(\mathbf{Ax} + \mathbf{a})\mathbf{b}^T(\mathbf{Cx} + \mathbf{c})(\mathbf{Dx} + \mathbf{d})^T] &= (\mathbf{Ax} + \mathbf{a})\mathbf{b}^T(\mathbf{CMD}^T + (\mathbf{Cm} + \mathbf{c})(\mathbf{Dm} + \mathbf{d})^T) \\
 &\quad + (\mathbf{AMC}^T + (\mathbf{Am} + \mathbf{a})(\mathbf{Cm} + \mathbf{c})^T)\mathbf{b}(\mathbf{Dm} + \mathbf{d})^T \\
 &\quad + \mathbf{b}^T(\mathbf{Cm} + \mathbf{c})(\mathbf{AMD}^T - (\mathbf{Am} + \mathbf{a})(\mathbf{Dm} + \mathbf{d})^T)
 \end{aligned}$$

## 6.3 加权标量变量

假设  $\mathbf{x} \in \mathbb{R}^{n \times 1}$  是一个随机变量,  $\mathbf{w} \in \mathbb{R}^{n \times 1}$  是一个常数向量,  $y$  是线性组合  $y = \mathbf{w}^T \mathbf{x}$ 。进一步假设  $\mathbf{m}, \mathbf{M}_2, \mathbf{M}_3, \mathbf{M}_4$  表示变量  $\mathbf{x}$  的均值、协方差和中心三阶和四阶矩阵。那么有

$$\langle y \rangle = \mathbf{w}^T \mathbf{m} \quad (331)$$

$$\langle (y - \langle y \rangle)^2 \rangle = \mathbf{w}^T \mathbf{M}_2 \mathbf{w} \quad (332)$$

$$\langle (y - \langle y \rangle)^3 \rangle = \mathbf{w}^T \mathbf{M}_3 \mathbf{w} \otimes \mathbf{w} \quad (333)$$

$$\langle (y - \langle y \rangle)^4 \rangle = \mathbf{w}^T \mathbf{M}_4 \mathbf{w} \otimes \mathbf{w} \otimes \mathbf{w} \quad (334)$$

## 7 多元分布

### 7.1 柯西分布

柯西分布向量的密度函数  $\mathbf{t} \in \mathbb{R}^{P \times 1}$ , 给定为

$$p(\mathbf{t}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \pi^{-P/2} \frac{\Gamma(\frac{1+P}{2})}{\Gamma(1/2)} \frac{\det(\boldsymbol{\Sigma})^{-1/2}}{\left[1 + (\mathbf{t} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{t} - \boldsymbol{\mu})\right]^{(1+P)/2}} \quad (335)$$

其中  $\boldsymbol{\mu}$  是位置,  $\boldsymbol{\Sigma}$  是正定的,  $\Gamma$  表示伽玛函数。柯西分布是学生-t 分布的特例。

### 7.2 狄利克雷分布

狄利克雷分布是与多项分布相比的一种“逆”分布, 适用于有界连续变量  $\mathbf{x} = [x_1, \dots, x_P]$  [16, p. 44]

$$p(\mathbf{x}|\boldsymbol{\alpha}) = \frac{\Gamma\left(\sum_p \alpha_p\right)}{\prod_p \Gamma(\alpha_p)} \prod_p x_p^{\alpha_p-1}$$

### 7.3 正态分布

正态分布也被称为高斯分布。见第8节。

### 7.4 正态逆伽马分布

### 7.5 高斯分布

见第8节。

### 7.6 多项分布

如果向量  $\mathbf{n}$  包含计数, 即  $(\mathbf{n})_i \in 0, 1, 2, \dots$ , 则离散多项式分布对于  $\mathbf{n}$  给出

$$P(\mathbf{n}|\mathbf{a}, n) = \frac{n!}{n_1! \dots n_d!} \prod_i a_i^{n_i}, \quad \sum_i n_i = n \quad (336)$$

其中  $a_i$  是概率, 即  $0 \leq a_i \leq 1$ , 且  $\sum_i a_i = 1$ .

### 7.7 学生t分布

学生-t 分布向量  $\mathbf{t} \in \mathbb{R}^{P \times 1}$  的密度由以下公式给出

$$p(\mathbf{t}|\boldsymbol{\mu}, \boldsymbol{\Sigma}, \nu) = (\pi\nu)^{-P/2} \frac{\Gamma(\frac{\nu+P}{2})}{\Gamma(\nu/2)} \frac{\det(\boldsymbol{\Sigma})^{-1/2}}{\left[1 + \nu^{-1}(\mathbf{t} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{t} - \boldsymbol{\mu})\right]^{(\nu+P)/2}} \quad (337)$$

其中  $\boldsymbol{\mu}$  是位置, 比例矩阵  $\boldsymbol{\Sigma}$  是对称的、正定的,  $\nu$  是自由度,  $\Gamma$  表示伽玛函数。对于  $\nu=1$ , 学生-t 分布变成柯西分布 (见第7.1节)。

## 7.7.1 平均值

$$E(\mathbf{t}) = \boldsymbol{\mu}, \quad \nu > 1 \quad (338)$$

## 7.7.2 方差

$$\text{cov}(\mathbf{t}) = \frac{\nu}{\nu - 2} \boldsymbol{\Sigma}, \quad \nu > 2 \quad (339)$$

## 7.7.3 众数

概念 *mode* 意味着最可能值的位置

$$\text{mode}(\mathbf{t}) = \boldsymbol{\mu} \quad (340)$$

## 7.7.4 完整矩阵版本

如果不是一个向量  $\mathbf{t} \in \mathbb{R}^{P \times 1}$ ，而是一个矩阵  $\mathbf{T} \in \mathbb{R}^{P \times N}$ ，则对于T的学生-t分布为

$$\begin{aligned} p(\mathbf{T}|\mathbf{M}, \boldsymbol{\Omega}, \boldsymbol{\Sigma}, \nu) &= \pi^{-N P/2} \prod_{p=1}^P \frac{\Gamma[(\nu + P - p + 1)/2]}{\Gamma[(\nu - p + 1)/2]} \times \\ &\quad \nu \det(\boldsymbol{\Omega})^{-\nu/2} \det(\boldsymbol{\Sigma})^{-N/2} \times \\ &\quad \det \left[ \boldsymbol{\Omega}^{-1} + (\mathbf{T} - \mathbf{M}) \boldsymbol{\Sigma}^{-1} (\mathbf{T} - \mathbf{M})^T \right]^{-(\nu+P)/2} \end{aligned} \quad (341)$$

其中  $\mathbf{M}$  是位置， $\boldsymbol{\Omega}$  是缩放矩阵， $\boldsymbol{\Sigma}$  是正定的， $\nu$  是自由度， $\Gamma$  表示伽玛函数。

## 7.8 Wishart

对于  $\mathbf{M} \in \mathbb{R}^{P \times P}$  的中心Wishart分布， $\mathbf{M}$  是正定的，其中  $m$  可以看作是自由度参数[16，方程3.8.1] [8，第2.5节]，[11]

$$\begin{aligned} p(\mathbf{M}|\boldsymbol{\Sigma}, m) &= \frac{1}{2^{mP/2} \pi^{P(P-1)/4} \prod_{p=1}^P \Gamma[\frac{1}{2}(m+1-p)]} \times \\ &\quad \det(\boldsymbol{\Sigma})^{-m/2} \det(\mathbf{M})^{(m-P-1)/2} \times \\ &\quad \exp \left[ -\frac{1}{2} \text{Tr}(\boldsymbol{\Sigma}^{-1} \mathbf{M}) \right] \end{aligned} \quad (342)$$

## 7.8.1 平均值

$$E(\mathbf{M}) = m \boldsymbol{\Sigma} \quad (343)$$

### 7.9 逆Wishart分布

对于  $\mathbf{M} \in \mathbb{R}^{P \times P}$  的（正常的）逆Wishart分布， $\mathbf{M}$ 是正定的，其中  $m$  可以被视为自由度参数[11]

$$p(\mathbf{M}|\boldsymbol{\Sigma}, m) = \frac{1}{2^{mP/2} \pi^{P(P-1)/4} \prod_p^P \Gamma[\frac{1}{2}(m+1-p)]} \times \det(\boldsymbol{\Sigma})^{m/2} \det(\mathbf{M})^{-(m-P+1)/2} \times \exp\left[-\frac{1}{2}\text{Tr}(\boldsymbol{\Sigma}\mathbf{M}^{-1})\right] \quad (344)$$

#### 7.9.1 平均值

$$E(\mathbf{M}) = \boldsymbol{\Sigma} \frac{1}{m-P+1} \quad (345)$$

## 8 高斯分布

### 8.1 基础知识

#### 8.1.1 密度和归一化

$\mathbf{x} \sim \mathcal{N}(\mathbf{m}, \Sigma)$  的密度为

$$p(\mathbf{x}) = \frac{1}{\sqrt{\det(2\pi\Sigma)}} \exp \left[ -\frac{1}{2}(\mathbf{x} - \mathbf{m})^T \Sigma^{-1}(\mathbf{x} - \mathbf{m}) \right] \quad (346)$$

请注意, 如果  $\mathbf{x}$  是  $d$  维的, 则  $\det(2\pi\Sigma) = (2\pi)^d \det(\Sigma)$ 。  
积分和归一化

$$\begin{aligned} \int \exp \left[ -\frac{1}{2}(\mathbf{x} - \mathbf{m})^T \Sigma^{-1}(\mathbf{x} - \mathbf{m}) \right] d\mathbf{x} &= \sqrt{\det(2\pi\Sigma)} \\ \int \exp \left[ -\frac{1}{2}\mathbf{x}^T \Sigma^{-1}\mathbf{x} + \mathbf{m}^T \Sigma^{-1}\mathbf{x} \right] d\mathbf{x} &= \sqrt{\det(2\pi\Sigma)} \exp \left[ \frac{1}{2}\mathbf{m}^T \Sigma^{-1}\mathbf{m} \right] \\ \int \exp \left[ -\frac{1}{2}\mathbf{x}^T \mathbf{A}\mathbf{x} + \mathbf{c}^T \mathbf{x} \right] d\mathbf{x} &= \sqrt{\det(2\pi\mathbf{A}^{-1})} \exp \left[ \frac{1}{2}\mathbf{c}^T \mathbf{A}^{-1}\mathbf{c} \right] \end{aligned}$$

如果  $\mathbf{X} = [\mathbf{x}_1 \mathbf{x}_2 \dots \mathbf{x}_n]$  和  $\mathbf{C} = [\mathbf{c}_1 \mathbf{c}_2 \dots \mathbf{c}_n]$ , 那么

$$\int \exp \left[ -\frac{1}{2}\text{Tr}(\mathbf{X}^T \mathbf{A} \mathbf{X}) + \text{Tr}(\mathbf{C}^T \mathbf{X}) \right] d\mathbf{X} = \sqrt{\det(2\pi\mathbf{A}^{-1})^n} \exp \left[ \frac{1}{2}\text{Tr}(\mathbf{C}^T \mathbf{A}^{-1} \mathbf{C}) \right]$$

密度的导数为

$$\frac{\partial p(\mathbf{x})}{\partial \mathbf{x}} = -p(\mathbf{x}) \Sigma^{-1}(\mathbf{x} - \mathbf{m}) \quad (347)$$

$$\frac{\partial^2 p}{\partial \mathbf{x} \partial \mathbf{x}^T} = p(\mathbf{x}) \left( \Sigma^{-1}(\mathbf{x} - \mathbf{m})(\mathbf{x} - \mathbf{m})^T \Sigma^{-1} - \Sigma^{-1} \right) \quad (348)$$

#### 8.1.2 边缘分布

假设  $\mathbf{x} \sim \mathcal{N}_{\mathbf{x}}(\mu, \Sigma)$  其中

$$\mathbf{x} = \begin{bmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{bmatrix} \quad \mu = \begin{bmatrix} \mu_a \\ \mu_b \end{bmatrix} \quad \Sigma = \begin{bmatrix} \Sigma_a & \Sigma_c \\ \Sigma_c^T & \Sigma_b \end{bmatrix} \quad (349)$$

然后

$$p(\mathbf{x}_a) = \mathcal{N}_{\mathbf{x}_a}(\mu_a, \Sigma_a) \quad (350)$$

$$p(\mathbf{x}_b) = \mathcal{N}_{\mathbf{x}_b}(\mu_b, \Sigma_b) \quad (351)$$

#### 8.1.3 条件分布

假设  $\mathbf{x} \sim \mathcal{N}_{\mathbf{x}}(\mu, \Sigma)$  其中

$$\mathbf{x} = \begin{bmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{bmatrix} \quad \mu = \begin{bmatrix} \mu_a \\ \mu_b \end{bmatrix} \quad \Sigma = \begin{bmatrix} \Sigma_a & \Sigma_c \\ \Sigma_c^T & \Sigma_b \end{bmatrix} \quad (352)$$



然后

$$p(\mathbf{x}_a|\mathbf{x}_b) = \mathcal{N}_{\mathbf{x}_a}(\hat{\boldsymbol{\mu}}_a, \hat{\boldsymbol{\Sigma}}_a) \quad \begin{cases} \hat{\boldsymbol{\mu}}_a &= \boldsymbol{\mu}_a + \boldsymbol{\Sigma}_c \boldsymbol{\Sigma}_b^{-1}(\mathbf{x}_b - \boldsymbol{\mu}_b) \\ \hat{\boldsymbol{\Sigma}}_a &= \boldsymbol{\Sigma}_a - \boldsymbol{\Sigma}_c \boldsymbol{\Sigma}_b^{-1} \boldsymbol{\Sigma}_c^T \end{cases} \quad (353)$$

$$p(\mathbf{x}_b|\mathbf{x}_a) = \mathcal{N}_{\mathbf{x}_b}(\hat{\boldsymbol{\mu}}_b, \hat{\boldsymbol{\Sigma}}_b) \quad \begin{cases} \hat{\boldsymbol{\mu}}_b &= \boldsymbol{\mu}_b + \boldsymbol{\Sigma}_c^T \boldsymbol{\Sigma}_a^{-1}(\mathbf{x}_a - \boldsymbol{\mu}_a) \\ \hat{\boldsymbol{\Sigma}}_b &= \boldsymbol{\Sigma}_b - \boldsymbol{\Sigma}_c^T \boldsymbol{\Sigma}_a^{-1} \boldsymbol{\Sigma}_c \end{cases} \quad (354)$$

注意，协方差矩阵是块矩阵的舒尔补，详见9.1.5。

#### 8.1.4 线性组合

假设  $\mathbf{x} \sim \mathcal{N}(\mathbf{m}_x, \boldsymbol{\Sigma}_x)$  和  $\mathbf{y} \sim \mathcal{N}(\mathbf{m}_y, \boldsymbol{\Sigma}_y)$ ，则

$$\mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{y} + \mathbf{c} \sim \mathcal{N}(\mathbf{A}\mathbf{m}_x + \mathbf{B}\mathbf{m}_y + \mathbf{c}, \mathbf{A}\boldsymbol{\Sigma}_x\mathbf{A}^T + \mathbf{B}\boldsymbol{\Sigma}_y\mathbf{B}^T) \quad (355)$$

#### 8.1.5 重新排列均值

$$\mathcal{N}_{\mathbf{A}\mathbf{x}}[\mathbf{m}, \boldsymbol{\Sigma}] = \frac{\sqrt{\det(2\pi(\mathbf{A}^T\boldsymbol{\Sigma}^{-1}\mathbf{A})^{-1})}}{\sqrt{\det(2\pi\boldsymbol{\Sigma})}} \mathcal{N}_{\mathbf{x}}[\mathbf{A}^{-1}\mathbf{m}, (\mathbf{A}^T\boldsymbol{\Sigma}^{-1}\mathbf{A})^{-1}] \quad (356)$$

如果  $\mathbf{A}$  是方阵且可逆，简化为

$$\mathcal{N}_{\mathbf{A}\mathbf{x}}[\mathbf{m}, \boldsymbol{\Sigma}] = \frac{1}{|\det(\mathbf{A})|} \mathcal{N}_{\mathbf{x}}[\mathbf{A}^{-1}\mathbf{m}, (\mathbf{A}^T\boldsymbol{\Sigma}^{-1}\mathbf{A})^{-1}] \quad (357)$$

#### 8.1.6 重排成方阵形式

如果  $\mathbf{A}$  是对称矩阵，则

$$\begin{aligned} -\frac{1}{2}\mathbf{x}^T\mathbf{A}\mathbf{x} + \mathbf{b}^T\mathbf{x} &= -\frac{1}{2}(\mathbf{x} - \mathbf{A}^{-1}\mathbf{b})^T\mathbf{A}(\mathbf{x} - \mathbf{A}^{-1}\mathbf{b}) + \frac{1}{2}\mathbf{b}^T\mathbf{A}^{-1}\mathbf{b} \\ -\frac{1}{2}\text{Tr}(\mathbf{X}^T\mathbf{A}\mathbf{X}) + \text{Tr}(\mathbf{B}^T\mathbf{X}) &= -\frac{1}{2}\text{Tr}[(\mathbf{X} - \mathbf{A}^{-1}\mathbf{B})^T\mathbf{A}(\mathbf{X} - \mathbf{A}^{-1}\mathbf{B})] + \frac{1}{2}\text{Tr}(\mathbf{B}^T\mathbf{A}^{-1}\mathbf{B}) \end{aligned}$$

#### 8.1.7 两个平方形式的和

在向量形式中（假设  $\boldsymbol{\Sigma}_1, \boldsymbol{\Sigma}_2$  是对称的）

$$-\frac{1}{2}(\mathbf{x} - \mathbf{m}_1)^T\boldsymbol{\Sigma}_1^{-1}(\mathbf{x} - \mathbf{m}_1) \quad (358)$$

$$-\frac{1}{2}(\mathbf{x} - \mathbf{m}_2)^T\boldsymbol{\Sigma}_2^{-1}(\mathbf{x} - \mathbf{m}_2) \quad (359)$$

$$= -\frac{1}{2}(\mathbf{x} - \mathbf{m}_c)^T\boldsymbol{\Sigma}_c^{-1}(\mathbf{x} - \mathbf{m}_c) + C \quad (360)$$

$$\boldsymbol{\Sigma}_c^{-1} = \boldsymbol{\Sigma}_1^{-1} + \boldsymbol{\Sigma}_2^{-1} \quad (361)$$

$$\mathbf{m}_c = (\boldsymbol{\Sigma}_1^{-1} + \boldsymbol{\Sigma}_2^{-1})^{-1}(\boldsymbol{\Sigma}_1^{-1}\mathbf{m}_1 + \boldsymbol{\Sigma}_2^{-1}\mathbf{m}_2) \quad (362)$$

$$C = \frac{1}{2}(\mathbf{m}_1^T\boldsymbol{\Sigma}_1^{-1} + \mathbf{m}_2^T\boldsymbol{\Sigma}_2^{-1})(\boldsymbol{\Sigma}_1^{-1} + \boldsymbol{\Sigma}_2^{-1})^{-1}(\boldsymbol{\Sigma}_1^{-1}\mathbf{m}_1 + \boldsymbol{\Sigma}_2^{-1}\mathbf{m}_2) \quad (363)$$

$$-\frac{1}{2}\left(\mathbf{m}_1^T\boldsymbol{\Sigma}_1^{-1}\mathbf{m}_1 + \mathbf{m}_2^T\boldsymbol{\Sigma}_2^{-1}\mathbf{m}_2\right) \quad (364)$$

在迹的表述中（假设  $\Sigma_1, \Sigma_2$  是对称的）

$$-\frac{1}{2}\text{Tr}((\mathbf{X} - \mathbf{M}_1)^T \Sigma_1^{-1} (\mathbf{X} - \mathbf{M}_1)) \quad (365)$$

$$-\frac{1}{2}\text{Tr}((\mathbf{X} - \mathbf{M}_2)^T \Sigma_2^{-1} (\mathbf{X} - \mathbf{M}_2)) \quad (366)$$

$$= -\frac{1}{2}\text{Tr}[(\mathbf{X} - \mathbf{M}_c)^T \Sigma_c^{-1} (\mathbf{X} - \mathbf{M}_c)] + C \quad (367)$$

$$\Sigma_c^{-1} = \Sigma_1^{-1} + \Sigma_2^{-1} \quad (368)$$

$$\mathbf{M}_c = (\Sigma_1^{-1} + \Sigma_2^{-1})^{-1} (\Sigma_1^{-1} \mathbf{M}_1 + \Sigma_2^{-1} \mathbf{M}_2) \quad (369)$$

$$C = \frac{1}{2}\text{Tr}[(\Sigma_1^{-1} \mathbf{M}_1 + \Sigma_2^{-1} \mathbf{M}_2)^T (\Sigma_1^{-1} + \Sigma_2^{-1})^{-1} (\Sigma_1^{-1} \mathbf{M}_1 + \Sigma_2^{-1} \mathbf{M}_2)] \\ - \frac{1}{2}\text{Tr}(\mathbf{M}_1^T \Sigma_1^{-1} \mathbf{M}_1 + \mathbf{M}_2^T \Sigma_2^{-1} \mathbf{M}_2) \quad (370)$$

### 8.1.8 高斯密度的乘积

设  $\mathcal{N}_x(\mathbf{m}, \Sigma)$  表示  $\mathbf{x}$  的密度，则

$$\mathcal{N}_x(\mathbf{m}_1, \Sigma_1) \cdot \mathcal{N}_x(\mathbf{m}_2, \Sigma_2) = c_c \mathcal{N}_x(\mathbf{m}_c, \Sigma_c) \quad (371)$$

$$c_c = \mathcal{N}_{\mathbf{m}_1}(\mathbf{m}_2, (\Sigma_1 + \Sigma_2)) \\ = \frac{1}{\sqrt{\det(2\pi(\Sigma_1 + \Sigma_2))}} \exp \left[ -\frac{1}{2}(\mathbf{m}_1 - \mathbf{m}_2)^T (\Sigma_1 + \Sigma_2)^{-1} (\mathbf{m}_1 - \mathbf{m}_2) \right] \\ \mathbf{m}_c = (\Sigma_1^{-1} + \Sigma_2^{-1})^{-1} (\Sigma_1^{-1} \mathbf{m}_1 + \Sigma_2^{-1} \mathbf{m}_2) \\ \Sigma_c = (\Sigma_1^{-1} + \Sigma_2^{-1})^{-1}$$

但请注意，该乘积未归一化为密度  $\mathbf{x}$ 。

## 8.2 矩的定义

### 8.2.1 线性形式的均值和协方差

一阶和二阶矩。假设  $\mathbf{x} \sim \mathcal{N}(\mathbf{m}, \Sigma)$

$$E(\mathbf{x}) = \mathbf{m} \quad (372)$$

$$\text{Cov}(\mathbf{x}, \mathbf{x}) = \text{Var}(\mathbf{x}) = \Sigma = E(\mathbf{x}\mathbf{x}^T) - E(\mathbf{x})E(\mathbf{x}^T) = E(\mathbf{x}\mathbf{x}^T) - \mathbf{m}\mathbf{m}^T \quad (373)$$

对于任何其他分布，高斯分布也成立

$$E[\mathbf{A}\mathbf{x}] = \mathbf{A}E[\mathbf{x}] \quad (374)$$

$$\text{Var}[\mathbf{A}\mathbf{x}] = \mathbf{A}\text{Var}[\mathbf{x}]\mathbf{A}^T \quad (375)$$

$$\text{Cov}[\mathbf{A}\mathbf{x}, \mathbf{B}\mathbf{y}] = \mathbf{A}\text{Cov}[\mathbf{x}, \mathbf{y}]\mathbf{B}^T \quad (376)$$

## 8.2.2 平方形式的均值和方差

平方形式的均值和方差：假设  $\mathbf{x} \sim \mathcal{N}(\mathbf{m}, \Sigma)$

$$E(\mathbf{x}\mathbf{x}^T) = \Sigma + \mathbf{m}\mathbf{m}^T \quad (377)$$

$$E[\mathbf{x}^T \mathbf{A} \mathbf{x}] = \text{Tr}(\mathbf{A}\Sigma) + \mathbf{m}^T \mathbf{A} \mathbf{m} \quad (378)$$

$$\begin{aligned} \text{Var}(\mathbf{x}^T \mathbf{A} \mathbf{x}) &= \text{Tr}[\mathbf{A}\Sigma(\mathbf{A} + \mathbf{A}^T)\Sigma] + \dots \\ &\quad + \mathbf{m}^T(\mathbf{A} + \mathbf{A}^T)\Sigma(\mathbf{A} + \mathbf{A}^T)\mathbf{m} \end{aligned} \quad (379)$$

$$E[(\mathbf{x} - \mathbf{m}')^T \mathbf{A}(\mathbf{x} - \mathbf{m}')] = (\mathbf{m} - \mathbf{m}')^T \mathbf{A}(\mathbf{m} - \mathbf{m}') + \text{Tr}(\mathbf{A}\Sigma) \quad (380)$$

如果  $\Sigma = \sigma^2 \mathbf{I}$  且  $\mathbf{A}$  是对称的，则

$$\text{Var}(\mathbf{x}^T \mathbf{A} \mathbf{x}) = 2\sigma^4 \text{Tr}(\mathbf{A}^2) + 4\sigma^2 \mathbf{m}^T \mathbf{A}^2 \mathbf{m} \quad (381)$$

假设  $\mathbf{x} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$  且  $\mathbf{A}$  和  $\mathbf{B}$  是对称矩阵，那么

$$\text{Cov}(\mathbf{x}^T \mathbf{A} \mathbf{x}, \mathbf{x}^T \mathbf{B} \mathbf{x}) = 2\sigma^4 \text{Tr}(\mathbf{A}\mathbf{B}) \quad (382)$$

## 8.2.3 三次形式

假设  $\mathbf{x}$  是一个具有独立坐标、均值  $\mathbf{m}$  和协方差  $\mathbf{M}$  的随机向量

$$\begin{aligned} E[\mathbf{x}\mathbf{b}^T \mathbf{x}\mathbf{x}^T] &= \mathbf{m}\mathbf{b}^T(\mathbf{M} + \mathbf{m}\mathbf{m}^T) + (\mathbf{M} + \mathbf{m}\mathbf{m}^T)\mathbf{b}\mathbf{m}^T \\ &\quad + \mathbf{b}^T \mathbf{m}(\mathbf{M} - \mathbf{m}\mathbf{m}^T) \end{aligned} \quad (383)$$

## 8.2.4 四次形式的均值

$$\begin{aligned} E[\mathbf{x}\mathbf{x}^T \mathbf{x}\mathbf{x}^T] &= 2(\Sigma + \mathbf{m}\mathbf{m}^T)^2 + \mathbf{m}^T \mathbf{m}(\Sigma - \mathbf{m}\mathbf{m}^T) \\ &\quad + \text{Tr}(\Sigma)(\Sigma + \mathbf{m}\mathbf{m}^T) \\ E[\mathbf{x}\mathbf{x}^T \mathbf{A}\mathbf{x}\mathbf{x}^T] &= (\Sigma + \mathbf{m}\mathbf{m}^T)(\mathbf{A} + \mathbf{A}^T)(\Sigma + \mathbf{m}\mathbf{m}^T) \\ &\quad + \mathbf{m}^T \mathbf{A} \mathbf{m}(\Sigma - \mathbf{m}\mathbf{m}^T) + \text{Tr}[\mathbf{A}\Sigma](\Sigma + \mathbf{m}\mathbf{m}^T) \\ E[\mathbf{x}^T \mathbf{x}\mathbf{x}^T \mathbf{x}] &= 2\text{Tr}(\Sigma^2) + 4\mathbf{m}^T \Sigma \mathbf{m} + (\text{Tr}(\Sigma) + \mathbf{m}^T \mathbf{m})^2 \\ E[\mathbf{x}^T \mathbf{A}\mathbf{x}\mathbf{x}^T \mathbf{B}\mathbf{x}] &= \text{Tr}[\mathbf{A}\Sigma(\mathbf{B} + \mathbf{B}^T)\Sigma] + \mathbf{m}^T(\mathbf{A} + \mathbf{A}^T)\Sigma(\mathbf{B} + \mathbf{B}^T)\mathbf{m} \\ &\quad + (\text{Tr}(\mathbf{A}\Sigma) + \mathbf{m}^T \mathbf{A} \mathbf{m})(\text{Tr}(\mathbf{B}\Sigma) + \mathbf{m}^T \mathbf{B} \mathbf{m}) \end{aligned}$$

$$\begin{aligned} &E[\mathbf{a}^T \mathbf{x}\mathbf{b}^T \mathbf{x}\mathbf{c}^T \mathbf{x}\mathbf{d}^T \mathbf{x}] \\ &= (\mathbf{a}^T(\Sigma + \mathbf{m}\mathbf{m}^T)\mathbf{b})(\mathbf{c}^T(\Sigma + \mathbf{m}\mathbf{m}^T)\mathbf{d}) \\ &\quad + (\mathbf{a}^T(\Sigma + \mathbf{m}\mathbf{m}^T)\mathbf{c})(\mathbf{b}^T(\Sigma + \mathbf{m}\mathbf{m}^T)\mathbf{d}) \\ &\quad + (\mathbf{a}^T(\Sigma + \mathbf{m}\mathbf{m}^T)\mathbf{d})(\mathbf{b}^T(\Sigma + \mathbf{m}\mathbf{m}^T)\mathbf{c}) - 2\mathbf{a}^T \mathbf{m}\mathbf{b}^T \mathbf{m}\mathbf{c}^T \mathbf{m}\mathbf{d}^T \mathbf{m} \\ &E[(\mathbf{A}\mathbf{x} + \mathbf{a})(\mathbf{B}\mathbf{x} + \mathbf{b})^T(\mathbf{C}\mathbf{x} + \mathbf{c})(\mathbf{D}\mathbf{x} + \mathbf{d})^T] \\ &= [\mathbf{A}\Sigma\mathbf{B}^T + (\mathbf{A}\mathbf{m} + \mathbf{a})(\mathbf{B}\mathbf{m} + \mathbf{b})^T][\mathbf{C}\Sigma\mathbf{D}^T + (\mathbf{C}\mathbf{m} + \mathbf{c})(\mathbf{D}\mathbf{m} + \mathbf{d})^T] \\ &\quad + [\mathbf{A}\Sigma\mathbf{C}^T + (\mathbf{A}\mathbf{m} + \mathbf{a})(\mathbf{C}\mathbf{m} + \mathbf{c})^T][\mathbf{B}\Sigma\mathbf{D}^T + (\mathbf{B}\mathbf{m} + \mathbf{b})(\mathbf{D}\mathbf{m} + \mathbf{d})^T] \\ &\quad + (\mathbf{B}\mathbf{m} + \mathbf{b})^T(\mathbf{C}\mathbf{m} + \mathbf{c})[\mathbf{A}\Sigma\mathbf{D}^T - (\mathbf{A}\mathbf{m} + \mathbf{a})(\mathbf{D}\mathbf{m} + \mathbf{d})^T] \\ &\quad + \text{Tr}(\mathbf{B}\Sigma\mathbf{C}^T)[\mathbf{A}\Sigma\mathbf{D}^T + (\mathbf{A}\mathbf{m} + \mathbf{a})(\mathbf{D}\mathbf{m} + \mathbf{d})^T] \end{aligned}$$

$$\begin{aligned}
& E[(\mathbf{Ax} + \mathbf{a})^T (\mathbf{Bx} + \mathbf{b})(\mathbf{Cx} + \mathbf{c})^T (\mathbf{Dx} + \mathbf{d})] \\
&= \text{Tr}[\mathbf{A}\Sigma(\mathbf{C}^T \mathbf{D} + \mathbf{D}^T \mathbf{C})\Sigma \mathbf{B}^T] \\
&+ [(\mathbf{Am} + \mathbf{a})^T \mathbf{B} + (\mathbf{Bm} + \mathbf{b})^T \mathbf{A}]\Sigma[\mathbf{C}^T (\mathbf{Dm} + \mathbf{d}) + \mathbf{D}^T (\mathbf{Cm} + \mathbf{c})] \\
&+ [\text{Tr}(\mathbf{A}\Sigma \mathbf{B}^T) + (\mathbf{Am} + \mathbf{a})^T (\mathbf{Bm} + \mathbf{b})][\text{Tr}(\mathbf{C}\Sigma \mathbf{D}^T) + (\mathbf{Cm} + \mathbf{c})^T (\mathbf{Dm} + \mathbf{d})]
\end{aligned}$$

参见 [7].

### 8.2.5 矩

$$E[\mathbf{x}] = \sum_k \rho_k \mathbf{m}_k \quad (384)$$

$$\text{Cov}(\mathbf{x}) = \sum_k \sum_{k'} \rho_k \rho_{k'} (\Sigma_k + \mathbf{m}_k \mathbf{m}_k^T - \mathbf{m}_k \mathbf{m}_{k'}^T) \quad (385)$$

## 8.3 其他

### 8.3.1 白化

假设  $\mathbf{x} \sim \mathcal{N}(\mathbf{m}, \Sigma)$  那么

$$\mathbf{z} = \Sigma^{-1/2}(\mathbf{x} - \mathbf{m}) \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (386)$$

相反地, 如果  $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$  那么可以通过设置

$$\mathbf{x} = \Sigma^{1/2} \mathbf{z} + \mathbf{m} \sim \mathcal{N}(\mathbf{m}, \Sigma) \text{ 来生成数据} \quad (387)$$

注意  $\Sigma^{1/2}$  表示满足  $\Sigma^{1/2} \Sigma^{1/2} = \Sigma$  的矩阵, 它存在且唯一, 因为  $\Sigma$  是正定的。

### 8.3.2 卡方连接

假设  $\mathbf{x} \sim \mathcal{N}(\mathbf{m}, \Sigma)$  并且  $\mathbf{x}$  是  $n$  维的, 那么

$$z = (\mathbf{x} - \mathbf{m})^T \Sigma^{-1} (\mathbf{x} - \mathbf{m}) \sim \chi_n^2 \quad (388)$$

其中  $\chi^2$  和表示自由度为  $n$  的卡方分布。

### 8.3.3 熵

$D$  维高斯分布的熵

$$H(\mathbf{x}) = - \int \mathcal{N}(\mathbf{m}, \Sigma) \ln \mathcal{N}(\mathbf{m}, \Sigma) d\mathbf{x} = \ln \sqrt{\det(2\pi\Sigma)} + \frac{D}{2} \quad (389)$$

## 8.4 高斯混合模型

### 8.4.1 密度

如果变量  $\mathbf{x}$  服从高斯混合分布, 则其密度函数为

$$p(\mathbf{x}) = \sum_{k=1}^K \rho_k \frac{1}{\sqrt{\det(2\pi\Sigma_k)}} \exp \left[ -\frac{1}{2} (\mathbf{x} - \mathbf{m}_k)^T \Sigma_k^{-1} (\mathbf{x} - \mathbf{m}_k) \right] \quad (390)$$

其中  $\rho_k$  之和为 1, 且  $\Sigma_k$  都是正定的。

## 8.4.2 导数

定义  $p(\mathbf{s}) = \sum_k \rho_k \mathcal{N}_s(\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$  得到

$$\frac{\partial \ln p(\mathbf{s})}{\partial \rho_j} = \frac{\rho_j \mathcal{N}_s(\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}{\sum_k \rho_k \mathcal{N}_s(\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)} \frac{\partial}{\partial \rho_j} \ln[\rho_j \mathcal{N}_s(\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)] \quad (391)$$

$$= \frac{\rho_j \mathcal{N}_s(\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}{\sum_k \rho_k \mathcal{N}_s(\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)} \frac{1}{\rho_j} \quad (392)$$

$$\frac{\partial \ln p(\mathbf{s})}{\partial \boldsymbol{\mu}_j} = \frac{\rho_j \mathcal{N}_s(\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}{\sum_k \rho_k \mathcal{N}_s(\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)} \frac{\partial}{\partial \boldsymbol{\mu}_j} \ln[\rho_j \mathcal{N}_s(\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)] \quad (393)$$

$$= \frac{\rho_j \mathcal{N}_s(\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}{\sum_k \rho_k \mathcal{N}_s(\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)} \left[ \boldsymbol{\Sigma}_j^{-1} (\mathbf{s} - \boldsymbol{\mu}_j) \right] \quad (394)$$

$$\frac{\partial \ln p(\mathbf{s})}{\partial \boldsymbol{\Sigma}_j} = \frac{\rho_j \mathcal{N}_s(\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}{\sum_k \rho_k \mathcal{N}_s(\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)} \frac{\partial}{\partial \boldsymbol{\Sigma}_j} \ln[\rho_j \mathcal{N}_s(\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)] \quad (395)$$

$$= \frac{\rho_j \mathcal{N}_s(\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}{\sum_k \rho_k \mathcal{N}_s(\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)} \frac{1}{2} \left[ -\boldsymbol{\Sigma}_j^{-1} + \boldsymbol{\Sigma}_j^{-1} (\mathbf{s} - \boldsymbol{\mu}_j) (\mathbf{s} - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}_j^{-1} \right] \quad (396)$$

但是  $\rho_k$  和  $\boldsymbol{\Sigma}_k$  需要受到限制。

## 9个特殊矩阵

### 9.1 块矩阵

设  $\mathbf{A}_{ij}$  表示  $\mathbf{A}$  的第  $ij$  个块。

#### 9.1.1 乘法

假设块的维度匹配，我们有

$$\left[ \begin{array}{c|c} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \hline \mathbf{A}_{21} & \mathbf{A}_{22} \end{array} \right] \left[ \begin{array}{c|c} \mathbf{B}_{11} & \mathbf{B}_{12} \\ \hline \mathbf{B}_{21} & \mathbf{B}_{22} \end{array} \right] = \left[ \begin{array}{c|c} \mathbf{A}_{11}\mathbf{B}_{11} + \mathbf{A}_{12}\mathbf{B}_{21} & \mathbf{A}_{11}\mathbf{B}_{12} + \mathbf{A}_{12}\mathbf{B}_{22} \\ \hline \mathbf{A}_{21}\mathbf{B}_{11} + \mathbf{A}_{22}\mathbf{B}_{21} & \mathbf{A}_{21}\mathbf{B}_{12} + \mathbf{A}_{22}\mathbf{B}_{22} \end{array} \right]$$

#### 9.1.2 行列式

行列式可以通过以下方式表示

$$\mathbf{C}_1 = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21} \quad (397)$$

$$\mathbf{C}_2 = \mathbf{A}_{22} - \mathbf{A}_{21}\mathbf{A}_{11}^{-1}\mathbf{A}_{12} \quad (398)$$

作为

$$\text{行列式} \left( \left[ \begin{array}{c|c} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \hline \mathbf{A}_{21} & \mathbf{A}_{22} \end{array} \right] \right) = \det(\mathbf{A}_{22}) \cdot \det(\mathbf{C}_1) = \det(\mathbf{A}_{11}) \cdot \det(\mathbf{C}_2)$$

#### 9.1.3 逆矩阵

逆矩阵可以通过以下方式表示

$$\mathbf{C}_1 = \mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21} \quad (399)$$

$$\mathbf{C}_2 = \mathbf{A}_{22} - \mathbf{A}_{21}\mathbf{A}_{11}^{-1}\mathbf{A}_{12} \quad (400)$$

as

$$\begin{aligned} \left[ \begin{array}{c|c} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \hline \mathbf{A}_{21} & \mathbf{A}_{22} \end{array} \right]^{-1} &= \left[ \begin{array}{c|c} \mathbf{C}_1^{-1} & -\mathbf{A}_{11}^{-1}\mathbf{A}_{12}\mathbf{C}_2^{-1} \\ \hline -\mathbf{C}_2^{-1}\mathbf{A}_{21}\mathbf{A}_{11}^{-1} & \mathbf{C}_2^{-1} \end{array} \right] \\ &= \left[ \begin{array}{c|c} \mathbf{A}_{11}^{-1} + \mathbf{A}_{11}^{-1}\mathbf{A}_{12}\mathbf{C}_2^{-1}\mathbf{A}_{21}\mathbf{A}_{11}^{-1} & -\mathbf{C}_1^{-1}\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \hline -\mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{C}_1^{-1} & \mathbf{A}_{22}^{-1} + \mathbf{A}_{22}^{-1}\mathbf{A}_{21}\mathbf{C}_1^{-1}\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \end{array} \right] \end{aligned}$$

#### 9.1.4 块对角

对于块对角矩阵，我们有

$$\left[ \begin{array}{c|c} \mathbf{A}_{11} & \mathbf{0} \\ \hline \mathbf{0} & \mathbf{A}_{22} \end{array} \right]^{-1} = \left[ \begin{array}{c|c} (\mathbf{A}_{11})^{-1} & \mathbf{0} \\ \hline \mathbf{0} & (\mathbf{A}_{22})^{-1} \end{array} \right] \quad (401)$$

$$\text{行列式} \left( \left[ \begin{array}{c|c} \mathbf{A}_{11} & \mathbf{0} \\ \hline \mathbf{0} & \mathbf{A}_{22} \end{array} \right] \right) = \text{行列式}(\mathbf{A}_{11}) \cdot \text{行列式}(\mathbf{A}_{22}) \quad (402)$$

### 9.1.5 Schur补

将矩阵视为

$$\left[ \begin{array}{c|c} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \hline \mathbf{A}_{21} & \mathbf{A}_{22} \end{array} \right]$$

上述矩阵的块  $\mathbf{A}_{11}$  的舒尔补是矩阵（在上文中表示为  $\mathbf{C}_2$ ）

$$\mathbf{A}_{22} - \mathbf{A}_{21}\mathbf{A}_{11}^{-1}\mathbf{A}_{12}$$

上述矩阵的块  $\mathbf{A}_{22}$  的舒尔补是矩阵（在上文中表示为  $\mathbf{C}_1$ ）

$$\mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21}$$

使用舒尔补，可以重写块矩阵的逆

$$\begin{aligned} & \left[ \begin{array}{c|c} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \hline \mathbf{A}_{21} & \mathbf{A}_{22} \end{array} \right]^{-1} \\ &= \left[ \begin{array}{c|c} \mathbf{I} & \mathbf{0} \\ \hline -\mathbf{A}_{22}^{-1}\mathbf{A}_{21} & \mathbf{I} \end{array} \right] \left[ \begin{array}{c|c} (\mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21})^{-1} & \mathbf{0} \\ \hline \mathbf{0} & \mathbf{A}_{22}^{-1} \end{array} \right] \left[ \begin{array}{c|c} \mathbf{I} & -\mathbf{A}_{12}\mathbf{A}_{22}^{-1} \\ \hline \mathbf{0} & \mathbf{I} \end{array} \right] \end{aligned}$$

舒尔补在解决以下形式的线性系统时很有用

$$\left[ \begin{array}{c|c} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \hline \mathbf{A}_{21} & \mathbf{A}_{22} \end{array} \right] \begin{bmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \end{bmatrix} = \begin{bmatrix} \mathbf{b}_1 \\ \mathbf{b}_2 \end{bmatrix}$$

对于  $\mathbf{x}_1$ ，它具有以下方程

$$(\mathbf{A}_{11} - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{A}_{21})\mathbf{x}_1 = \mathbf{b}_1 - \mathbf{A}_{12}\mathbf{A}_{22}^{-1}\mathbf{b}_2$$

当适当的逆存在时，可以解出  $\mathbf{x}_1$ ，然后将其插入方程中以解出  $\mathbf{x}_2$ 。

## 9.2 离散傅里叶变换矩阵

DFT矩阵是一个  $N \times N$  对称矩阵  $\mathbf{W}_N$ ，其中  $k, n$  元素为

$$W_N^{kn} = e^{-j\frac{2\pi kn}{N}} \quad (403)$$

因此，离散傅里叶变换（DFT）可以表示为

$$X(k) = \sum_{n=0}^{N-1} x(n)W_N^{kn} \quad (404)$$

同样，逆离散傅里叶变换（IDFT）可以表示为

$$x(n) = \frac{1}{N} \sum_{k=0}^{N-1} X(k)W_N^{-kn} \quad (405)$$

向量  $\mathbf{x} = [x(0), x(1), \dots, x(N-1)]^T$  的DFT可以以矩阵形式表示

$$\mathbf{X} = \mathbf{W}_N \mathbf{x}, \quad (406)$$

其中  $\mathbf{X} = [X(0), X(1), \dots, x(N-1)]^T$ . 逆离散傅里叶变换 (IDFT) 同样给出为

$$\mathbf{x} = \mathbf{W}_N^{-1} \mathbf{X}. \quad (407)$$

一些  $\mathbf{W}_N$  的性质存在 :

$$\mathbf{W}_N^{-1} = \frac{1}{N} \mathbf{W}_N^* \quad (408)$$

$$\mathbf{W}_N \mathbf{W}_N^* = N \mathbf{I} \quad (409)$$

$$\mathbf{W}_N^* = \mathbf{W}_N^H \quad (410)$$

如果  $W_N = e^{-j2\pi}$ , 那么 [23]

$$W_N^{m+N/2} = -W_N^m \quad (411)$$

注意, 离散傅里叶变换 (DFT) 矩阵是一个范德蒙德矩阵。

循环矩阵和离散傅里叶变换 (DFT) 之间存在以下重要关系

$$\mathbf{T}_C = \mathbf{W}_N^{-1} (\mathbf{I} \circ (\mathbf{W}_N \mathbf{t})) \mathbf{W}_N, \quad (412)$$

其中  $\mathbf{t} = [t_0, t_1, \dots, t_{n-1}]^T$  是  $\mathbf{T}_C$  的第一行.

### 9.3 Hermite矩阵和skew-Hermite矩阵

一个矩阵  $\mathbf{A} \in \mathbb{C}^{m \times n}$  被称为 *Hermitian* 如果

$$\mathbf{A}^H = \mathbf{A}$$

对于实值矩阵, Hermitian和symmetric矩阵是等价的.

$$\mathbf{A} \text{ 是 Hermitian} \Leftrightarrow \mathbf{x}^H \mathbf{A} \mathbf{x} \in \mathbb{R}, \quad \forall \mathbf{x} \in \mathbb{C}^{n \times 1} \quad (413)$$

$$\mathbf{A} \text{ 是 Hermitian} \Leftrightarrow \text{eig}(\mathbf{A}) \in \mathbb{R} \quad (414)$$

注意

$$\mathbf{A} = \mathbf{B} + i\mathbf{C}$$

其中  $\mathbf{B}, \mathbf{C}$  是 Hermitian, 那么

$$\mathbf{B} = \frac{\mathbf{A} + \mathbf{A}^H}{2}, \quad \mathbf{C} = \frac{\mathbf{A} - \mathbf{A}^H}{2i}$$

#### 9.3.1 Skew-Hermitian

如果一个矩阵  $\mathbf{A}$  被称为 *skew-hermitian* 如果

$$\mathbf{A} = -\mathbf{A}^H$$

对于实值矩阵, 反厄米矩阵和反对称矩阵是等价的。

$$\mathbf{A} \text{ 厄米矩阵} \Leftrightarrow i\mathbf{A} \text{ 是反厄米矩阵} \quad (415)$$

$$\mathbf{A} \text{ 反厄米矩阵} \Leftrightarrow \mathbf{x}^H \mathbf{A} \mathbf{y} = -\mathbf{x}^H \mathbf{A}^H \mathbf{y}, \quad \forall \mathbf{x}, \mathbf{y} \quad (416)$$

$$\mathbf{A} \text{ 反厄米矩阵} \Rightarrow \text{eig}(\mathbf{A}) = i\lambda, \quad \lambda \in \mathbb{R} \quad (417)$$



### 9.4 幂等矩阵

矩阵  $A$  是幂等矩阵，如果

$$AA = A$$

幂等矩阵  $A$  和  $B$ ，具有以下性质

$$A^n = A, \quad \text{对于 } n = 1, 2, 3, \dots \quad (418)$$

$$I - A \quad \text{是幂等的} \quad (419)$$

$$A^H \quad \text{是幂等的} \quad (420)$$

$$I - A^H \quad \text{是幂等的} \quad (421)$$

$$\text{如果 } AB = BA \Rightarrow AB \text{ 是幂等的} \quad (422)$$

$$\text{rank}(A) = \text{Tr}(A) \quad (423)$$

$$A(I - A) = 0 \quad (424)$$

$$(I - A)A = 0 \quad (425)$$

$$A^+ = A \quad (426)$$

$$f(sI + tA) = (I - A)f(s) + Af(s + t) \quad (427)$$

注意  $A - I$  不一定是幂等的。

#### 9.4.1 零幂

如果矩阵  $A$  是零幂的，则

$$A^2 = 0$$

零幂矩阵具有以下性质：

$$f(sI + tA) = If(s) + tAf'(s) \quad (428)$$

#### 9.4.2 单位势

如果矩阵  $A$  是单位势的，则

$$AA = I$$

单位势矩阵具有以下性质：

$$f(sI + tA) = [(I + A)f(s + t) + (I - A)f(s - t)]/2 \quad (429)$$

### 9.5 正交矩阵

如果一个方阵  $Q$  是正交的，当且仅当，

$$Q^T Q = QQ^T = I$$

然后  $Q$  具有以下特性

- 它的特征值位于单位圆上。
- 它的特征向量是酉的，即长度为一。
- 正交矩阵的逆矩阵也是正交的。

正交矩阵  $\mathbf{Q}$  的基本性质

$$\begin{aligned}\mathbf{Q}^{-1} &= \mathbf{Q}^T \\ \mathbf{Q}^{-T} &= \mathbf{Q} \\ \mathbf{Q}\mathbf{Q}^T &= \mathbf{I} \\ \mathbf{Q}^T\mathbf{Q} &= \mathbf{I} \\ \det(\mathbf{Q}) &= \pm 1\end{aligned}$$

### 9.5.1 正交对称

一个同时正交和对称的矩阵被称为正交对称矩阵[20]。因此， $\mathbf{Q}_+^T \mathbf{Q}_+ = \mathbf{I}$

(430)

$$\mathbf{Q}_+ = \mathbf{Q}_+^T \quad (431)$$

正交对称矩阵的幂由以下规则给出

$$\mathbf{Q}_+^k = \frac{1 + (-1)^k}{2} \mathbf{I} + \frac{1 + (-1)^{k+1}}{2} \mathbf{Q}_+ \quad (432)$$

$$= \frac{1 + \cos(k\pi)}{2} \mathbf{I} + \frac{1 - \cos(k\pi)}{2} \mathbf{Q}_+ \quad (433)$$

### 9.5.2 正交斜对称

一个同时正交和反对称的矩阵被称为正交斜对称矩阵[20]。因此， $\mathbf{Q}_-^H \mathbf{Q}_- = \mathbf{I}$

(434)

$$\mathbf{Q}_- = -\mathbf{Q}_-^H \quad (435)$$

正交斜对称矩阵的幂由以下规则给出

$$\mathbf{Q}_-^k = \frac{i^k + (-i)^k}{2} \mathbf{I} - i \frac{i^k - (-i)^k}{2} \mathbf{Q}_- \quad (436)$$

$$= \cos(k \frac{\pi}{2}) \mathbf{I} + \sin(k \frac{\pi}{2}) \mathbf{Q}_- \quad (437)$$

### 9.5.3 分解

一个方阵  $\mathbf{A}$  总是可以写成一个对称矩阵  $\mathbf{A}_+$  和一个反对称矩阵  $\mathbf{A}_-$  的和

$$\mathbf{A} = \mathbf{A}_+ + \mathbf{A}_- \quad (438)$$

## 9.6 正定和半正定矩阵

### 9.6.1 定义

矩阵  $\mathbf{A}$  是正定的当且仅当

$$\mathbf{x}^T \mathbf{A} \mathbf{x} > 0, \quad \forall \mathbf{x} \neq \mathbf{0} \quad (439)$$

矩阵  $\mathbf{A}$  是半正定的当且仅当

$$\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0, \quad \forall \mathbf{x} \quad (440)$$

注意，如果  $\mathbf{A}$  是正定的，则  $\mathbf{A}$  也是半正定的。

### 9.6.2 特征值

以下关于特征值成立：

$$\begin{aligned} \mathbf{A} \text{ 正定} & \Leftrightarrow \text{特征值 } \left(\frac{\mathbf{A} + \mathbf{A}^H}{2}\right) > 0 \\ \mathbf{A} \text{ 半正定} & \Leftrightarrow \text{特征值 } \left(\frac{\mathbf{A} + \mathbf{A}^H}{2}\right) \geq 0 \end{aligned} \quad (441)$$

### 9.6.3 迹

以下关于迹成立：

$$\begin{aligned} \mathbf{A} \text{ 正定} & \Rightarrow \text{Tr}(\mathbf{A}) > 0 \\ \mathbf{A} \text{ 半正定} & \Rightarrow \text{Tr}(\mathbf{A}) \geq 0 \end{aligned} \quad (442)$$

### 9.6.4 逆

如果  $\mathbf{A}$  是正定的，则  $\mathbf{A}$  可逆且  $\mathbf{A}^{-1}$  也是正定的。

### 9.6.5 对角线

如果  $\mathbf{A}$  是正定的，则  $A_{ii} > 0, \forall i$

### 9.6.6 分解 I

矩阵  $\mathbf{A}$  是秩为  $r$  的半正定矩阵  $\Leftrightarrow$  存在一个秩为  $r$  的矩阵  $\mathbf{B}$  使得  $\mathbf{A} = \mathbf{B}\mathbf{B}^T$

矩阵  $\mathbf{A}$  是正定的  $\Leftrightarrow$  存在可逆矩阵  $\mathbf{B}$  使得  $\mathbf{A} = \mathbf{B}\mathbf{B}^T$

### 9.6.7 分解 II

假设  $\mathbf{A}$  是一个  $n \times n$  半正定矩阵，那么存在一个  $n \times r$  秩为  $r$  的矩阵  $\mathbf{B}$  使得  $\mathbf{B}^T \mathbf{A} \mathbf{B} = \mathbf{I}$ .

### 9.6.8 零方程

假设  $\mathbf{A}$  是半正定的，那么  $\mathbf{X}^T \mathbf{A} \mathbf{X} = 0 \Rightarrow \mathbf{A} \mathbf{X} = 0$

### 9.6.9 乘积的秩

假设  $\mathbf{A}$  是正定的，那么  $\text{rank}(\mathbf{B}\mathbf{A}\mathbf{B}^T) = \text{rank}(\mathbf{B})$

### 9.6.10 正定性

如果  $\mathbf{A}$  是一个  $n \times n$  正定矩阵， $\mathbf{B}$  是一个  $r \times n$  秩为  $r$  的矩阵，那么  $\mathbf{B}\mathbf{A}\mathbf{B}^T$  是正定的。

### 9.6.11 外积

如果  $\mathbf{X}$  是一个  $n \times r$  的矩阵，其中  $n \leq r$  且  $\text{rank}(\mathbf{X}) = n$ ，则  $\mathbf{X}\mathbf{X}^T$  是正定的。

## 9.6.12 小扰动

如果  $\mathbf{A}$  是正定的且  $\mathbf{B}$  是对称的, 则对于足够小的  $t$ ,  $\mathbf{A} - t\mathbf{B}$  是正定的。

## 9.6.13 Hadamard不等式

如果  $\mathbf{A}$  是一个正定或半正定矩阵, 则

$$\det(\mathbf{A}) \leq \prod_i A_{ii}$$

参见[15, pp.477]

## 9.6.14 Hadamard乘积关系

假设  $\mathbf{P} = \mathbf{A}\mathbf{A}^T$  和  $\mathbf{Q} = \mathbf{B}\mathbf{B}^T$  是半正定矩阵, 则有

$$\mathbf{P} \circ \mathbf{Q} = \mathbf{R}\mathbf{R}^T$$

其中  $\mathbf{R}$  的列按以下方式构造:  $\mathbf{r}_{i+(j-1)N}$   $\mathbf{A}$  是一个  $i$  一个  $j$ , 对于  $i = 1, 2, \dots, N_A$  和  $j = 1, 2, \dots, N_B$ 。结果尚未发表, 但由 Pavel Sakov 和 Craig Bishop 报道。

## 9.7 单入口矩阵

## 9.7.1 定义

单元素矩阵  $\mathbf{J}^{ij} \in \mathbb{R}^{n \times n}$  被定义为除了在  $(i, j)$  处为 1 之外, 其他地方都为零的矩阵。在一个  $4 \times 4$  的例子中, 可能会有

$$\mathbf{J}^{23} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} \quad (443)$$

当处理涉及矩阵的表达式的导数时, 单元素矩阵非常有用。

## 9.7.2 交换和零

假设  $\mathbf{A}$  为  $n \times m$ ,  $\mathbf{J}^{ij}$  为  $m \times p$

$$\mathbf{A}\mathbf{J}^{ij} = \begin{bmatrix} \mathbf{0} & \mathbf{0} & \dots & \mathbf{A}_i & \dots & \mathbf{0} \end{bmatrix} \quad (444)$$

即一个零矩阵, 其中第  $i$  列用  $\mathbf{A}$  的第  $j$  列代替。假设  $\mathbf{A}$  是一个  $n \times m$  的矩阵,  $\mathbf{J}^{ij}$  是一个  $p \times n$  的矩阵

$$\mathbf{J}^{ij}\mathbf{A} = \begin{bmatrix} \mathbf{0} \\ \vdots \\ \mathbf{0} \\ \mathbf{A}_j \\ \mathbf{0} \\ \vdots \\ \mathbf{0} \end{bmatrix} \quad (445)$$

即一个  $p \times m$  的零矩阵, 其中第  $j$  行用  $A$  的第  $i$  行代替。

### 9.7.3 重写元素的乘积

$$A_{ki}B_{jl} = (A \text{ 的第 } i \text{ 行乘以 } B \text{ 的第 } j \text{ 列}) \text{ 的第 } kl \text{ 个元素} = (AJ^{ij}B) \text{ 的第 } kl \text{ 个元素} \quad (446)$$

$$A_{ik}B_{lj} = (A \text{ 的第 } i \text{ 行乘以 } B \text{ 的第 } j \text{ 列的转置}) \text{ 的第 } kl \text{ 个元素} = (A \text{ 的转置 } J^{ij}B) \text{ 的} \quad (447)$$

$$A_{ik}B_{jl} = (A \text{ 的第 } i \text{ 行乘以 } B \text{ 的第 } j \text{ 列}) \text{ 的第 } kl \text{ 个元素} = (A \text{ 的转置 } J^{ij}B) \quad (448)$$

$$A_{ki}B_{lj} = (Ae_i e_j^T B^T)_{kl} = (AJ^{ij}B^T)_{kl} \quad (449)$$

### 9.7.4 单元素矩阵的性质

If  $i = j$

$$J^{ij}J^{ij} = J^{ij} \quad (J^{ij})^T(J^{ij})^T = J^{ij}$$

$$J^{ij}(J^{ij})^T = J^{ij} \quad (J^{ij})^T J^{ij} = J^{ij}$$

If  $i \neq j$

$$J^{ij}J^{ij} = 0 \quad (J^{ij})^T(J^{ij})^T = 0$$

$$J^{ij}(J^{ij})^T = J^{ii} \quad (J^{ij})^T J^{ij} = J^{jj}$$

### 9.7.5 标量表达式中的单元素矩阵

假设  $A$  是  $n \times m$  的矩阵,  $J$  是  $m \times n$  的矩阵, 则

$$\text{Tr}(AJ^{ij}) = \text{Tr}(J^{ij}A) = (A^T)_{ij} \quad (450)$$

假设  $A$  是  $n \times n$  的矩阵,  $J$  是  $n \times m$  的矩阵,  $B$  是  $m \times n$  的矩阵, 那么

$$\text{Tr}(AJ^{ij}B) = (A^T B^T)_{ij} \quad (451)$$

$$\text{Tr}(AJ^{ji}B) = (BA)_{ij} \quad (452)$$

$$\text{Tr}(AJ^{ij}J^{ij}B) = \text{diag}(A^T B^T)_{ij} \quad (453)$$

假设  $A$  是  $n \times n$  的矩阵,  $J^{ij}$  是  $n \times m$  的矩阵,  $B$  是  $m \times n$  的矩阵, 那么

$$\mathbf{x}^T A J^{ij} B \mathbf{x} = (A^T \mathbf{x} \mathbf{x}^T B^T)_{ij} \quad (454)$$

$$\mathbf{x}^T A J^{ij} J^{ij} B \mathbf{x} = \text{diag}(A^T \mathbf{x} \mathbf{x}^T B^T)_{ij} \quad (455)$$

### 9.7.6 结构矩阵

结构矩阵的定义如下

$$\frac{\partial A}{\partial A_{ij}} = S^{ij} \quad (456)$$

如果  $A$  没有特殊结构, 则

$$S^{ij} = J^{ij} \quad (457)$$

如果  $A$  是对称的

$$S^{ij} = J^{ij} + J^{ji} - J^{ij}J^{ij} \quad (458)$$

## 9.8 对称矩阵，反对称矩阵

### 9.8.1 对称矩阵

如果矩阵  $\mathbf{A}$  是对称的

$$\mathbf{A} = \mathbf{A}^T \quad (459)$$

对称矩阵具有许多重要的性质，例如它们的特征值是实数，特征向量正交。

### 9.8.2 反对称矩阵/斜对称矩阵

反对称矩阵也被称为斜对称矩阵。它具有以下定义的属性

$$\mathbf{A} = -\mathbf{A}^T \quad (460)$$

由此可见，反对称矩阵的对角线始终为零。 $n \times n$  的反对称矩阵还具有以下属性。

$$\det(\mathbf{A}^T) = \det(-\mathbf{A}) = (-1)^n \det(\mathbf{A}) \quad (461)$$

$$-\det(\mathbf{A}) = \det(-\mathbf{A}) = 0, \quad \text{if } n \text{ is odd} \quad (462)$$

反对称矩阵的特征值位于虚轴上，而特征向量是酉的。

### 9.8.3 分解

一个方阵  $\mathbf{A}$  总是可以写成一个对称矩阵  $\mathbf{A}_+$  和一个反对称矩阵  $\mathbf{A}_-$  的和

$$\mathbf{A} = \mathbf{A}_+ + \mathbf{A}_- \quad (463)$$

这样的分解可以是

$$\mathbf{A} = \frac{\mathbf{A} + \mathbf{A}^T}{2} + \frac{\mathbf{A} - \mathbf{A}^T}{2} = \mathbf{A}_+ + \mathbf{A}_- \quad (464)$$

## 9.9 Toeplitz 矩阵

Toeplitz 矩阵  $\mathbf{T}$  是一种每个对角线上的元素都相同的矩阵。在方阵的情况下，它具有以下结构：

$$\mathbf{T} = \begin{bmatrix} t_{11} & t_{12} & \cdots & t_{1n} \\ t_{21} & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & t_{12} \\ t_{n1} & \cdots & t_{21} & t_{11} \end{bmatrix} = \begin{bmatrix} t_0 & t_1 & \cdots & t_{n-1} \\ t_{-1} & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & t_1 \\ t_{-(n-1)} & \cdots & t_{-1} & t_0 \end{bmatrix} \quad (465)$$

一个 Toeplitz 矩阵是对称的。如果一个矩阵是对称的（或正交对称的），这意味着该矩阵关于其东北-西南对角线（反对角线）对称[12]。对称矩阵是更大的矩阵类别，因为对称矩阵不一定具有 Toeplitz 结构。这

是一些特殊情况的Toeplitz矩阵。对称Toeplitz矩阵的表示为：

$$\mathbf{T} = \begin{bmatrix} t_0 & t_1 & \cdots & t_{n-1} \\ t_1 & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & t_1 \\ t_{n-1} & \cdots & t_1 & t_0 \end{bmatrix} \quad (466)$$

循环Toeplitz矩阵：

$$\mathbf{T}_C = \begin{bmatrix} t_0 & t_1 & \cdots & t_{n-1} \\ t_{n-1} & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & t_1 \\ t_1 & \cdots & t_{n-1} & t_0 \end{bmatrix} \quad (467)$$

上三角Toeplitz矩阵：

$$\mathbf{T}_U = \begin{bmatrix} t_0 & t_1 & \cdots & t_{n-1} \\ 0 & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & t_1 \\ 0 & \cdots & 0 & t_0 \end{bmatrix}, \quad (468)$$

和下三角Toeplitz矩阵：

$$\mathbf{T}_L = \begin{bmatrix} t_0 & 0 & \cdots & 0 \\ t_{-1} & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ t_{-(n-1)} & \cdots & t_{-1} & t_0 \end{bmatrix} \quad (469)$$

### 9.9.1 Toeplitz矩阵的性质

Toeplitz矩阵具有一些计算优势。两个Toeplitz矩阵的加法可以在  $\mathcal{O}(n)$  次浮点运算中完成，两个Toeplitz矩阵的乘法可以在  $\mathcal{O}(n \ln n)$  次浮点运算中完成。Toeplitz方程组可以在  $\mathcal{O}(n^2)$  次浮点运算中求解。正定Toeplitz矩阵的逆矩阵也可以在  $\mathcal{O}(n^2)$  次浮点运算中找到。Toeplitz矩阵的逆矩阵是对称的。两个下三角Toeplitz矩阵的乘积是一个Toeplitz矩阵。有关Toeplitz矩阵和循环矩阵的更多信息可以在[13, 7]中找到。

## 9.10 过渡矩阵

一个方阵  $\mathbf{P}$  是一个过渡矩阵，也被称为随机矩阵或概率矩阵，如果

$$0 \leq (\mathbf{P})_{ij} \leq 1, \quad \sum_j (\mathbf{P})_{ij} = 1$$

过渡矩阵通常描述了从状态  $i$  到状态  $j$  在一步中移动的概率，并且与马尔可夫过程密切相关。过渡矩阵

具有以下属性

$$\text{Prob}[i \rightarrow j \text{ 在1步中}] = (\mathbf{P})_{ij} \quad (470)$$

$$\text{Prob}[i \rightarrow j \text{ 在2步中}] = (\mathbf{P}^2)_{ij} \quad (471)$$

$$\text{Prob}[i \rightarrow j \text{ 在 } k \text{ 步中}] = (\mathbf{P}^k)_{ij} \quad (472)$$

$$\text{如果所有行都相同} \Rightarrow \mathbf{P}^n = \mathbf{P} \quad (473)$$

$$\alpha \mathbf{P} = \alpha, \quad \alpha \text{ 被称为不变} \quad (474)$$

其中  $\alpha$  是所谓的稳态概率向量, 即  $0 \leq \alpha_i \leq 1$  和  $\sum_i \alpha_i = 1$ .

## 9.11 单位矩阵, 排列和移位

### 9.11.1 单位向量

设  $\mathbf{e}_i \in \mathbb{R}^{n \times 1}$  为第  $i$  个单位向量, 即在所有条目中都为零, 除了第  $i$  个条目为1。

### 9.11.2 行和列

$$\mathbf{A} \text{ 的第 } i \text{ 行} = \mathbf{e}_i^T \mathbf{A} \quad (475)$$

$$\mathbf{A} \text{ 的第 } j \text{ 列} = \mathbf{A} \mathbf{e}_j \quad (476)$$

### 9.11.3 排列

设  $\mathbf{P}$  为某个排列矩阵, 例如

$$\mathbf{P} = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} \mathbf{e}_2 & \mathbf{e}_1 & \mathbf{e}_3 \end{bmatrix} = \begin{bmatrix} \mathbf{e}_2^T \\ \mathbf{e}_1^T \\ \mathbf{e}_3^T \end{bmatrix} \mathbf{A} \quad (477)$$

对于排列矩阵, 有以下性质

$$\mathbf{P} \mathbf{P}^T = \mathbf{I} \quad (478)$$

以及

$$\mathbf{A} \mathbf{P} = \begin{bmatrix} \mathbf{A} \mathbf{e}_2 & \mathbf{A} \mathbf{e}_1 & \mathbf{A} \mathbf{e}_3 \end{bmatrix} \quad \mathbf{P} \mathbf{A} = \begin{bmatrix} \mathbf{e}_2^T \mathbf{A} \\ \mathbf{e}_1^T \mathbf{A} \\ \mathbf{e}_3^T \mathbf{A} \end{bmatrix} \quad (479)$$

也就是说, 第一个矩阵的列是  $\mathbf{A}$  的列按照排列顺序排列, 而第二个矩阵的行是  $\mathbf{A}$  的行按照排列顺序排列。

### 9.11.4 平移、移动或滞后算子

设  $\mathbf{L}$  表示  $4 \times 4$

示例中定义的滞后 (或 “平移” 或 “移动”) 算子

$$\mathbf{L} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \quad (480)$$



即一个零矩阵，其次对角线上为1， $(\mathbf{L})_{ij} = \delta_{i,j+1}$ 。对于一些信号  $x_t$ ，其中  $t=1, \dots, N$ ，滞后算子的 $n$ 次幂会改变索引，即

$$(\mathbf{L}^n \mathbf{x})_t = \begin{cases} 0 & \text{对于 } t=1, \dots, n \\ \text{对于 } t=n+1, \dots, N, \text{ 滞后算子的 } n \text{ 次幂会将索引向后移动 } n \text{ 个位置} \end{cases} \quad (481)$$

一个相关但略有不同的矩阵是在4x4示例中定义的“循环平移”算子

$$\hat{\mathbf{L}} = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \quad (482)$$

即一个矩阵，其定义为 $(\hat{\mathbf{L}})_{ij} = \delta_{i,j+1} + \delta_{i,1}\delta_{j,dim(\mathbf{L})}$ 。对于一个信号  $\mathbf{x}$ ，它的作用是

$$(\hat{\mathbf{L}}^n \mathbf{x})_t = x_{t'}, \quad t' = [(t-n) \bmod N] + 1 \quad (483) \text{ 也就是}$$

说， $\hat{\mathbf{L}}$ 就像移位运算符  $\mathbf{L}$ 一样，只是它将信号“包裹”起来，就像周期性地移动（用信号的末尾替换零值）。

请注意， $\hat{\mathbf{L}}$ 是可逆的和正交的，即

$$\hat{\mathbf{L}}^{-1} = \hat{\mathbf{L}}^T \quad (484)$$

## 9.12 Vandermonde矩阵

Vandermonde矩阵的形式为[15]

$$\mathbf{V} = \begin{bmatrix} 1 & v_1 & v_1^2 & \dots & v_1^{n-1} \\ 1 & v_2 & v_2^2 & \dots & v_2^{n-1} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & v_n & v_n^2 & \dots & v_n^{n-1} \end{bmatrix}. \quad (485)$$

$\mathbf{V}$ 的转置也被称为范德蒙德矩阵。行列式由[29]给出

$$\det \mathbf{V} = \prod_{i>j} (v_i - v_j) \quad (486)$$

## 10 函数和运算符

### 10.1 函数和级数

#### 10.1.1 有限级数

$$(\mathbf{X}^n - \mathbf{I})(\mathbf{X} - \mathbf{I})^{-1} = \mathbf{I} + \mathbf{X} + \mathbf{X}^2 + \dots + \mathbf{X}^{n-1} \quad (487)$$

#### 10.1.2 标量函数的泰勒展开

考虑一些以向量  $\mathbf{x}$  为参数的标量函数  $f(\mathbf{x})$ 。

我们可以围绕  $\mathbf{x}_0$  进行泰勒展开

$$f(\mathbf{x}) \cong f(\mathbf{x}_0) + \mathbf{g}(\mathbf{x}_0)^T (\mathbf{x} - \mathbf{x}_0) + \frac{1}{2} (\mathbf{x} - \mathbf{x}_0)^T \mathbf{H}(\mathbf{x}_0) (\mathbf{x} - \mathbf{x}_0) \quad (488)$$

哪里

$$\mathbf{g}(\mathbf{x}_0) = \left. \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} \right|_{\mathbf{x}_0} \quad \mathbf{H}(\mathbf{x}_0) = \left. \frac{\partial^2 f(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T} \right|_{\mathbf{x}_0}$$

#### 10.1.3 无穷级数矩阵函数

对于一维解析函数，可以通过无穷级数为方阵  $\mathbf{X}$  定义一个矩阵函数

$$\mathbf{f}(\mathbf{X}) = \sum_{n=0}^{\infty} c_n \mathbf{X}^n \quad (489)$$

假设极限存在且有限。如果系数  $c_n$  满足  $\sum_{n=0}^{\infty} c_n x^n < \infty$ ，则可以证明上述级数存在且有限，参见[1]。因此，对于任何解析函数  $f(x)$ ，都存在一个相应的矩阵函数  $\mathbf{f}(\mathbf{x})$  通过泰勒展开构造。利用这一点，可以证明以下结果：

1) 矩阵  $\mathbf{A}$  是其特征多项式的零点[1]：

$$p(\lambda) = \det(\mathbf{I}\lambda - \mathbf{A}) = \sum_n c_n \lambda^n \quad \Rightarrow \quad p(\mathbf{A}) = \mathbf{0} \quad (490)$$

2) 如果  $\mathbf{A}$  是方阵，则成立 [1]

$$\mathbf{A} = \mathbf{U}\mathbf{B}\mathbf{U}^{-1} \quad \Rightarrow \quad \mathbf{f}(\mathbf{A}) = \mathbf{U}\mathbf{f}(\mathbf{B})\mathbf{U}^{-1} \quad (491)$$

3) 在使用幂级数时，一个有用的事实是

$$\mathbf{A}^n \rightarrow \mathbf{0} \text{ 当 } n \rightarrow \infty \quad \text{if} \quad |\mathbf{A}| < 1 \quad (492)$$

#### 10.1.4 身份和交换

对于一个解析矩阵函数  $\mathbf{f}(\mathbf{X})$ ，有以下关系成立

$$\mathbf{f}(\mathbf{A}\mathbf{B})\mathbf{A} = \mathbf{A}\mathbf{f}(\mathbf{B}\mathbf{A}) \quad (493)$$

参见 B.1.2 以获取证明。

## 10.1.5 指数矩阵函数

类似于普通标量指数函数，可以定义指数和对数矩阵函数：

$$e^{\mathbf{A}} \equiv \sum_{n=0}^{\infty} \frac{1}{n!} \mathbf{A}^n = \mathbf{I} + \mathbf{A} + \frac{1}{2} \mathbf{A}^2 + \dots \quad (494)$$

$$e^{-\mathbf{A}} \equiv \sum_{n=0}^{\infty} \frac{1}{n!} (-1)^n \mathbf{A}^n = \mathbf{I} - \mathbf{A} + \frac{1}{2} \mathbf{A}^2 - \dots \quad (495)$$

$$e^{t\mathbf{A}} \equiv \sum_{n=0}^{\infty} \frac{1}{n!} (t\mathbf{A})^n = \mathbf{I} + t\mathbf{A} + \frac{1}{2} t^2 \mathbf{A}^2 + \dots \quad (496)$$

$$\ln(\mathbf{I} + \mathbf{A}) \equiv \sum_{n=1}^{\infty} \frac{(-1)^{n-1}}{n} \mathbf{A}^n = \mathbf{A} - \frac{1}{2} \mathbf{A}^2 + \frac{1}{3} \mathbf{A}^3 - \dots \quad (497)$$

指数函数的一些性质[1]

$$e^{\mathbf{A}} e^{\mathbf{B}} = e^{\mathbf{A}+\mathbf{B}} \quad \text{if} \quad \mathbf{AB} = \mathbf{BA} \quad (498)$$

$$(e^{\mathbf{A}})^{-1} = e^{-\mathbf{A}} \quad (499)$$

$$\frac{d}{dt} e^{t\mathbf{A}} = \mathbf{A} e^{t\mathbf{A}} = e^{t\mathbf{A}} \mathbf{A}, \quad t \in \mathbb{R} \quad (500)$$

$$\frac{d}{dt} \text{Tr}(e^{t\mathbf{A}}) = \text{Tr}(\mathbf{A} e^{t\mathbf{A}}) \quad (501)$$

$$\det(e^{\mathbf{A}}) = e^{\text{Tr}(\mathbf{A})} \quad (502)$$

## 10.1.6 三角函数

$$\sin(\mathbf{A}) \equiv \sum_{n=0}^{\infty} \frac{(-1)^n \mathbf{A}^{2n+1}}{(2n+1)!} = \mathbf{A} - \frac{1}{3!} \mathbf{A}^3 + \frac{1}{5!} \mathbf{A}^5 - \dots \quad (503)$$

$$\cos(\mathbf{A}) \equiv \sum_{n=0}^{\infty} \frac{(-1)^n \mathbf{A}^{2n}}{(2n)!} = \mathbf{I} - \frac{1}{2!} \mathbf{A}^2 + \frac{1}{4!} \mathbf{A}^4 - \dots \quad (504)$$

## 10.2 Kronecker和Vec运算符

## 10.2.1 克罗内克积

一个  $m \times n$  矩阵  $\mathbf{A}$  和一个  $r \times q$  矩阵  $\mathbf{B}$  的克罗内克积是一个  $mr \times nq$  矩阵， $\mathbf{A} \otimes \mathbf{B}$  定义为

$$\mathbf{A} \otimes \mathbf{B} = \begin{bmatrix} A_{11}\mathbf{B} & A_{12}\mathbf{B} & \dots & A_{1n}\mathbf{B} \\ A_{21}\mathbf{B} & A_{22}\mathbf{B} & \dots & A_{2n}\mathbf{B} \\ \vdots & & & \vdots \\ A_{m1}\mathbf{B} & A_{m2}\mathbf{B} & \dots & A_{mn}\mathbf{B} \end{bmatrix} \quad (505)$$

克罗内克积具有以下性质 (见[19])

$$\mathbf{A} \otimes (\mathbf{B} + \mathbf{C}) = \mathbf{A} \otimes \mathbf{B} + \mathbf{A} \otimes \mathbf{C} \quad (506)$$

$$\mathbf{A} \otimes \mathbf{B} = \mathbf{B} \otimes \mathbf{A} \quad \text{一般来说} \quad (507)$$

$$\mathbf{A} \otimes (\mathbf{B} \otimes \mathbf{C}) = (\mathbf{A} \otimes \mathbf{B}) \otimes \mathbf{C} \quad (508)$$

$$(\alpha_A \mathbf{A} \otimes \alpha_B \mathbf{B}) = \alpha_A \alpha_B (\mathbf{A} \otimes \mathbf{B}) \quad (509)$$

$$(\mathbf{A} \otimes \mathbf{B})^T = \mathbf{A}^T \otimes \mathbf{B}^T \quad (510)$$

$$(\mathbf{A} \otimes \mathbf{B})(\mathbf{C} \otimes \mathbf{D}) = \mathbf{AC} \otimes \mathbf{BD} \quad (511)$$

$$(\mathbf{A} \otimes \mathbf{B})^{-1} = \mathbf{A}^{-1} \otimes \mathbf{B}^{-1} \quad (512)$$

$$(\mathbf{A} \otimes \mathbf{B})^+ = \mathbf{A}^+ \otimes \mathbf{B}^+ \quad (513)$$

$$\text{rank}(\mathbf{A} \otimes \mathbf{B}) = \text{rank}(\mathbf{A})\text{rank}(\mathbf{B}) \quad (514)$$

$$\text{Tr}(\mathbf{A} \otimes \mathbf{B}) = \text{Tr}(\mathbf{A})\text{Tr}(\mathbf{B}) = \text{Tr}(\mathbf{\Lambda}_A \otimes \mathbf{\Lambda}_B) \quad (515)$$

$$\det(\mathbf{A} \otimes \mathbf{B}) = \det(\mathbf{A})^{\text{rank}(\mathbf{B})} \det(\mathbf{B})^{\text{rank}(\mathbf{A})} \quad (516)$$

$$\{\text{eig}(\mathbf{A} \otimes \mathbf{B})\} = \{\text{eig}(\mathbf{B} \otimes \mathbf{A})\} \quad \text{如果 } \mathbf{A}, \mathbf{B} \text{ 是方阵} \quad (517)$$

$$\{\text{eig}(\mathbf{A} \otimes \mathbf{B})\} = \{\text{eig}(\mathbf{A})\text{eig}(\mathbf{B})^T\} \quad (518)$$

如果  $\mathbf{A}, \mathbf{B}$  是对称的方阵

$$\text{eig}(\mathbf{A} \otimes \mathbf{B}) = \text{eig}(\mathbf{A}) \otimes \text{eig}(\mathbf{B}) \quad (519)$$

其中  $\{\lambda_i\}$  表示值  $\lambda_i$  的集合, 即无特定顺序或结构的值,  $\mathbf{\Lambda}_A$  表示具有特征值的对角矩阵

$\mathbf{A}$ 。

### 10.2.2 向量运算符

向量运算符应用于矩阵  $\mathbf{A}$  将列堆叠成向量, 即对于一个  $2 \times 2$  的矩阵

$$\mathbf{A} = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \quad \text{vec}(\mathbf{A}) = \begin{bmatrix} A_{11} \\ A_{21} \\ A_{12} \\ A_{22} \end{bmatrix}$$

向量运算符的性质包括 (参见[19])

$$\text{vec}(\mathbf{AXB}) = (\mathbf{B}^T \otimes \mathbf{A})\text{vec}(\mathbf{X}) \quad (520)$$

$$\text{Tr}(\mathbf{A}^T \mathbf{B}) = \text{vec}(\mathbf{A})^T \text{vec}(\mathbf{B}) \quad (521)$$

$$\text{vec}(\mathbf{A} + \mathbf{B}) = \text{vec}(\mathbf{A}) + \text{vec}(\mathbf{B}) \quad (522)$$

$$\text{vec}(\alpha \mathbf{A}) = \alpha \cdot \text{vec}(\mathbf{A}) \quad (523)$$

$$\mathbf{a}^T \mathbf{X} \mathbf{B} \mathbf{X}^T \mathbf{c} = \text{vec}(\mathbf{X})^T (\mathbf{B} \otimes \mathbf{ca}^T) \text{vec}(\mathbf{X}) \quad (524)$$

参见 B.1.1 以证明等式 524。

### 10.3 向量范数

#### 10.3.1 例子

$$\|\mathbf{x}\|_1 = \sum_i |x_i| \quad (525)$$

$$\|\mathbf{x}\|_2^2 = \mathbf{x}^H \mathbf{x} \quad (526)$$

$$\|\mathbf{x}\|_p = \left[ \sum_i |x_i|^p \right]^{1/p} \quad (527)$$

$$\|\mathbf{x}\|_\infty = \max_i |x_i| \quad (528)$$

进一步阅读，例如 [12, p. 52]

### 10.4 矩阵范数

#### 10.4.1 定义

矩阵范数是一个满足

$$\|\mathbf{A}\| \geq 0 \text{ 的映射} \quad (529)$$

$$\|\mathbf{A}\| = 0 \Leftrightarrow \mathbf{A} = \mathbf{0} \quad (530)$$

$$\|c\mathbf{A}\| = |c|\|\mathbf{A}\|, \quad c \in \mathbb{R} \quad (531)$$

$$\|\mathbf{A} + \mathbf{B}\| \leq \|\mathbf{A}\| + \|\mathbf{B}\| \quad (532)$$

#### 10.4.2 引导范数或算子范数

引导范数是由向量范数引导的矩阵范数，由以下公式定义

$$\|\mathbf{A}\| = \sup\{\|\mathbf{A}\mathbf{x}\| \mid \|\mathbf{x}\| = 1\} \quad (533)$$

左边的 $\|\cdot\|$ 表示引导矩阵范数，而右边的 $\|\cdot\|$ 表示向量范数。对于引导范数，有 $\|\mathbf{I}\| = 1$

$$(534)$$

$$\|\mathbf{A}\mathbf{x}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{x}\|, \quad \text{对于所有 } \mathbf{A}, \mathbf{x} \quad (535)$$

$$\|\mathbf{A}\mathbf{B}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{B}\|, \quad \text{对于所有 } \mathbf{A}, \mathbf{B} \quad (536)$$

#### 10.4.3 例子

$$\|\mathbf{A}\|_1 = \max_j \sum_i |A_{ij}| \quad (537)$$

$$\|\mathbf{A}\|_2 = \sqrt{\max \text{eig}(\mathbf{A}^H \mathbf{A})} \quad (538)$$

$$\|\mathbf{A}\|_p = \left( \max_{\|\mathbf{x}\|_p=1} \|\mathbf{A}\mathbf{x}\|_p \right)^{1/p} \quad (539)$$

$$\|\mathbf{A}\|_\infty = \max_i \sum_j |A_{ij}| \quad (540)$$

$$\|\mathbf{A}\|_F = \sqrt{\sum_{ij} |A_{ij}|^2} = \sqrt{\text{Tr}(\mathbf{A}\mathbf{A}^H)} \quad (\text{Frobenius}) \quad (541)$$

$$\|\mathbf{A}\|_{\max} = \max_{ij} |A_{ij}| \quad (542)$$

$$\|\mathbf{A}\|_{\text{KF}} = \|\text{sing}(\mathbf{A})\|_1 \quad (\text{Ky Fan}) \quad (543)$$

其中  $\text{sing}(\mathbf{A})$  是矩阵  $\mathbf{A}$  的奇异值向量。

#### 10.4.4 不等式

E. H. Rasmussen 在尚未发表的资料中推导和收集了以下不等式。它们被整理在下表中，假设  $\mathbf{A}$  是一个  $m \times n$  的矩阵， $d = \text{rank}(\mathbf{A})$

	$\ \mathbf{A}\ _{\text{最大值}}$	$\ \mathbf{A}\ _1$ 范数	$\ \mathbf{A}\ _{\text{无穷范数}}$	$\ \mathbf{A}\ _2$ 范数	$\ \mathbf{A}\ _F$ 范数	$\ \mathbf{A}\ _{\text{KF}}$ 范数
$\ \mathbf{A}\ _{\text{最大值}}$		1	1	1	1	1
$\ \mathbf{A}\ _1$	$m$		$m$	$\sqrt{\frac{m}{n}}$	$\sqrt{\frac{m}{n}}$	$\sqrt{\frac{m}{n}}$
$\ \mathbf{A}\ _{\text{无穷范数}}$	$n$	$\sqrt{\frac{n}{m}}$		$\sqrt{\frac{n}{m}}$	$\sqrt{\frac{n}{m}}$	$\sqrt{\frac{n}{m}}$
$\ \mathbf{A}\ _2$ 范数	$\sqrt{\frac{m}{n}}$	$\sqrt{\frac{n}{m}}$	$\sqrt{\frac{m}{n}}$		1	1
$\ \mathbf{A}\ _F$	$\sqrt{\frac{m}{n}}$	$\sqrt{\frac{n}{m}}$	$\sqrt{\frac{m}{n}}$	$\sqrt{d}$		1
$\ \mathbf{A}\ _{\text{KF}}$ 范数	$\sqrt{\frac{m}{n}}$	$\sqrt{\frac{n}{m}}$	$\sqrt{\frac{m}{n}}$	$d$	$\sqrt{d}$	

这些应该被理解为，例如

$$\|\mathbf{A}\|_2 \leq \sqrt{\frac{m}{n}} \cdot \|\mathbf{A}\|_{\text{无穷范数}} \quad (544)$$

#### 10.4.5 条件数

矩阵  $\mathbf{A}$  的2范数等于  $\sqrt{\max(\text{eig}(\mathbf{A}^T \mathbf{A}))}$  [12, p.57]。对于对称的、正定的矩阵，这可以简化为  $\max(\text{eig}(\mathbf{A}))$  基于2范数的条件数因此简化为

$$\|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2 = \max(\text{eig}(\mathbf{A})) \max(\text{eig}(\mathbf{A}^{-1})) = \frac{\max(\text{eig}(\mathbf{A}))}{\min(\text{eig}(\mathbf{A}))}. \quad (545)$$

### 10.5 秩

#### 10.5.1 斯尔维斯特不等式

如果  $\mathbf{A}$  是  $m \times n$ ， $\mathbf{B}$  是  $n \times r$ ，那么

$$\text{rank}(\mathbf{A}) + \text{rank}(\mathbf{B}) - n \leq \text{rank}(\mathbf{AB}) \leq \min\{\text{rank}(\mathbf{A}), \text{rank}(\mathbf{B})\} \quad (546)$$

### 10.6 包含Dirac Delta函数的积分

假设  $\mathbf{A}$  是方阵，那么

$$\int p(\mathbf{s}) \delta(\mathbf{x} - \mathbf{As}) d\mathbf{s} = \frac{1}{\det(\mathbf{A})} p(\mathbf{A}^{-1} \mathbf{x}) \quad (547)$$

假设  $\mathbf{A}$  是“欠定”的，即“高瘦”的，那么

$$\int p(\mathbf{s}) \delta(\mathbf{x} - \mathbf{As}) d\mathbf{s} = \begin{cases} \frac{1}{\sqrt{\det(\mathbf{A}^T \mathbf{A})}} p(\mathbf{A}^+ \mathbf{x}) & \text{如果 } \mathbf{x} = \mathbf{AA}^+ \mathbf{x} \\ 0 & \text{其他地方} \end{cases} \quad (548)$$

见[9]

### 10.7 其他

对于任意的  $\mathbf{A}$  都成立

$$\text{rank}(\mathbf{A}) = \text{rank}(\mathbf{A}^T) = \text{rank}(\mathbf{A}\mathbf{A}^T) = \text{rank}(\mathbf{A}^T\mathbf{A}) \quad (549)$$

它成立

$$\mathbf{A} \text{ 是正定的} \Leftrightarrow \text{存在 } \mathbf{B} \text{ 可逆, 使得 } \mathbf{A} = \mathbf{B}\mathbf{B}^T \quad (550)$$

## 一维结果

### A.1 高斯分布

#### A.1.1 密度

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad (551)$$

#### A.1.2 归一化

$$\int e^{-\frac{(s-\mu)^2}{2\sigma^2}} ds = \sqrt{2\pi\sigma^2} \quad (552)$$

$$\int e^{-(ax^2+bx+c)} dx = \sqrt{\frac{\pi}{a}} \exp\left[\frac{b^2-4ac}{4a}\right] \quad (553)$$

$$\int e^{c_2x^2+c_1x+c_0} dx = \sqrt{\frac{\pi}{-c_2}} \exp\left[\frac{\frac{c_1^2}{4}-4c_2c_0}{-4c_2}\right] \quad (554)$$

#### A.1.3 导数

$$\frac{\partial p(\text{克})}{\partial \mu} = p(x) \frac{(\text{克} - \mu)}{\sigma^2} \quad (555)$$

$$\frac{\partial \ln p(\text{克})}{\partial \mu} = \frac{(\text{克} - \mu)}{\sigma^2} \quad (556)$$

$$\frac{\partial p(\text{克})}{\partial \sigma} = p(x) \frac{1}{\sigma} \left[ \frac{(\text{克} - \mu)^2}{\sigma^2} - 1 \right] \quad (557)$$

$$\frac{\partial \ln p(\text{克})}{\partial \sigma} = \frac{1}{\sigma} \left[ \frac{(\text{克} - \mu)^2}{\sigma^2} - 1 \right] \quad (558)$$

#### A.1.4 完成平方

$$\text{克}_2 \text{克}^2 + \text{克}_1 \text{克} + \text{克}_0 = -\text{克}(\text{克} - \text{克})^2 + \text{克}$$

$$-\text{克} = \text{克}_2 \quad \text{克} = \frac{1}{2} \frac{\text{克}_1}{\text{克}_2} \quad \text{克} = \frac{1}{4} \frac{\text{克}_1^2}{\text{克}_2} + \text{克}_0$$

或

$$\text{克}_2 \text{克}^2 + \text{克}_1 \text{克} + \text{克}_0 = \frac{1}{2\sigma^2} (\text{克} - \mu)^2 + \text{克}$$

$$\mu = \frac{-\text{克}_1}{2\text{克}_2} \quad \sigma^2 = \frac{-1}{2\text{克}_2} \quad d = c_0 - \frac{c_1^2}{4c_2}$$

#### A.1.5 矩阵的矩

如果密度由以下方式表示

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(s-\mu)^2}{2\sigma^2}\right] \quad \text{或者} \quad p(x) = C \exp(c_2x^2 + c_1x) \quad (559)$$

那么前几个基本矩为



## A.2 一维高斯混合一维结果

$$\begin{aligned}
 \langle x \rangle &= \mu &= \frac{-c_1}{2c_2} \\
 \langle x^2 \rangle &= \sigma^2 + \mu^2 &= \frac{-1}{2c_2} + \left( \frac{-c_1}{2c_2} \right)^2 \\
 \langle x^3 \rangle &= 3\sigma^2\mu + \mu^3 &= \frac{\frac{c_1}{2c_2}}{(2c_2)^2} \left[ 3 - \frac{c_1^2}{2c_2} \right] \\
 \langle x^4 \rangle &= \mu^4 + 6\mu^2\sigma^2 + 3\sigma^4 &= \left( \frac{\frac{c_1}{2c_2}}{2c_2} \right)^4 + 6 \left( \frac{\frac{c_1}{2c_2}}{2c_2} \right)^2 \left( \frac{-1}{2c_2} \right) + 3 \left( \frac{1}{2c_2} \right)^2
 \end{aligned}$$

以及中心矩是

$$\begin{aligned}
 \langle (x - \mu) \rangle &= 0 &= 0 \\
 \langle (x - \mu)^2 \rangle &= \sigma^2 &= \left[ \frac{-1}{2c_2} \right] \\
 \langle (x - \mu)^3 \rangle &= 0 &= 0 \\
 \langle (x - \mu)^4 \rangle &= 3\sigma^4 &= 3 \left[ \frac{1}{2c_2} \right]^2
 \end{aligned}$$

一种伪矩（非归一化积分）可以很容易地推导出来

$$\int \exp(c_2 x^2 + c_1 x) x^n dx = Z \langle x^n \rangle = \sqrt{\frac{\pi}{-c_2}} \exp \left[ \frac{c_1^2}{-4c_2} \right] \langle x^n \rangle \quad (560)$$

从非中心矩可以推导出其他实体，如

$$\begin{aligned}
 \langle x^2 \rangle - \langle x \rangle^2 &= \sigma^2 &= \frac{-1}{2c_2} \\
 \langle x^3 \rangle - \langle x^2 \rangle \langle x \rangle &= 2\sigma^2\mu &= \frac{\frac{2c_1}{(2c_2)^2}}{} \\
 \langle x^4 \rangle - \langle x^2 \rangle^2 &= 2\sigma^4 + 4\mu^2\sigma^2 &= \frac{2}{(2c_2)^2} \left[ 1 - 4 \frac{c_1^2}{2c_2} \right]
 \end{aligned}$$

## A.2 一维高斯混合

### A.2.1 密度和归一化

$$p(s) = \sum_k^K \frac{\rho_k}{\sqrt{2\pi\sigma_k^2}} \exp \left[ -\frac{1}{2} \frac{(s - \mu_k)^2}{\sigma_k^2} \right] \quad (561)$$

### A.2.2 矩

MoG的一个有用的事实是

$$\langle x^n \rangle = \sum_k \rho_k \langle x^n \rangle_k \quad (562)$$

其中  $\langle \cdot \rangle_k$  表示对第  $k$  个分量的平均。我们可以从密度函数计算前四个矩

$$p(x) = \sum_k \rho_k \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp \left[ -\frac{1}{2} \frac{(x - \mu_k)^2}{\sigma_k^2} \right] \quad (563)$$

$$p(x) = \sum_k \rho_k \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp \left[ c_{k2}x^2 + c_{k1}x \right] \quad (564)$$

如

$$\begin{aligned}
\langle x \rangle &= \sum_k \rho_k \mu_k &= \sum_k \rho_k \left[ \frac{-c_{k1}}{2c_{k2}} \right] \\
\langle x^2 \rangle &= \sum_k \rho_k (\sigma_k^2 + \mu_k^2) &= \sum_k \rho_k \left[ \frac{-1}{2c_{k2}} + \left( \frac{-c_{k1}}{2c_{k2}} \right)^2 \right] \\
\langle x^3 \rangle &= \sum_k \rho_k (3\sigma_k^2 \mu_k + \mu_k^3) &= \sum_k \rho_k \left[ \frac{c_{k1}}{(2c_{k2})^2} \left[ 3 - \frac{c_{k1}^2}{2c_{k2}} \right] \right] \\
\langle x^4 \rangle &= \sum_k \rho_k (\mu_k^4 + 6\mu_k^2 \sigma_k^2 + 3\sigma_k^4) &= \sum_k \rho_k \left[ \left( \frac{1}{2c_{k2}} \right)^2 \left[ \left( \frac{c_{k1}}{2c_{k2}} \right)^2 - 6 \frac{c_{k1}^2}{2c_{k2}} + 3 \right] \right]
\end{aligned}$$

如果所有的高斯函数都是以中心为基准的, 即  $\mu_k = 0$  对于所有的  $k$ , 那么

$$\begin{aligned}
\langle x \rangle &= 0 &= 0 \\
\langle x^2 \rangle &= \sum_k \rho_k \sigma_k^2 &= \sum_k \rho_k \left[ \frac{-1}{2c_{k2}} \right] \\
\langle x^3 \rangle &= 0 &= 0 \\
\langle x^4 \rangle &= \sum_k \rho_k 3\sigma_k^4 &= \sum_k \rho_k 3 \left[ \frac{-1}{2c_{k2}} \right]^2
\end{aligned}$$

从非中心矩可以推导出其他实体, 如

$$\begin{aligned}
\langle x^2 \rangle - \langle x \rangle^2 &= \sum_{k,k'} \rho_k \rho_{k'} \left[ \mu_k^2 + \sigma_k^2 - \mu_k \mu_{k'} \right] \\
\langle x^3 \rangle - \langle x^2 \rangle \langle x \rangle &= \sum_{k,k'} \rho_k \rho_{k'} \left[ 3\sigma_k^2 \mu_k + \mu_k^3 - (\sigma_k^2 + \mu_k^2) \mu_{k'} \right] \\
\langle x^4 \rangle - \langle x^2 \rangle^2 &= \sum_{k,k'} \rho_k \rho_{k'} \left[ \mu_k^4 + 6\mu_k^2 \sigma_k^2 + 3\sigma_k^4 - (\sigma_k^2 + \mu_k^2)(\sigma_{k'}^2 + \mu_{k'}^2) \right]
\end{aligned}$$

### A.2.3 导数

定义  $p(s) = \sum$  对于第  $j$  个分量的参数  $\theta_j$  of, 我们得到

$$\frac{\partial \ln p(s)}{\partial \theta_j} = \frac{\rho_j \mathcal{N}_s(\mu_j, \sigma_j^2)}{\sum_k \rho_k \mathcal{N}_s(\mu_k, \sigma_k^2)} \frac{\partial \ln(\rho_j \mathcal{N}_s(\mu_j, \sigma_j^2))}{\partial \theta_j} \quad (565)$$

也就是说,

$$\frac{\partial \ln p(s)}{\partial \rho_j} = \frac{\rho_j \mathcal{N}_s(\mu_j, \sigma_j^2)}{\sum_k \rho_k \mathcal{N}_s(\mu_k, \sigma_k^2)} \frac{1}{\rho_j} \quad (566)$$

$$\frac{\partial \ln p(s)}{\partial \mu_j} = \frac{\rho_j \mathcal{N}_s(\mu_j, \sigma_j^2)}{\sum_k \rho_k \mathcal{N}_s(\mu_k, \sigma_k^2)} \frac{(s - \mu_j)}{\sigma_j^2} \quad (567)$$

$$\frac{\partial \ln p(s)}{\partial \sigma_j} = \frac{\rho_j \mathcal{N}_s(\mu_j, \sigma_j^2)}{\sum_k \rho_k \mathcal{N}_s(\mu_k, \sigma_k^2)} \frac{1}{\sigma_j} \left[ \frac{(s - \mu_j)^2}{\sigma_j^2} - 1 \right] \quad (568)$$

注意  $\rho_k$  必须受到约束, 成为适当的比率。通过定义比率为

$\rho_j = e^{r_j} / \sum_k e^{r_k}$ , 我们得到

$$\frac{\partial \ln p(s)}{\partial r_j} = \sum_l \frac{\partial \ln p(s)}{\partial \rho_l} \frac{\partial \rho_l}{\partial r_j} \quad \text{哪里} \quad \frac{\partial \rho_l}{\partial r_j} = \rho_l (\delta_{lj} - \rho_j) \quad (569)$$

## B 证明和细节

### B.1 其他证明

#### B.1.1 方程式 524 的证明

以下证明是 Florian Roemer 的工作。请注意下面的向量和矩阵可以是复数, 符号  $\mathbf{X}^H$  用于转置和共轭, 而  $\mathbf{X}^T$  仅用于复数矩阵的转置。

定义行向量  $\mathbf{y} = \mathbf{a}^H \mathbf{X} \mathbf{B}$  和列向量  $\mathbf{z} = \mathbf{X}^H \mathbf{c}$ 。然后,  $\mathbf{a}^T \mathbf{X} \mathbf{B} \mathbf{X}^T \mathbf{c} = \mathbf{y} \mathbf{z} = \mathbf{z}^T \mathbf{y}$

请注意,  $\mathbf{y}$  可以重写为  $\text{vec}(\mathbf{y})^T$ , 这与  $\text{vec}(\text{conj}(\mathbf{y}))^H = \text{vec}(\mathbf{a}^T \text{conj}(\mathbf{X}) \text{conj}(\mathbf{B}))^H$  相同

其中“conj”表示复共轭。应用线性形式的  $\text{vec}$  规则  
方程式 520, 我们得到

$$\mathbf{y} = (\mathbf{B}^H \otimes \mathbf{a}^T \text{vec}(\text{conj}(\mathbf{X})))^H = \text{vec}(\mathbf{X})^T (\mathbf{B} \otimes \text{conj}(\mathbf{a}))$$

其中我们还使用了 Kronecker 乘积的转置规则。对于  $\mathbf{y}^T$ , 这得到了  $(\mathbf{B}^T \otimes \mathbf{a}^H) \text{vec}(\mathbf{X})$ 。类似地, 我们可以重写  $\mathbf{z}$ , 这与  $\text{vec}(\mathbf{z}^T) = \text{vec}(\mathbf{c}^T \text{conj}(\mathbf{X}))$  相同。再次应用方程式 520, 我们得到  $\mathbf{z} = (\mathbf{I} \otimes \mathbf{c}^T) \text{vec}(\text{conj}(\mathbf{X}))$

其中  $\mathbf{I}$  是单位矩阵。对于  $\mathbf{z}^T$ , 我们得到  $\text{vec}(\mathbf{X}) (\mathbf{I} \otimes \mathbf{c})$ 。最后, 原始表达式为  $\mathbf{z}^T \mathbf{y}^T$ , 现在采用以下形式  $\text{vec}(\mathbf{X})^H (\mathbf{I} \otimes \mathbf{c}) (\mathbf{B}^T \otimes \mathbf{a}^H) \text{vec}(\mathbf{X})$

最后一步是应用 Kronecker 积的乘积规则, 并通过此方式组合 Kronecker 积。这给出了  $\text{vec}(\mathbf{X})^H (\mathbf{B}^T \otimes \mathbf{c} \mathbf{a}^H) \text{vec}(\mathbf{X})$  这是所需的结果。

### B.1.2 方程式 493 的证明

对于任何矩阵参数  $\mathbf{X}$  的解析函数  $f(\mathbf{X})$ , 有

$$\begin{aligned} f(\mathbf{A} \mathbf{B}) \mathbf{A} &= \left( \sum_{n=0}^{\infty} c_n (\mathbf{A} \mathbf{B})^n \right) \mathbf{A} \\ &= \sum_{n=0}^{\infty} c_n (\mathbf{A} \mathbf{B})^n \mathbf{A} \\ &= \sum_{n=0}^{\infty} c_n \mathbf{A} (\mathbf{B} \mathbf{A})^n \\ &= \mathbf{A} \sum_{n=0}^{\infty} c_n (\mathbf{B} \mathbf{A})^n \\ &= \mathbf{A} f(\mathbf{B} \mathbf{A}) \end{aligned}$$

### B.1.3 方程 91 的证明

基本上我们需要计算

$$\begin{aligned}
\frac{\partial(\mathbf{X}^n)_{kl}}{\partial X_{ij}} &= \frac{\partial}{\partial X_{ij}} \sum_{u_1, \dots, u_{n-1}} X_{k,u_1} X_{u_1,u_2} \dots X_{u_{n-1},l} \\
&= \delta_{k,i} \delta_{u_1,j} X_{u_1,u_2} \dots X_{u_{n-1},l} \\
&\quad + X_{k,u_1} \delta_{u_1,i} \delta_{u_2,j} \dots X_{u_{n-1},l} \\
&\quad \vdots \\
&\quad + X_{k,u_1} X_{u_1,u_2} \dots \delta_{u_{n-1},i} \delta_{l,j} \\
&= \sum_{r=0}^{n-1} (\mathbf{X}^r)_{ki} (\mathbf{X}^{n-1-r})_{jl} \\
&= \sum_{r=0}^{n-1} (\mathbf{X}^r \mathbf{J}^{ij} \mathbf{X}^{n-1-r})_{kl}
\end{aligned}$$

利用第 9.7.4 节中找到的单个元素矩阵的性质，结果很容易得出。

#### B.1.4 方程式 571 的详细信息

$$\begin{aligned}
\partial \det(\mathbf{X}^H \mathbf{A} \mathbf{X}) &= \det(\mathbf{X}^H \mathbf{A} \mathbf{X}) \text{Tr}[(\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} \partial(\mathbf{X}^H \mathbf{A} \mathbf{X})] \\
&= \det(\mathbf{X}^H \mathbf{A} \mathbf{X}) \text{Tr}[(\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} (\partial(\mathbf{X}^H) \mathbf{A} \mathbf{X} + \mathbf{X}^H \partial(\mathbf{A} \mathbf{X}))] \\
&= \det(\mathbf{X}^H \mathbf{A} \mathbf{X}) \left( \text{Tr}[(\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} \partial(\mathbf{X}^H) \mathbf{A} \mathbf{X}] \right. \\
&\quad \left. + \text{Tr}[(\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} \mathbf{X}^H \partial(\mathbf{A} \mathbf{X})] \right) \\
&= \det(\mathbf{X}^H \mathbf{A} \mathbf{X}) \left( \text{Tr}[\mathbf{A} \mathbf{X} (\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} \partial(\mathbf{X}^H)] \right. \\
&\quad \left. + \text{Tr}[(\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} \mathbf{X}^H \mathbf{A} \partial(\mathbf{X})] \right)
\end{aligned}$$

首先，找到对  $\mathbf{X}$  的实部的导数

$$\begin{aligned}
\frac{\partial \det(\mathbf{X}^H \mathbf{A} \mathbf{X})}{\partial \Re \mathbf{X}} &= \det(\mathbf{X}^H \mathbf{A} \mathbf{X}) \left( \frac{\text{Tr}[\mathbf{A} \mathbf{X} (\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} \partial(\mathbf{X}^H)]}{\partial \Re \mathbf{X}} \right. \\
&\quad \left. + \frac{\text{Tr}[(\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} \mathbf{X}^H \mathbf{A} \partial(\mathbf{X})]}{\partial \Re \mathbf{X}} \right) \\
&= \det(\mathbf{X}^H \mathbf{A} \mathbf{X}) \left( \mathbf{A} \mathbf{X} (\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} + ((\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} \mathbf{X}^H \mathbf{A})^T \right)
\end{aligned}$$

通过计算，使用了(100)和(240)。此外，通过使用(241)，找到了对  $\mathbf{X}$  的虚部的导数即  $\partial \det(\mathbf{X}^H \mathbf{A} \mathbf{X})$

$$\begin{aligned}
\frac{\partial \det(\mathbf{X}^H \mathbf{A} \mathbf{X})}{\partial \Im \mathbf{X}} &= i \det(\mathbf{X}^H \mathbf{A} \mathbf{X}) \left( \frac{\text{Tr}[\mathbf{A} \mathbf{X} (\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} \partial(\mathbf{X}^H)]}{\partial \Im \mathbf{X}} \right. \\
&\quad \left. + \frac{\text{Tr}[(\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} \mathbf{X}^H \mathbf{A} \partial(\mathbf{X})]}{\partial \Im \mathbf{X}} \right) \\
&= \det(\mathbf{X}^H \mathbf{A} \mathbf{X}) \left( \mathbf{A} \mathbf{X} (\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} - ((\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} \mathbf{X}^H \mathbf{A})^T \right)
\end{aligned}$$

因此，导数为

$$\begin{aligned}
\frac{\partial \det(\mathbf{X}^H \mathbf{A} \mathbf{X})}{\partial \mathbf{X}} &= \frac{1}{2} \left( \frac{\partial \det(\mathbf{X}^H \mathbf{A} \mathbf{X})}{\partial \Re \mathbf{X}} - i \frac{\partial \det(\mathbf{X}^H \mathbf{A} \mathbf{X})}{\partial \Im \mathbf{X}} \right) \\
&= \det(\mathbf{X}^H \mathbf{A} \mathbf{X}) \left( (\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} \mathbf{X}^H \mathbf{A} \right)^T
\end{aligned}$$

而复共轭导数为

$$\begin{aligned}\frac{\partial \det(\mathbf{X}^H \mathbf{A} \mathbf{X})}{\partial \mathbf{X}^*} &= \frac{1}{2} \left( \frac{\partial \det(\mathbf{X}^H \mathbf{A} \mathbf{X})}{\partial \Re \mathbf{X}} + i \frac{\partial \det(\mathbf{X}^H \mathbf{A} \mathbf{X})}{\partial \Im \mathbf{X}} \right) \\ &= \det(\mathbf{X}^H \mathbf{A} \mathbf{X}) \mathbf{A} \mathbf{X} (\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1}\end{aligned}$$

注意，对于实数  $\mathbf{X}$ ,  $\mathbf{A}$ , (249)和(250)的和减少到(54)。  
类似的计算产生

$$\begin{aligned}\frac{\partial \det(\mathbf{X} \mathbf{A} \mathbf{X}^H)}{\partial \mathbf{X}} &= \frac{1}{2} \left( \frac{\partial \det(\mathbf{X} \mathbf{A} \mathbf{X}^H)}{\partial \Re \mathbf{X}} - i \frac{\partial \det(\mathbf{X} \mathbf{A} \mathbf{X}^H)}{\partial \Im \mathbf{X}} \right) \\ &= \det(\mathbf{X} \mathbf{A} \mathbf{X}^H) \left( \mathbf{A} \mathbf{X}^H (\mathbf{X} \mathbf{A} \mathbf{X}^H)^{-1} \right)^T\end{aligned}\quad (570)$$

和

$$\begin{aligned}\frac{\partial \det(\mathbf{X} \mathbf{A} \mathbf{X}^H)}{\partial \mathbf{X}^*} &= \frac{1}{2} \left( \frac{\partial \det(\mathbf{X} \mathbf{A} \mathbf{X}^H)}{\partial \Re \mathbf{X}} + i \frac{\partial \det(\mathbf{X} \mathbf{A} \mathbf{X}^H)}{\partial \Im \mathbf{X}} \right) \\ &= \det(\mathbf{X} \mathbf{A} \mathbf{X}^H) (\mathbf{X} \mathbf{A} \mathbf{X}^H)^{-1} \mathbf{X} \mathbf{A}\end{aligned}\quad (571)$$

## 参考文献

- [1] Karl Gustav Andersson and Lars-Christer Boiers. *Ordinera differentialekvationer*. Studentlitteratur, 1992.
- [2] Jörn Anemüller, Terrence J. Sejnowski, and Scott Makeig. Complex independent component analysis of frequency-domain electroencephalographic data. *Neural Networks*, 16(9):1311–1323, November 2003.
- [3] S. Barnett. 矩阵. 方法和应用. 牛津应用数学与计算科学系列. 克拉伦登出版社, 1990.
- [4] Christopher Bishop. 神经网络模式识别. 牛津大学出版社, 1995.
- [5] Robert J. Boik. 讲义: 统计学550. 在线, 2002年4月22日. 讲义.
- [6] D. H. Brandwood. 复杂梯度算子及其在自适应阵列理论中的应用. *IEEE Proceedings*, 130(1):11–16, 1983年2月. PTS. F和H.
- [7] M. Brookes. 矩阵参考手册, 2004年. 网站于2004年5月20日.
- [8] Contradsen K., 统计学导论, IMM讲义, 1984年.
- [9] Mads Dyrholm. 一些矩阵结果, 2004年. 网站于2004年8月23日.
- [10] Nielsen F. A., 公式, 神经研究单位和丹麦技术大学, 2002年.
- [11] Gelman A. B., J. S. Carlin, H. S. Stern, D. B. Rubin, 贝叶斯数据分析, Chapman and Hall / CRC, 1995年.
- [12] Gene H. Golub and Charles F. van Loan. 矩阵计算. 巴尔的摩约翰斯霍普金斯大学出版社, 第三版, 1996年.
- [13] Robert M. Gray. Toeplitz和循环矩阵: 一份综述. 技术报告, 信息系统实验室, 电气工程系, 斯坦福大学, 加利福尼亚州斯坦福, 94305, 2002年8月.
- [14] Simon Haykin. 自适应滤波器理论. 普林斯顿大学出版社, 上塞德尔河, 新泽西州, 第四版, 2002年.
- [15] 罗杰·霍恩和查尔斯·约翰逊. 矩阵分析. 剑桥大学出版社, 1985年.
- [16] Mardia K. V., J.T. Kent和J.M. Bibby, 多元分析, 学术出版社有限公司, 1979年.
- [17] Mathpages关于“特征值问题和矩阵不变量”的内容,  
  
<http://www.mathpages.com/home/kmath128.htm>
- [18] Carl D. Meyer. 修改矩阵的广义逆. *SIAM应用数学杂志*, 24(3):315–323, 1973年5月.

- [19] Thomas P. Minka. 对统计学有用的旧和新的矩阵代数, 2000年12月。笔记。
- [20] Daniele Mortari正交-斜对称和正交-对称矩阵三角学, John Lee Junkins天体动力学研讨会, AAS 03-265, 2003年5月。德克萨斯州A&M大学, College Station, TX
- [21] L. Parra 和 C. Spence. 非平稳源的卷积盲分离。在 *IEEE Transactions Speech and Audio Processing*, 页码 320-327, 2000年5月。
- [22] Kaare Brandt Petersen, Jiucang Hao 和 Te-Won Lee. 用于过完备表示的生成和过滤方法。神经信息处理 - 信件和评论, 卷 8(1), 2005年。
- [23] John G. Proakis 和 Dimitris G. Manolakis. 数字信号处理。Prentice-Hall, 1996年。
- [24] Laurent Schwartz. *Cours d'Analyse*, 第二卷。Hermann, Paris, 1967年。如 [14] 中引用。
- [25] Shayle R. Searle. 矩阵代数在统计学中的应用。John Wiley and Sons, 1982年。
- [26] G. Seber 和 A. Lee. 线性回归分析。John Wiley and Sons, 2002。
- [27] S. M. Selby. 标准数学表。CRC Press, 1974。
- [28] Inna Stainvas. 微分计算中的矩阵代数。神经计算研究小组, 信息工程, 阿斯顿大学, 英国, 八月 2002。笔记。
- [29] P. P. Vaidyanathan. 多速率系统和滤波器组。Prentice Hall, 1993。
- [30] Max Welling. 卡尔曼滤波器。讲义。
- [31] 维基百科关于子式: "子式 (线性代数)",  
  
[http://en.wikipedia.org/wiki/Minor\\_\(linear\\_algebra\)](http://en.wikipedia.org/wiki/Minor_(linear_algebra))
- [32] Zhaoshui He, Shengli Xie, 等, "基于稀疏表示的频域卷积盲源分离", *IEEE Transactions on Audio, Speech and Language Processing*, vol.15(5):1551-1563, 2007年7月。
- [33] Karim T. Abou-Moustafa关于广义特征值问题的特征值和特征向量的导数。麦吉尔技术报告, 2010年10月。
- [34] Mohammad Emtiyaz Khan当添加/删除一行时, 更新矩阵的逆. *Emt CS, UBC* 2008年2月27日

## 索引

- 反对称, 54
- 分块矩阵, 46
- 链式法则, 15
- 乔列斯基分解, 32
- 共偏度, 34
- 共偏斜度, 34
- 条件数, 62
- 克莱默法则, 29
- 复矩阵的导数, 24
- 行列式的导数, 8
- 迹的导数, 12
- 逆的导数, 9
- 对称矩阵的导数, 15
- Toeplitz矩阵的导数, 16
- 狄利克雷分布, 37
- 特征值, 30
- 特征向量, 30
- 指数矩阵函数, 59
- 高斯, 条件, 40
- 高斯, 熵, 44
- 高斯, 线性组合, 41
- 高斯, 边际, 40
- 高斯, 密度的乘积, 42
- 广义逆, 21
- 哈达玛不等式, 52
- 共轭, 48
- 幂等, 49
- 克罗内克积, 59
- LDL分解, 33
- LDM分解, 33
- 线性回归, 28
- LU分解, 32
- 李雅普诺夫方程, 30
- 摩尔-彭罗斯逆, 21
- 多项式分布, 37
- 幂零, 49
- 矩阵的范数, 61
- 向量的范数, 61
- 正态逆伽玛分布, 37
- 正态逆威夏特分布, 39
- 正交, 49
- 矩阵的幂级数, 58
- 概率矩阵, 55
- 伪逆, 21
- 舒尔补, 41, 47
- 单元素矩阵, 52
- 奇异值分解 (SVD), 31
- 斜厄米矩阵, 48
- 斜对称矩阵, 54
- 随机矩阵, 55
- 学生-t分布, 37
- Sylvester不等式, 62
- 对称矩阵, 54
- 泰勒展开, 58
- Toeplitz矩阵, 54
- 过渡矩阵, 55
- 三角函数, 59
- 幂等矩阵, 49
- 范德蒙矩阵, 57
- 向量算子, 59, 60
- Wishart分布, 38
- Woodbury恒等式, 18